



In Prospect and Retrospect: Reflective Memory Management for Long-term Personalized Dialogue Agents

Zhen Tan, Jun Yan, I-Hung Hsu, Rujun Han, Zifeng Wang

♠ Arizona State University, ♠ Google Cloud AI Research

♠ Google Cloud AI, ♠ University of North Carolina at Chapel Hill

ACL '25

Presented by Lili Pan

作者团队

研究方向

- Human-centered AI
- Explainable and interpretable machine learning
- Foundation models
- Trustworthy AI systems



Zhen Tan

Arizona State University, Ph.D.

CMU, master

HUST, bachelor



Huan Liu

Arizona State University

1. 【ICLR 2026】 Probing to Refine: Reinforcement Distillation of LLM Reasoners via Explanatory Inversion. **Zhen Tan**, Chengshuai Zhao, Song Wang, Jundong Li, Tianlong Chen, **Huan Liu**.
2. 【ICLR 2026】 CAR-LoRA: Training Compression-Aware and Robust LoRA Adapters for Evolving LLMs. Rana Shahroz, **Zhen Tan**, Ruichen Zhang, Hua Wei, Tianlong Chen, Charles Fleming.

Outline

1

Background

2

Limitation

3

Design


4

Experiments

5

Conclusion

Dialog agent



Agent: 渊博但“健忘”

Dialog agent

- **通俗理解:** 知识渊博但记性不好的专家
- **核心优点:** 知识储备极其丰富，能回答各种各样的专业或常识问题。
- **当前局限:** “记性”很差，缺乏长程记忆能力，每次对话都像是第一次见面，记不住上下文。 (2025)

Dialog agent

Agent在长期对话中的核心挑战

1. 上下文窗口限制

2. 固有的无状态性

3. 缺乏持续的个性化表征

➤ 用户长期偏好、行为模式建模

- 短期记忆容量有限
- 旧信息易被新内容覆盖
- 长对话中易丢失细节





图1：个性化医疗中Dialog agent的长期记忆需求

外部记忆机制

外部记忆机制发展阶段

- **早期方法：**基于规则或监督学习的记忆网络（如 MemNN），需手动设计记忆结构与更新规则。
- **近期方法：**检索增强生成（RAG）系统，结合LLM与外部知识库，实现检索式问答。
- **当前主流：**LDAgent、MemoryBank等框架，引入外部记忆库管理长期对话历史，突破上下文限制。



Outline

1

Background

2

Limitation

3

Design

4

Experiments

5

Conclusion

局限性（一）：僵化的记忆粒度


现有方法

- 基于固定的结构（如轮次、会话、时间窗口）来划分和存储记忆
- 预定义的粒度与对话的自然语义结构（如话题、事件）往往不一致


局限性

- 记忆碎片化、关键信息丢失
- 语义关联被切断，严重影响后续的检索效率和准确性

现有方法：固定结构划分



理想状态：语义结构划分



局限性（二）：固定检索机制


现有方法：静态依赖与策略固化

现有方法严重依赖静态的、预训练的检索器（eg: BM25、Sentence-BERT）。核心局限在于：

- 检索策略固定，无法根据对话上下文动态调整
- 忽略用户实时意图与特定领域的特性差异

局限性：精度不足与适应性差

- 复杂/多轮对话中检索精度显著下降
- 难以适应多样化的用户交互模式与场景



核心痛点：一把钥匙开所有锁

现有记忆范式的局限性

范式	内存边界	检索适应性	标注成本
Long-Context	窗口限制	静态	零
RAG (Turn/Session)	固定且碎片化	静态	零
Fixed Agents (MemoryBank)	固定	启发式 / 规则驱动	高
理想状态 (RMM)	基于主题的动态整合	强化学习在线自适应	无监督

核心痛点： 固定的分割粒度破坏了对话的语义连贯性，而静态的检索器无法适应多变的用户习惯且微调查成本高昂。

Outline

1

Background

2

Limitation

3

Design

4

Experiments

5

Conclusion

RMM (Reflective Memory Management)

范式	内存边界	检索适应性	标注成本
Long-Context	窗口限制	静态	零
RAG (Turn/Session)	固定且碎片化	静态	零
Fixed Agents (MemoryBank)	固定	启发式 / 规则驱动	高
理想状态 (RMM)	基于主题的动态整合	强化学习在线自适应	无监督

静态的记忆管理策略 vs. 动态的对话交互需求

RMM (Reflective Memory Management)

一种**自适应的、动态的记忆管理机制**


- **动态组织记忆**: 能够根据对话的语义结构, 灵活地划分、合并和更新记忆单元, 而非依赖固定粒度。
- **自适应优化检索**: 能够利用对话过程中的实时反馈信号, 在线调整检索策略, 使其适应不同的上下文和用户模式。

RMM (Reflective Memory Management)

核心思想：整合前瞻性 (Prospective) 和回顾性 (Retrospective) 两种反思机制，解决现有方法痛点

前瞻性反思

- **功能：**动态提取、打破边界、基于特定主题进行合并
- **核心目标：**为未来检索构建完美的搜索空间



回顾性反思

- **功能：**利用 LLM 引用作为奖励，通过强化学习在线更新检索策略
- **核心目标：**从“过去”的效用中学习最佳的搜索策略



RMM框架总览



Algorithm 1 Reflective Memory Management (RMM) for Dialogue Agents

Input: query q , past messages in current session S , memory bank B , retriever f_θ , reranker g_ϕ , **LLM**

Output: response a , updated S , g_ϕ , B

```
1: Retrieve:  $\mathcal{M}_K \leftarrow f_\theta(q, B)$ 
2: Rerank:  $\mathcal{M}_M \leftarrow g_\phi(q, \mathcal{M}_K)$ , where  $\mathcal{M}_M = \{m_i\}_{i=1}^M$ 
3: // Retrospective Reflection
4: Generate:  $a, R_M \leftarrow \text{LLM}(q, S, \mathcal{M}_M)$  where  $R_M = \{r_i\}_{i=1}^M$ 
5:  $g_\phi \leftarrow \text{RL\_Update}(g_\phi, R_M)$ 
6:  $S.append((q, a))$ 
7: // Prospective Reflection
8: if session  $S$  ends then
9:    $\mathcal{M} \leftarrow \text{ExtractMemory}(S)$ 
10:  for  $m \in \mathcal{M}$  do
11:     $B \leftarrow \text{UpdateMemory}(B, m)$ 
12:  end for
13:   $S \leftarrow []$ 
14: end if
```

1. 记忆库 (Memory Bank)

存储对话历史，条目包含“主题摘要”与“原始对话片段”，摘要用于快速检索。

2. 检索器 (Retriever)

基于当前用户查询，从记忆库中初步筛选出相关的记忆条目。

3. 重排器 (Reranker)

对检索结果精细化排序提升相关性，参数可通过回顾性反思动态更新。


4. 大模型生成 (LLM)

生成个性化回复，生成过程提供归因信号用于回顾性反思。

Prospective Reflection (前瞻性反思)

基于主题的记忆组织

- **解决的问题：**记忆粒度僵化
 - 传统按固定轮次或会话划分，导致信息碎片化
 - 无法适应灵活的对话场景需求
- **核心目标：**构建主题单元
 - 将对话历史重组为逻辑连贯的主题单元
 - 确保记忆的完整性与相关性
- **实现方式：**自动提取与主题存储
 - 会话结束后自动提取核心主题
 - 将其作为独立记忆条目存储
 - 为未来基于主题的精准检索奠定基础



摒弃固定的轮次或会话切分，PR 机制动态跨越话语界限，将对话历史提炼为语义连贯的核心主题，彻底解决内存碎片化问题。

Prospective Reflection (前瞻性反思)




图2：前瞻性反思示意图

1. 记忆提取 (Memory Extraction)

在会话结束后，使用LLM分析会话历史，识别讨论的不同主题，并为每个主题生成对应的摘要和原始对话片段。

2. 记忆更新 (Memory Update)

将新记忆与记忆库现有记忆比较：

若为全新主题则直接添加；

若为补充或更新，则与旧记忆合并。

核心：通过“提取-更新”闭环，确保记忆库随对话动态演进，保持信息的时效性与完整性。

Prospective Reflection (前瞻性反思)




图2：前瞻性反思示意图

1. 记忆提取 (Memory Extraction)

输出结构化记忆条目

- **主题 (Topic)**: 记忆片段的核心
- **摘要 (Summary)**: 对主题内容的简洁概括
- **原始对话**: 关联的具体对话文本原文

2. 记忆更新 (Memory Update)


- **新增 (Add)**: 无相似旧记忆, 直接添加
- **合并 (Merge)**: 对旧主题补充或更新

优势: 保持记忆的紧凑与高密度, 减少冗余, 并且记忆是持续演进更新的。

Retrospective Reflection (回顾性反思)

基于反馈的检索优化

- **解决的问题：**
 - 传统检索机制固定僵化
 - 打破静态匹配局限，引入动态调整机制
- **核心目标：**
 - 利用LLM生成的反馈信号，在线优化检索器
 - 能够自适应不同的对话场景和用户模式
- **实现方式：**
 - 无需人工标注
 - 通过模型自身生成的归因信号进行自我学习
 - 动态调整检索策略




让检索器从“静态工具”进化为“可学习的智能组件”

Retrospective Reflection (回顾性反思)

流程核心步骤

- **生成回复和归因**: LLM生成回复时, 自动判断检索记忆的“有用性”(引用/未引用), 从而产生精准的归因反馈信号
- **强化学习更新**: 将归因信号作为奖励, 通过RL更新重排器(reranker)参数
- **优化未来检索**: 重排器优先选择更可能被使用的记忆, 提升对话质量



回顾性反思形成了“生成-反馈-优化”的学习闭环

Retrospective Reflection (回顾性反思)




图3：回顾性反思的示意图


将LLM的引用行为转化为强化学习信号
基于归因的二进制奖励机制

- 被引用的记忆获得+1奖励
- 未被引用的获得-1奖励
- 一个轻量级的、可微分的重排序器，根据这些奖励进行在线优化
- 在特定对话上下文中优先选择对生成器真正有用的记忆。

核心：利用 LLM 生成的归因信号作为反馈，驱动重排序器的在线强化学习，实现记忆检索的自我进化。

PR+RR 搜索空间与搜索策略结合

RR → PR: 回顾性反思依赖于高质量的候选池。重排序器确保在庞大的 Memory Bank中, 最契合当前语境的主题块被精准激活。



PR → RR: 前瞻性提取构建了高质量、低噪音的主题记忆块, 降低了检索难度, 使得 LLM 的引用打分更加准确。

没有 PR: RR 会在碎片化的噪音中迷失方向。没有 RR: PR 提炼的金矿无法被动态发掘。
结论: 结构化记忆 (空间) 与强化学习检索 (策略) 相互强化, 共同攻克长期对话个性化难题。

Outline

1

Background

2

Limitation

3

Design

4

Experiments

5

Conclusion

- **生成器**

- Gemini-1.5-Flash

- **检索器**

- Contriever^[2022]: 一个针对语义搜索优化的密集检索器
- Stella^[2024]: 一种基于语言模型开发的大型嵌入检索器
- GTE^[2023]: 一款专为指令跟踪查询设计的检索器

数据集

- MSC^[2022]
- 评估衡量生成的响应是否与人类提供的真实情况相符
- LongMemEval^[2024]
- 评估模型从对话历史中检索相关信息的能力

实验结果

Method	Retriever	MSC		LongMemEval	
		METEOR (%) ↑	BERT (%) ↑	Recall@5 (%) ↑	Acc. (%) ↑
No History	-	5.2	10.6	-	0.0
Long Context	-	14.8	31.9	-	57.4
RAG	Contriever	24.8	50.8	54.3	58.8
	Stella	26.2	51.6	59.2	61.4
	GTE	27.5	52.1	62.4	63.6
MemoryBank	Specific1	20.1	40.3	58.6	59.6
LD-Agent	Specific2	25.4	51.5	56.8	59.2
RMM (Ours)	Contriever	30.8	55.4	60.4	61.2
	Stella	31.9	56.3	65.9	64.8
	GTE	33.4	57.1	69.8	70.4
RAG	Oracle	-	-	100.0	90.2

历史信息的必要性

RMM框架在长期个性化对话任务上的优越性

Variant	MSC		LongMemEval	
	METEOR	BERT	Recall@5	Acc.
RAG	24.8	50.8	54.3	58.8
+ PR	28.6	53.3	57.4	59.6
+ RR (W/O reranker)	20.3	31.8	34.2	31.0
+ RR	27.5	52.2	58.8	60.2
RMM	30.8	55.4	60.4	61.2


PR: 按语义主题重构记忆库，本身就能有效改善未来检索的相关性

RR(W/O reranker): 不引入重排序器，直接更新大型检索器参数是不稳定且低效的

RR: 通过一个小的、可学习的重排序器来承载在线自适应，是高效且可行的策略

前瞻性反思（优化记忆存储）和回顾性反思（优化记忆检索）是互补并且协同的


实验--不同记忆粒度的影响



- **固定粒度：按轮次**
- **固定粒度：按会话**
- **混合粒度：同时检索轮次和会话**
- **本文方法：前瞻性反思**
- **理想情况：为每个问题人工选择最佳粒度，作为理论上限**

实验证实了“**固定记忆粒度是局限性**”这一核心论点，并证明了前瞻性反思所实现的**动态的、主题化的记忆组织方式**，是解决此问题的有效方案

实验--离线监督训练的影响



- **固定粒度：**按轮次
- **固定粒度：**按会话
- **混合粒度：**同时检索轮次和会话
- **本文方法：**前瞻性反思
- **理想情况：**为每个问题人工选择最佳粒度，作为理论上限

有标注数据时，用标注数据初始化系统以获得更好起点；
无标注数据时，系统依然能通过纯在线、无监督的方式自我优化。

Outline

1

Background

2

Limitation

3

Design

4

Experiments

5

Conclusion

Conclusion

• Conclusion

- 首次提出整合**前瞻性反思**和**回顾性反思**的记忆管理机制
- 通过**基于主题的记忆组织**和**在线RL优化检索**，实现了更灵活的记忆存储和更智能的检索策略
- 在多个数据集上的实验证明了RMM的优越性，为构建长期个性化对话代理提供了新的思路

• Inspiration

➤ 能不能进一步提高？

- ✓ 可以。RMM只是一个强大的框架，可以结合更优的排序算法、更细粒度的记忆关系建模等
- ✓ 当前记忆库是扁平的条目集合，引入层次化结构、知识图谱结构，能更好地建模复杂领域的内在逻辑

➤ 能不能用到我们的场景？EvoIoT

- ✓ 按topic抽取记忆，eg：IoT操作系统、头文件冲突、编译错误...
- ✓ 按经验采用次数评分，把多轮验证后高分经验蒸馏、注入模型参数或 adapter 中

➤ 泛化性？



Q&A

2026.03.30