

FineBadminton: A Multi-Level Dataset for Fine-Grained Badminton Video Understanding

Authors: Xusheng He, Wei Liu, Shanshan Ma*, Qian Liu,
Chenghao Ma, Jianlong Wu*
Harbin Institute of Technology, Shenzhen

ACM MM, 2025

Presenter: Shizhe Xue

2026.4.6

Recent Papers:



Jianlong Wu

Professor, Harbin Institute of Technology (Shenzhen)
在 pku.edu.cn 的电子邮件经过验证 - [首页](#)

[Computer Vision](#) [Multimodal Learning](#)

[TPAMI'25] A Survey on Video Temporal Grounding with Multimodal Large Language Model

[ACL'25] HAIC: Improving Human Action Understanding and Generation with Better Captions for Multi-modal Large Language Models

[TMM'25] RA-BLIP: Multimodal Adaptive Retrieval-Augmented Bootstrapping Language-Image Pre-training

- **研究背景**
- **MLLM驱动的羽毛球比赛分析**
- **针对羽毛球比赛的微调策略**
- **总结与思考**

■ 研究背景

■ MLLM驱动的羽毛球比赛分析

■ 针对羽毛球比赛的微调策略

■ 总结与思考

研究背景

问题场景

1. 羽毛球比赛具有**体积小、球速高、时空细节多、动作变化快以及战术博弈复杂**的特点，只用大模型很难从视频中提取有效信息。

2. 现有羽毛球比赛数据集只关心**基础数据**（击球类别等）而不捕捉球员**战术意图、动作质量**

3. 现有论文算法多为基于已经标注好的数据进行**概率预测**，而非从实际比赛视频中提取时空信息再进一步处理。



研究背景

羽毛球比赛分析现状

➤ 技术基础

现有羽毛球数据集（如 ShuttleSet, VideoBadminton）主要关注基础任务，例如**球路追踪**、**击球点检测**或简单的**击球动作分类**。

对于这些基础任务，已有许多成熟的解决方案

- 球路追踪：TrackNetV1~V4
- 击球点检测：YOLOV8-Pose（检测击球动作）、GCCE(基于球员足迹)
- 击球动作分类：BST(Badminton Stroke Transformer)

➤ 应用潜力

- 羽毛球比赛战术分析 -> AI教练
- 运动员比赛经验学习 -> 球员风格学习

方案对比

方案名称	主要任务	核心技术	优点	缺点
TrackNet	球路追踪	基于热图预测的 CNN 架构	在高速运动和遮挡场景下表现稳健。	在 复杂背景 （如观众席颜色相近）下可能出现 误报 ；处理超高速球时的像素丢失仍是挑战。
YOLOv8-Pose	击球动作检测	实时人体关键点检测	检测速度极快，适合部署在移动端；能精准捕捉球员挥拍瞬间的肢体轮廓。	比赛中 肢体重叠 或形变会导致关键点漂移；无法感知球的逻辑。
GCCE	击球点检测	球员移动轨迹时空建模	利用物理规律（如击球前必有跨步），提供极强的空间约束，辅助定位击球。	严重 依赖拍摄角度 ；对非典型步法（如鱼跃）的 泛化差
BST	动作分类	羽毛球轨迹 + 人体骨架的 Transformer 融合	捕捉了击球前后的时空长程依赖关系，擅长处理球速与动作之间的“因果”关联。	计算资源需求大 ；需要球路和人体数据的高度同步，对 数据预处理质量 要求极高。

Motivation

- **细粒度理解**：通用大模型（MLLMs）虽然在基础视频理解上表现出色，但面对羽毛球这种超高速、高频次的复杂场景，难以捕捉击球瞬间的细微差异和深层战术决策。
- **大规模专业标注数据难**：羽毛球**事件密度极高**且专业性强，纯**人工标注**多维度的精细数据**成本高昂**且难以保持一致性。急需一套自动化的流水线，平衡标注的“规模”与“专业深度”。
- **FineBadminton**：小模型+大模型设计，多层次、细粒度语义提取

- 研究背景
- **MLLM驱动的羽毛球比赛分析**
- 针对羽毛球比赛的微调策略
- 总结与思考

多层次比赛评估体系



① 基础动作层

- 对单次击球进行精细分类
- 含 11 种主要击球类型和 20 种基于手腕/手部动作的子类型

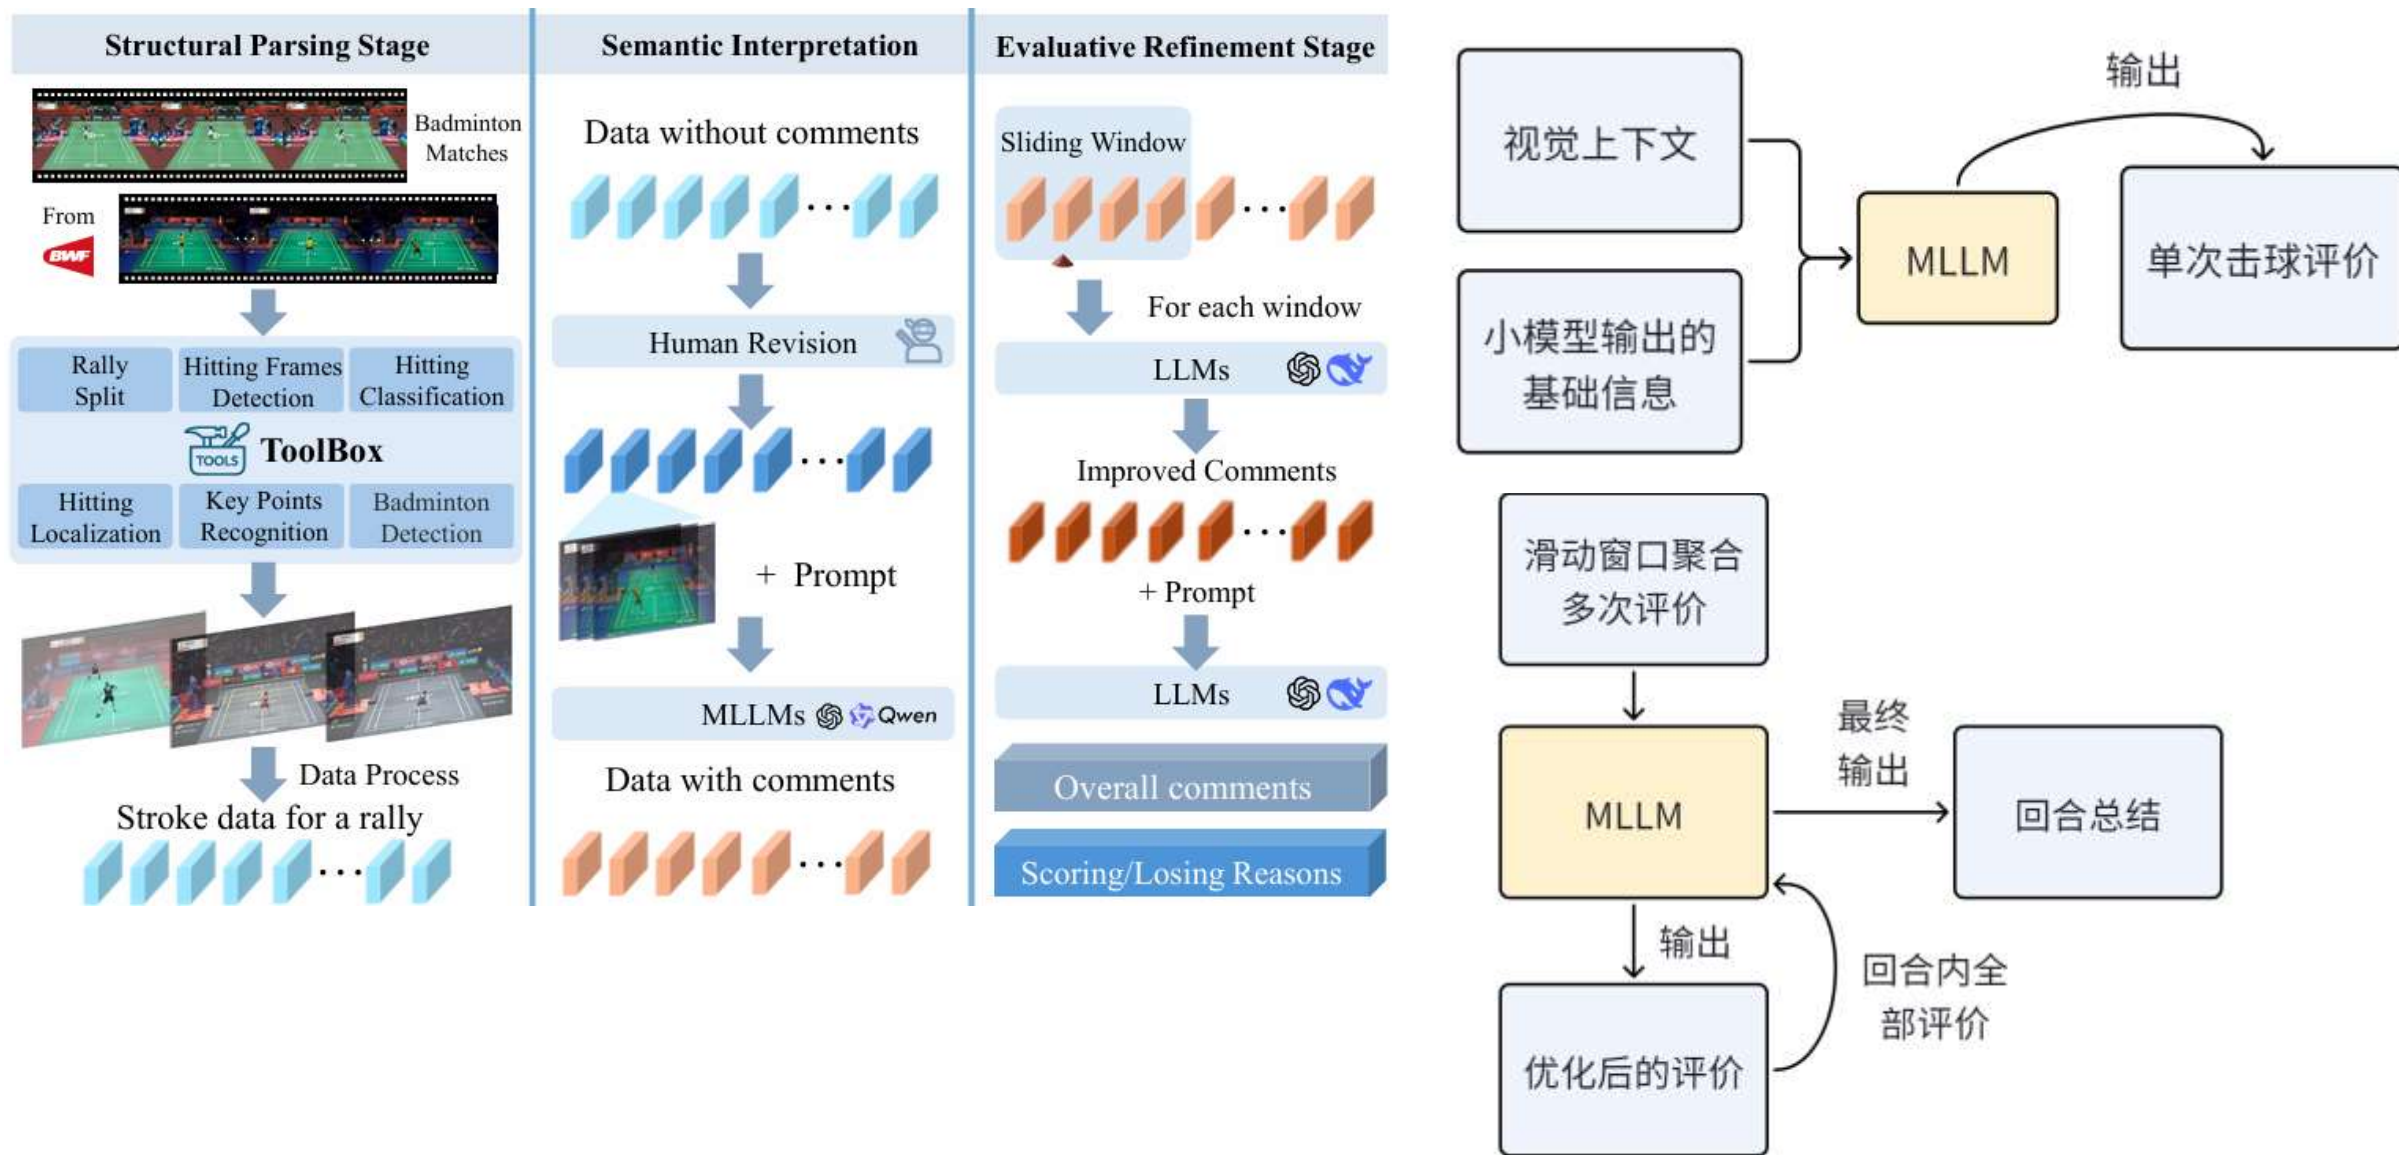
② 战术语义层

- 描述球的轨迹、推断球员的意图
- 飞行轨迹、人球关系、意图

③ 决策评估层

- 对单次击球和全回合的评价
- 单球质量打分，分析得分、失分原因，整体战术评价

MLLM驱动的羽毛球比赛分析



- 研究背景
- MLLM驱动的羽毛球比赛分析
- **针对羽毛球比赛的微调策略**
- 总结与思考

策略1：以击球帧为中心的关键帧选择

通过筛选“击球帧” + “查询帧” 的图片序列，减少输入LLM的总帧数

系统根据videoMAE对每一帧的预测概率分成两类：


1.击球帧 (A)： 击球概率超过阈值的帧，即击球发生的瞬间。

作用：代表了击球动作的核心节点。

2.查询帧 (Q)： 在两个击球帧之间的片段中采样的帧。

作用：捕捉击球前后的动态过程（如引拍、跑位）。


该策略极大减少了输入视频的总帧数，同时保留了完整的战术回合结构。



策略2：坐标引导的视觉信息压缩

通过对“查询帧”进行压缩编码，保留图片中关键信息

- 所有帧首先经过MLLM的视觉编码器，转为对应Token。
- 注意力计算：对查询帧中的关键元素(羽毛球)加入一个偏置项
- 压缩：击球帧不压缩；查询帧压缩为固定 R 个Token



实验结果对比

Model	Count			Action			Position			Cognition						Overall	
	T1	T2	T3	T4	T5	T6	T7	T8	T9	T10	T10*	T11	T11*	T12	T12*	Choice	Open-ended
Full Score	200	83	130	250	200	200	200	200	200	250	500	250	500	250	500	2413	1500
Commerical Models																	
Gemini 2.5 Pro	69	33	34	67	70	44	54	63	45	124	192	114	214	155	325	872 (36.14%)	731 (48.73%)
Gemini 2.5 Pro + S	79	28	35	68	71	54	58	70	53	131	202	117	222	168	335	932 (38.62%)	759 (50.60%)
Doubao 1.5 pro	71	23	45	55	50	36	40	61	52	133	165	112	213	133	286	811 (33.61%)	664 (44.27%)
Doubao 1.5 pro + S	71	30	48	56	57	39	48	68	45	130	188	121	227	143	294	856 (35.47%)	709 (47.27%)
GPT-4.1	47	12	40	76	55	60	40	30	48	110	183	98	217	128	310	743 (30.79%)	710 (47.33%)
GPT-4.1 + S	46	17	41	70	61	64	44	39	49	112	186	100	213	138	316	782 (32.41%)	715 (47.67%)
Open-Source Models																	
Qwen2.5VL-7B	48	19	30	50	39	33	52	41	41	60	110	62	79	82	46	557 (23.08%)	235 (15.67%)
Qwen2.5VL-7B + S + C	70	24	36	92	44	87	56	55	98	170	172	142	205	141	278	1015 (42.06%)	655 (43.67%)
VideoLLaMA3-7B	42	10	20	17	44	24	30	20	12	45	95	55	66	40	47	359 (14.88%)	208 (13.87%)
VideoLLaMA3-7B + S + C	52	24	25	85	54	80	40	68	96	165	167	130	198	135	264	954 (39.54%)	629 (41.93%)

在FBBench下，使用策略1(S)和2(C)与不使用结果对比，包括开源和商用模型

- 研究背景
- MLLM驱动的羽毛球比赛分析
- 针对羽毛球比赛的微调策略
- **总结与思考**

总结与思考

总结

FineBadminton通过**分层语义体系**和关键信息提纯策略，提升了LLM对**高速**运动视频的时空理解准确度；构建了自动化分析流水线，实现了从底层结构化解析到高层战术评价的闭环，为体育视频理解提供了基础框架。其细粒度的语义标注为“**AI教练**”与“**球员战术模拟**”等应用带来更多可能。

思考

算力开销：FineBadminton在击球帧识别使用**VideoMAE**，训练和推理开销过大，限制了**实时性**部署，未来可探讨**轻量化骨架提取**或基于**物理**先验知识的预测算法，以实现计算能效的平衡。

球员风格记忆库：论文提出的决策评估层捕获了**球员的意图与偏好**。若能利用这些深层语义进行建模，有望构建“球员风格记忆库”，从而实现个性化的对手分析与击球策略推演。



Thank you!