

# FAST: Efficient Action Tokenization for Vision-Language-Action Models

*Robotics: Science and Systems (RSS), 2025 (Best Paper Finalist)*

Karl Pertsch, Kyle Stachowicz, Brian Ichter, Danny  
Driess, Suraj Nair ...

徐翎

4.7

# 章节目录

- 作者团队介绍
- VLA基础
- 研究背景和动机
- FAST方法
- 实验评估
- 总结与讨论

# 作者团队介绍

## Physical Intelligence

定位:

专注于 Robot Foundation Model（机器人基础模型） 目标构建类似 GPT 的通用机器人系统

该团队成员主要来自:

- Google DeepMind
- Stanford University
- University of California, Berkeley

代表工作

- $\pi$ 0: A Vision-Language-Action Flow Model for General Robot Control
- $\pi$ 0.5: a VLA with Open-World Generalization
- VLAs with Long and Short-Term Memory

**Website:** [Physical Intelligence \( \$\pi\$ \)](#)



Karl Pertsch




Brian Ichter

# VLA基础

## VLA (Vison Language Action)

VLA模型是一种对环境进行感知，根据指令生成机器人动作的**控制模型**

- 输入：图像 + 语言 + 状态
- 输出：机器人动作



动作策略的三种主流设计



基于预训练VLM的VLA模型

# 研究背景和动机


## Tokenization

Transformer 模型预测tokens。Tokenization是将连续的动作空间映射成离散的tokens的过程。

在自回归方法中以往的朴素分箱（binning）策略在高频控制的机器人场景中表现不佳。如OpenVLA。

**Challenge 1: 模型训练效率受阻。**高频控制中前后token高度相关，模型直接复制上一个token就能取得较低的loss，并没有真正学习到有效的控制策略。

**Challenge 2: 模型推理效率受阻。**对于自回归方法，控制频率和计算复杂度直接挂钩，高频控制中生成动作密集，推理效率慢。




# FAST方法

## Frequency-space Action Sequence Tokenization (FAST)

DCT（Discrete Cosine Transform）是把一个时间序列表示成一组“不同频率的余弦波”的加权组合。本质是线性空间变换。在FAST中是将动作从时间域变换到频率域。

$$\text{Signal} = c_0 \cdot \text{低频波} + c_1 \cdot \text{中频波} + c_2 \cdot \text{高频波} + \dots$$

机器人动作通常比较平滑，信息主要集中在低频，高频信息主要由动作细节与噪声组成。



# FAST方法

## Frequency-space Action Sequence Tokenization (FAST)

对每一个生成的Action chunk

$$A = [a_0, a_1, \dots, a_{N-1}] \quad A \in R^{N \cdot D}$$

$$a_0 = [x_0, y_0, d_0, \theta_0, \dots]$$

$$a_1 = [x_1, y_1, d_1, \theta_1, \dots]$$

$\vdots$

$$a_{N-1} = [x_{N-1}, y_{N-1}, d_{N-1}, \theta_{N-1}, \dots]$$

其中 $N$ 为chunk长度， $D$ 为控制维度

DCT系数  $C \in R^{D \cdot N}$


$$c_{(1,k)} = \sum_{n=0}^{N-1} x_n \cdot \cos\left(\frac{\pi}{N}\left(n + \frac{1}{2}\right)k\right)$$

$$\downarrow$$
$$c_{(1,k)} = X \cdot \text{余弦基}_k$$


$$\downarrow \text{拓展}$$
$$c_1 = X \cdot D$$

$$\downarrow \text{拓展}$$
$$C = A \cdot D$$

变换完成。



# FAST方法



FAST 整体 Pipeline



# FAST+

## FAST+: A Universal Robot Action Tokenizer

在FAST中，唯一需要训练的部件是BPE（Byte Pair Encoding）

- 针对每个新数据集进行训练
- 轻量但是泛化能力差

而在此基础上作者训练了一个更大规模的FAST模型

- 将所有动作填充到32维
- 在海量的数据集上混合训练
- 能够对任何机器人动作块进行编码

| Dataset Name         | Morphology | Action Space | Control Frequency (Hz) | Mixture Weight (%) |
|----------------------|------------|--------------|------------------------|--------------------|
| ARX                  | Bi-manual  | Joint        | 50                     | 7.2                |
| AgileX               | Bi-manual  | Joint        | 50                     | 1.8                |
| Fibocom              | Mobile     | Joint        | 50                     | 2.9                |
| Franka FR3           | Single arm | Joint        | 20                     | 3.7                |
| Mobile Trossen       | Mobile     | Joint        | 50                     | 2.5                |
| Trossen Biarm        | Bi-manual  | Joint        | 50                     | 4.3                |
| UR5 single           | Single arm | Joint        | 20                     | 10.3               |
| UR5 biarm            | Bi-manual  | Joint        | 20                     | 2.4                |
| ARX slate mobile     | Mobile     | Joint        | 50                     | 2.5                |
| ARX EE               | Bi-manual  | EE           | 50                     | 3.6                |
| AgileX EE            | Bi-manual  | EE           | 50                     | 0.9                |
| Fibocom EE           | Mobile     | EE           | 50                     | 1.4                |
| Franka FR3 EE        | Single arm | EE           | 20                     | 1.9                |
| Mobile Trossen EE    | Mobile     | EE           | 50                     | 1.2                |
| Trossen Biarm EE     | Bi-manual  | EE           | 50                     | 2.1                |
| UR5 single EE        | Single arm | EE           | 20                     | 5.2                |
| UR5 biarm EE         | Bi-manual  | EE           | 20                     | 1.2                |
| ARX slate mobile EE  | Mobile     | EE           | 50                     | 1.2                |
| ARX Cam              | Bi-manual  | CamFrame     | 50                     | 3.6                |
| AgileX Cam           | Bi-manual  | CamFrame     | 50                     | 0.9                |
| Fibocom Cam          | Mobile     | CamFrame     | 50                     | 1.4                |
| Franka FR3 Cam       | Single arm | CamFrame     | 20                     | 1.9                |
| Mobile Trossen Cam   | Mobile     | CamFrame     | 50                     | 1.2                |
| Trossen Biarm Cam    | Bi-manual  | CamFrame     | 50                     | 2.1                |
| UR5 single Cam       | Single arm | CamFrame     | 20                     | 5.2                |
| UR5 biarm Cam        | Bi-manual  | CamFrame     | 20                     | 1.2                |
| ARX slate mobile Cam | Mobile     | CamFrame     | 50                     | 1.2                |
| ALOHA [69]           | Bi-manual  | Joint        | 50                     | 5.0                |
| DROID [38]           | Single arm | Joint        | 15                     | 11.2               |
| Bridge V2 [60]       | Single arm | EE           | 5                      | 5.0                |
| OpenX [52]           | Single arm | EE           | mixed                  | 3.8                |

# 实验评估

| Dataset    | Action Dimension | Control Frequency | Avg. Token |      | Compression |
|------------|------------------|-------------------|------------|------|-------------|
|            |                  |                   | Naive      | FAST |             |
| BridgeV2   | 7                | 5 Hz              | 35         | 20   | 1.75        |
| DROID      | 7                | 15 Hz             | 105        | 29   | 3.6         |
| Bussing    | 7                | 20 Hz             | 140        | 28   | 5.0         |
| Shirt Fold | 14               | 50 Hz             | 700        | 53   | 13.2        |


在不同数据集上，FAST在1s时间间隔内产生的token数量，以及相对朴素方法的压缩率



在不同数据集上不同Tokenizer的任务成功率


# 实验评估

- FAST方法的压缩倍率在 2-13 之间（根据控制频率）
- 经过分词后能够使训练收敛速度提升5x
- 随着动作表达效率的提升任务成功率也同时提升
- BPE能够很好的压缩信息表达
- 推理速度上依然落后diffusion类策略




FAST+ 对比简单Tokenizer的压缩倍率

## Ablation Studies



对模型训练收敛速度的提升



BPE 模块的重要性

# 总结与讨论

## FAST: Efficient Action Tokenization for VLA Models

文章提出了一种应用于机器人领域的新型Action Tokenizer，在高频控制的场景中对Action Tokens进行高效压缩，提高模型性能与训练效率。

### 1. 能不能迁移？

背景中能够应用DCT的**重要前提**是动作平滑，信号集中在低频部分，高频呈现稀疏特性。在其他问题中，只要满足该条件就可以将信号转换到频率域上进行处理压缩。

### 2. 能不能进一步提高？

虽然FAST大大压缩了动作表达，提高了自回归方法的与运行效率，但是在推理中速度仍然落后于diffusion方法。对推理速度进行提高仍然是一个可进行的课题，可以从LLM中寻找优化推理加速的方法将其应用到VLA模型中。

### 3. 能不能泛化？

FAST+已经创建了一个优越的通用机器人动作Tokenizer。后续的泛化可能要寻找更多角度，适应不同机器人工作环境等。

# 感谢聆听

Q&A

徐翎

4.7