



Activation-Informed Merging of Large Language Models

NeurIPS 2025

Amin Heyrani Nobari, Kaveh Alim,
Ali ArjomandBigdeli, Akash Srivastava,
Faez Ahmed, Navid Azizan

汇报人：孙敏鑫

2026.5.11

目录

- **研究背景**
- **相关工作**
- **设计实现**
- **实验测试**
- **后续思考**

作者介绍

研究方向:

机械设计自动化、机器学习、生成式工程设计

近期论文:

- **CAD代码生成与程序合成:** Cad-coder: An open-source vision-language model for computer-aided design code generation
- **图像到CAD程序合成:** GIFT: Bootstrapping Image-to-CAD Program Synthesis via Geometric Feedback
- **大语言模型融合:** Activation-informed merging of large language models
- **结构拓扑优化基础模型:** Optimize Any Topology: A Foundation Model for Shape-and Resolution-Free Structural Topology Optimization



Amin Heyrani Nobari

Ph.D. MIT

LLMs in a Fine-Tuning Paradigm



Pre-train

在海量通用数据上进行预训练，获得基础知识、语言理解与生成能力。

输出： Base Model



Fine-tuning

基于特定任务或领域数据进行微调，以较低成本获得不同领域的专家模型。

输出： Task-specific Expert




Refinement

通过偏好对齐或强化学习等进一步优化，增强指令跟随、推理表现与实用性。


输出： Refined Model

Cheap Fine-Tuning Leads To Many Experts




低成本微调催生了大量专家模型，但这些能力仍彼此孤立；如何以较低额外成本将它们有效整合到一个统一模型中，成为一个自然且重要的问题。

Why Choose Model Merging?




模型合并是直接聚合若干训练良好的专家模型的**参数**，从而融合它们的知识，因此具有很高的效率且成本较低。这些特性使得模型合并成为一种对于知识整合特别有吸引力的范式。

Model Merging



- 模型合并旨在将多个由同一 base model 微调得到的 expert models 的参数更新进行整合，得到一个统一的 merged model。
- 相比为每个任务单独保存和部署一个专家模型，模型合并能够以更低的存储与推理成本整合多种能力，因此成为大语言模型能力组合中的一种高效范式。
- 但在实际合并过程中，不同 expert 的参数更新往往会相互干扰，如何在吸收专家能力的同时尽量保留 base model 的通用能力，是这一方向的核心问题。

Model Merging



Task Arithmetic 将微调过程看作从 base model 到 expert model 的参数偏移，即 task vector。通过对不同 task vector 进行加减组合，可以实现能力叠加、能力抵消以及任务类比。


研究背景

现有LLM merging方法大多只在参数空间中进行操作，缺乏对权重重要性的细粒度区分。

在融合多个expert时，关键参数可能被过度修改，从而引发能力干扰，并损伤base model的通用能力。



AIM将activation space引入merging，用base model的激活来识别“哪些权重不该被大改”，从而在吸收expert能力的同时减轻灾难性遗忘。



相关工作

1. LLM Model Merging

模型合并旨在将多个由同一 base model 微调得到的专家模型整合为一个统一模型，以降低存储与推理成本，并融合不同任务专长。代表性方法包括 Model Soup、SLERP、Task Arithmetic、TIES、DARE、WIDEN等

2. Continual Learning Perspective

本文将模型合并视为一个类似持续学习的问题：多个 expert 在增强特定能力的同时，也可能使模型进一步偏离原始 base model，导致通用能力退化。这种现象与灾难性遗忘相似，因此持续学习中“保护关键参数”的思想为本文提供了重要启发。

3. Activation-Aware Compression

已有研究表明，激活信息能够用于识别更重要的权重，从而更有效地进行量化或剪枝。仅保护少量显著权重就能显著降低量化误差，这为本文将 activation space 引入模型合并提供了直接启发。

4. Position of This Work

现有 merging 方法大多主要工作在 weight space，而较少利用 activation space 来判断哪些 base 权重更应被保护。AIM 的定位不是替代已有 merging 方法，而是作为一个通用补充模块，在原始合并更新的基础上进一步调节，以提升合并的稳定性与鲁棒性。

Activation-Informed Merging of Large Language Models

- **Problem: Robust LLM Merging via Activation Information**
 - **Input:** 多个由同一base model微调得到的expert models, 以及一小份校准语料。
 - **Output:** 一个在多任务上更平衡、同时尽量保留base model通用能力的merged model。
 - **Significance:** 多数merging方法主要工作在参数空间, 容易在吸收 expert 能力时损伤base的关键能力。
- **SOTA & Limitations:**
 - **L1:** 现有LLM merging方法 (如 TA、TIES、DARE、WIDEN 等) 大多直接在参数空间中融合参数更新, 对激活空间的利用不足。
 - **L2:** 多个expert的合并可能使模型进一步偏离共享的pre-trained base, 从而引发类似catastrophic forgetting的问题, 导致通用能力退化。
- **Opportunity:**
 - **O1:** 激活值大小能够反映输入通道的重要性; 高激活通道对应的权重扰动更容易影响输出, 因此可作为识别关键权重的重要依据。
 - **O2:** AIM 不需要替代现有模型合并方法, 而是可以作为一个补充模块, 在原始合并更新的基础上做进一步调节。
- **Challenges:**
 - **C1:** 如何把校准语料中统计得到的激活值, 转化为一个可直接作用于参数更新的saliency map。
 - **C2:** 如何设计一个与底层merging algorithm无关、能够适配不同weight-space merging方法的统一调节公式。
- **Model:**
 - **M1:** 使用与具体任务无关的校准语料输入base model, 统计各输入通道的平均激活值大小, 并据此构造归一化的saliency map
 - **M2:** 通过对任意merging方法得到的参数更新做activation-informed relaxation: 高重要性位置更新更小, 从而保护base model关键能力。
- **3 Contributions:**
 - **Conceptually:** 提出从activation space而不仅是weight space来看待LLM merging, 并将其与continual learning中的参数保护视角联系起来。
 - **Technically,** 设计了一种可适配多种模型合并方法的自适应松弛机制, 利用由激活信息构造的saliency map对合并更新进行调节。
 - **Experimentally,** 在多种merging方法、多个benchmark, 以及不同架构与模态上验证了AIM的有效性; AIM在多数场景中都能提升性能。

为什么激活信息可以指导模型合并



- 在线性层中，权重扰动引起的输出变化满足： $\Delta y = x\delta W$
- 某一输入通道的激活越大，该通道对应权重变化对输出的放大效应越明显。
- 因而，激活值可以用来衡量不同权重的重要性，并指导模型合并时哪些位置应少改动。

核心思想：通过激活信息识别 base model 中更关键的权重，在融合 expert 能力的同时减少对原有能力的破坏。

统计各层输入通道的 activation magnitude

将一小份calibration data喂给base model，让模型正常前向传播。记录它的输入激活，也就是进入这一层的向量 x 。

对每一层，会得到很多token的输入向量 $x^{(t)}$ ，然后对每个通道的平均值做平均，得到一个代表性向量： $x \in \mathbb{R}^{1 \times N}$

将 activation 变成 saliency map

1. 先对向量取绝对值
2. 构造成对角矩阵
3. 再做归一化，得到 A_{pre}

例: $[0.2, 0.9, 0.0, 0.4]$ $\text{diag}(|x|) = \begin{bmatrix} 0.2 & 0 & 0 & 0 \\ 0 & 0.9 & 0 & 0 \\ 0 & 0 & 0.0 & 0 \\ 0 & 0 & 0 & 0.4 \end{bmatrix}$ $A_{pre} = \begin{bmatrix} 0.22 & 0 & 0 & 0 \\ 0 & 1.0 & 0 & 0 \\ 0 & 0 & 0 & 0 \\ 0 & 0 & 0 & 0.44 \end{bmatrix}$

调节 merged update

$$\theta_{AIM} = \theta_{pre} + (1 - A_{pre}(1 - \omega))\Delta_{merged}$$

θ_{pre} : base的参数

$\Delta_{merged} = \sum_{i=1}^N \lambda_i \Delta_i$: 原始 merging 方法得到的参数更新



ω : 控制保护强度, 平衡 base preservation 与 expert integration

对于更重要的位置, AIM 会减小更新幅度; 对于不那么重要的位置, AIM 会更大程度保留原始更新。这不是能不能改的二值约束, 而是一种连续的、可调的更新松弛机制。

设计实现

Feed Calibration Corpus into θ_{pre} to get average activation magnitudes $|A_{pre}|$.

Use $|A_{pre}|$ to determine the relaxation/scaling factor for the delta.



Original Δ_{merged}

.1	-.5	.2	.1	-.1
.3	.8	-.3	-.2	.1
-.2	-.1	.1	.4	.1
.1	.3	-.1	-.1	.2



Relaxed $\hat{\Delta}_{merged} = S \cdot \Delta_{merged}$

.08	-.4	.16	.08	-.08
.03	.08	-.03	-.02	.01
-.2	-.1	.1	.4	.1
.06	.18	-.06	-.06	.12



$$\theta_{AIM} = \theta_{pre} + (1 - |A_{pre}|)\Delta_{merged}$$

sensitivity-based AIM

如果某个权重被扰动一点，输出会有多敏感



用梯度的绝对值来衡量

权重的sensitivity: $g_{\theta}[j] = \left| \frac{\partial f}{\partial \theta[j]} \right|$

f_{θ} : 参数为 θ 的模型

$\theta[j]$: 其中某一个权重参数

$$\theta_{AIM,G} = \theta_{pre} + (1 - G_{pre}(1 - \omega))\Delta_{merged}$$

$$G_{pre} = \left| \frac{\partial L}{\partial \theta} \right|$$

- **activation-based AIM**

forward 一遍 calibration data

用“活跃程度”估计重要性

便宜、简单、易实现

- **sensitivity-based AIM**

backward 计算每个参数梯度

用“梯度大小”估计重要性

更直接、更理论化，但更贵




Figure 1: Overview of the proposed activation-informed merging (AIM) in LLMs.


1、通用性

不管底层是 Task Arithmetic、TIES、DARE、WIDEN 还是其他 merge 算法。只要它最终能给你一个相对 base 的 merged update, AIM 都能适用。

2、开销小

它不需要重新训练,也不需要梯度优化。只需要跑一遍 calibration set、统计 activation 再做一次参数后处理。

实验测试




HV Gain

反映的是整体折中提升，而非单一 benchmark 的局部增益。值越大，说明 merged model 对 base + experts 的综合性能提升越明显。

AIM对calibration set的规模不敏感，哪怕只用很少的校准数据，也能带来稳定而显著的提升。

实验测试



- 不同merging方法对 ω 的敏感性不同
- 适度relaxation往往能显著提升 HV Gain
- 过强relaxation可能导致部分方法退化（如 TIES）
- $\omega=0.4 \sim 0.6$ 是较稳妥的经验区间

实验测试

Method	Model(s)	AIM	HumanEval	MBPP	MMLU	MATH	GSM8K	IFEval	HV Gain
Base Models									
-	Base	-	17.07	27.80	52.18	0.70	4.20	25.10	-
-	Code	-	17.07	31.60	52.91	6.00	24.10	26.25	-
-	Instruction Tuned	-	26.83	34.80	53.41	7.50	43.40	35.67	-
-	Math	-	15.24	27.60	51.89	13.10	59.10	21.58	-
Merged Models									
DARE Task Arithmetic	Code + Instruction Tuned	No	26.83	34.40	53.53	8.40	45.80	33.42	0.27
		Yes	29.27 (+9.09%)	36.00 (+4.65%)	54.18 (+1.21%)	8.30 (-1.19%)	46.20 (+0.87%)	32.00 (-4.25%)	0.28 (+2.49%)
	Code + Math	No	16.46	28.60	51.96	15.10	64.70	22.02	0.23
		Yes	15.85 (-3.71%)	29.60 (+3.50%)	52.50 (+1.04%)	14.80 (-1.99%)	64.10 (-0.93%)	21.91 (-0.50%)	0.23 (-1.65%)
	Instruction Tuned + Math	No	5.49	19.00	51.08	9.80	54.30	32.35	0.18
		Yes	12.20 (+122.22%)	28.20 (+48.42%)	52.72 (+3.21%)	12.90 (+31.63%)	62.20 (+14.55%)	31.96 (-1.21%)	0.26 (+40.71%)
DARE Ties	Code + Instruction Tuned + Math	No	11.59	19.60	50.89	9.10	49.70	33.20	0.16
		Yes	15.85 (+36.76%)	27.00 (+37.76%)	52.59 (+3.34%)	12.20 (+34.07%)	60.70 (+22.13%)	33.59 (+1.17%)	0.23 (+40.59%)
	Code + Instruction Tuned	No	30.49	35.20	53.40	8.60	46.20	33.28	0.28
		Yes	30.49	36.80 (+4.55%)	54.02 (+1.16%)	8.60	47.20 (+2.16%)	33.16 (-0.36%)	0.29 (+1.63%)
	Code + Math	No	17.07	27.40	51.92	14.90	63.60	22.53	0.23
		Yes	17.68 (+3.57%)	29.00 (+5.84%)	52.61 (+1.33%)	15.20 (+2.01%)	63.90 (+0.47%)	21.10 (-6.35%)	0.24 (+4.00%)
Task Arithmetic	Instruction Tuned + Math	No	8.54	23.80	51.39	9.20	54.10	33.89	0.20
		Yes	15.85 (+85.60%)	30.20 (+26.89%)	52.89 (+2.92%)	11.60 (+26.09%)	57.80 (+6.84%)	35.63 (+5.13%)	0.26 (+31.22%)
	Code + Instruction Tuned + Math	No	13.41	21.20	51.15	8.70	51.50	35.75	0.17
		Yes	19.51 (+45.49%)	28.60 (+34.91%)	52.63 (+2.89%)	11.60 (+33.33%)	57.00 (+10.68%)	36.20 (+1.26%)	0.24 (+41.28%)
	Code + Instruction Tuned	No	29.27	33.80	53.44	8.60	47.10	31.60	0.28
		Yes	29.88 (+2.08%)	35.80 (+5.92%)	54.12 (+1.27%)	7.80 (-9.30%)	46.60 (-1.06%)	32.01 (+1.30%)	0.28 (+0.61%)
Ties Merging	Code + Math	No	18.29	28.60	52.10	15.00	64.70	21.92	0.24
		Yes	17.68 (-3.34%)	29.20 (+2.10%)	52.52 (+0.81%)	14.60 (-2.67%)	64.50 (-0.31%)	21.54 (-1.73%)	0.24 (-2.65%)
	Instruction Tuned + Math	No	4.27	20.20	51.50	10.00	54.20	31.31	0.18
		Yes	8.54 (+100.00%)	26.40 (+30.69%)	52.83 (+2.58%)	12.80 (+28.00%)	61.30 (+13.10%)	32.62 (+4.18%)	0.24 (+34.52%)
	Code + Instruction Tuned + Math	No	11.59	19.60	51.20	9.00	52.70	32.87	0.16
		Yes	15.24 (+31.49%)	27.40 (+39.80%)	52.63 (+2.79%)	12.00 (+33.33%)	58.10 (+10.25%)	33.91 (+3.16%)	0.22 (+31.97%)
WIDEN	Code + Instruction Tuned	No	16.46	23.60	52.70	2.70	5.40	24.48	0.00
		Yes	15.24 (-7.41%)	24.20 (+2.54%)	53.15 (+0.85%)	2.60 (-3.70%)	5.20 (-3.70%)	22.87 (-6.58%)	0.05 (+inf%)
	Code + Math	No	15.85	26.80	51.86	14.30	62.60	21.63	0.20
		Yes	15.85	28.60 (+6.72%)	52.29 (+0.83%)	15.30 (+6.99%)	63.80 (+1.92%)	22.64 (+4.67%)	0.23 (+13.55%)
	Instruction Tuned + Math	No	28.05	34.60	54.45	8.70	44.70	34.04	0.23
		Yes	27.44 (-2.17%)	35.00 (+1.16%)	54.74 (+0.53%)	9.30 (+6.90%)	46.10 (+3.13%)	34.51 (+1.38%)	0.25 (+6.38%)
	Code + Instruction Tuned + Math	No	21.34	29.20	53.97	6.30	29.20	26.95	0.11
		Yes	20.73 (-2.86%)	29.20	54.46 (+0.91%)	5.70 (-9.52%)	23.70 (-18.84%)	25.98 (-3.60%)	0.11 (+4.33%)
	Code + Instruction Tuned	No	26.22	35.60	54.90	8.30	45.00	30.42	0.27
		Yes	25.61 (-2.33%)	34.60 (-2.81%)	54.97 (+0.13%)	8.20 (-1.20%)	44.10 (-2.00%)	31.60 (+3.88%)	0.26 (-0.93%)
	Code + Math	No	17.07	29.40	53.35	14.20	64.40	24.02	0.24
		Yes	17.07	29.60 (+0.68%)	53.36 (+0.02%)	14.30 (+0.70%)	62.20 (-3.42%)	23.95 (-0.29%)	0.24 (-1.22%)
	Instruction Tuned + Math	No	24.39	30.40	54.20	14.60	66.00	30.82	0.30
		Yes	23.78 (-2.50%)	32.00 (+5.26%)	54.69 (+0.90%)	15.10 (+3.42%)	68.20 (+3.33%)	31.23 (+1.33%)	0.31 (+2.54%)
	Code + Instruction Tuned + Math	No	25.00	33.20	54.58	13.50	64.20	31.44	0.29
		Yes	26.83 (+7.32%)	32.80 (-1.20%)	54.98 (+0.73%)	14.40 (+6.67%)	64.00 (-0.31%)	32.82 (+4.39%)	0.30 (+4.70%)

实验测试

Table 2: AIM generalizes across architectures and modalities. We evaluated merging two Qwen 2.5-VL-7B experts (Video-R1 and CADCoder, with an instruction-tuned base). AIM consistently improves performance across benchmarks, increasing the multi-task Hypervolume Gain in all cases.

Method	AIM	IFEval	MMLU	Video VSI	Video MMMU	CAD test100	CAD R400	HV Gain
Base Models								
Instruct	-	0.68	0.67	0.21	0.47	0.04	0.05	-
Video-R1	-	0.64	0.61	0.38	0.49	0.00	0.03	-
CADCoder	-	0.27	0.66	0.00	0.00	0.61	0.32	-
Merged Models								
TIES	No	0.57	0.68	0.23	0.41	0.61	0.32	0.44
	Yes	0.58 (+1.75%)	0.68	0.23	0.45 (+9.76%)	0.65 (+6.56%)	0.32	0.45 (+2.26%)
DARE	No	0.54	0.67	0.25	0.42	0.54	0.32	0.43
	Yes	0.56 (+3.70%)	0.67	0.26 (+4.00%)	0.45 (+7.14%)	0.55 (+1.85%)	0.32	0.44 (+3.47%)
DARE Task Arithmetic	No	0.25	0.64	0.25	0.43	0.54	0.33	0.38
	Yes	0.56 (+124.00%)	0.67 (+4.69%)	0.26 (+4.00%)	0.45 (+4.65%)	0.54	0.34 (+3.03%)	0.45 (+17.42%)
WIDEN	No	0.35	0.66	0.08	0.26	0.61	0.33	0.32
	Yes	0.35	0.66	0.14 (+75.00%)	0.32 (+23.08%)	0.64 (+4.92%)	0.33	0.36 (+13.24%)

验证 AIM 泛化性的实验，AIM 不只对Llama-2文本模型有用，也不只对纯文本任务有用

后续思考

- 文章有什么问题？

1. 只利用了 base model 的激活信息

AIM 当前只使用pre-trained/base model的activation来构造saliency map，而没有显式利用各个expert model的activation。

2. Relaxation 机制仍较为简单

AIM 使用的是基于单一超参数 ω 的线性缩放机制。

但论文的消融实验表明，不同 merging 方法对 ω 的响应并不一致，有些方法在更强保护下继续受益，而有些方法则会退化。

后续思考

- **这篇 paper 的工作能否进一步深入？**

- 能否做 layer-wise / module-wise adaptive ω 。对于不同层不同 ω 、不同模块不同 ω 甚至不同 expert 对同一层不同 ω 。
- 能否加入 expert model 的 activation，更加有选择地吸收 expert 能力。
- 如果 AIM 的收益来自“少动 base 的关键位置”，那是否说明现有 merging 方法的真正短板不是不会平均参数，而是不知道哪些位置根本不该碰？

- **这篇 paper 能不能泛化？**

- 在多 LoRA 融合场景中，利用 activation-informed 机制精细控制哪些更新应优先被保护。
- 模型能力可能从模型微调整个走向 task vector 级别的模块化协作与组合。



Thanks

汇报人：孙敏鑫

2026.5.11