

EmbodiSkill: Skill-Aware Reflection for Self-Evolving Embodied Agents

arXiv 2026

1 Nanjing University, 2 Huazhong University of Science and Technology, 3 University of Science and Technology of China,

4 Microsoft Research, **5 Institute for AI Industry Research (AIR), Tsinghua University**



汇报人：宋青阳

2026年6月15日

Contents

- **Background**
- Challenges
- Design
- Evaluation
- Thinking


Background

Motivation → 具身 Agent 为什么需要 Skills?

1. 具身任务不是一次性问答，而是连续执行任务
2. 很多任务存在可复用的程序性规律，因此需要长期积累的 Skills

Limitations → 具身任务需要什么样的“经验”

1. **No Skill**: 直接执行，探索效率低
2. **Static Skill**: 固定技能，不能适应新情况
3. **Memory-based 方法**: 只是“记经历”，不是“形成技能”
4. **已有 skill self-evolution 方法**: 不是针对具身这种物理场景；且更新粒度太粗




Contents

- Background
- **Challenges**
- Design
- Evaluation
- Thinking

Challenges

为什么 embodied setting 下 skill evolution 更难?

答：在具身环境中，trajectory outcome 是多因素耦合的。失败轨迹不能简单归因于 skill 错误。



具身场景下的核心挑战

区分

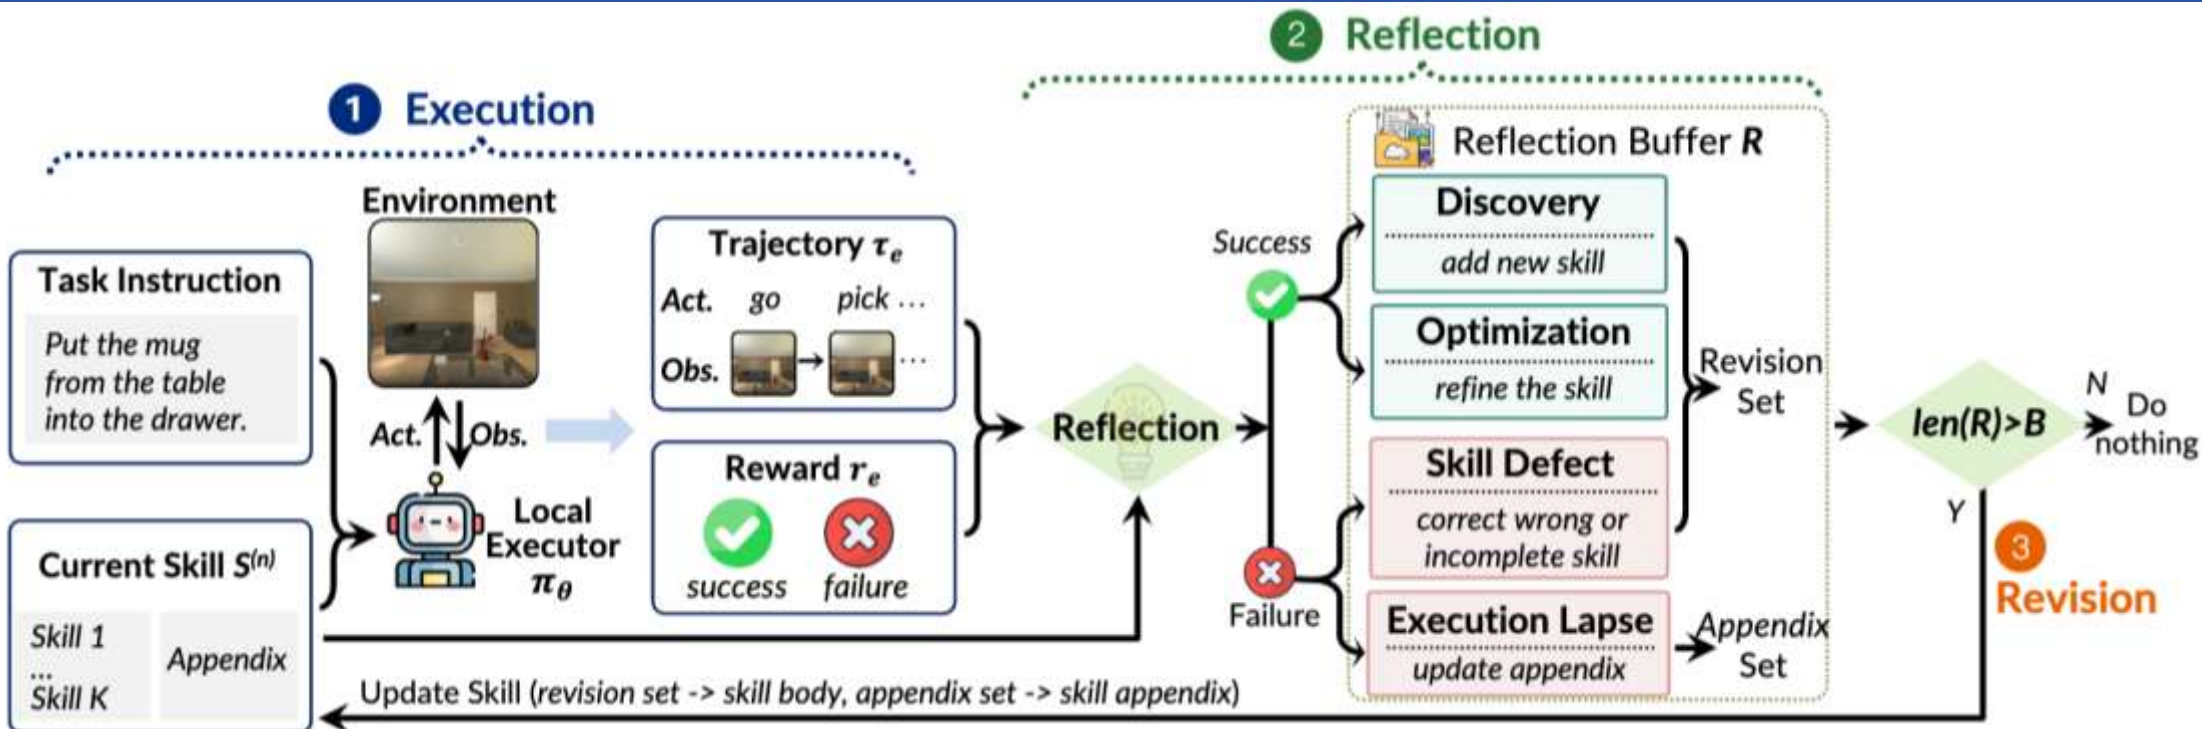
skill should be **changed**

skill should be **preserved** but **emphasized**

Contents

- Background
- Challenges
- **Design**
- Evaluation
- Thinking

Design—Overview



当前 Skill 指导执行 → 执行轨迹触发反思 → 反思结果定向修改 Skill → 新 Skill 继续指导后续任务

Execution

Reflection

Revision

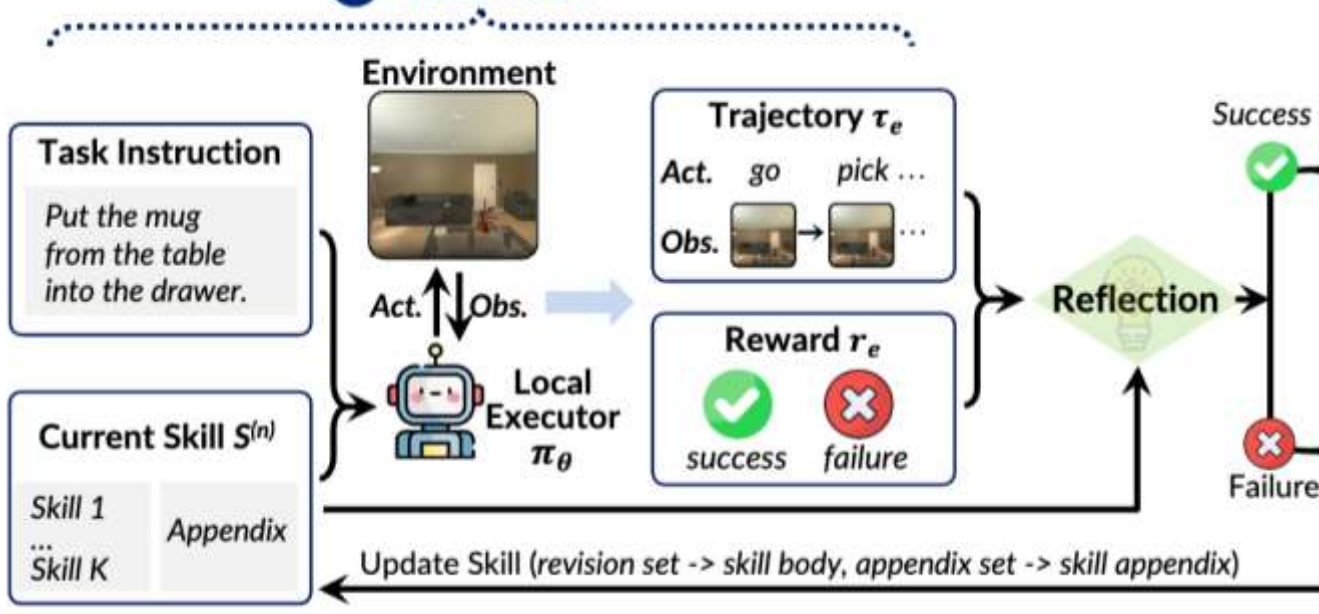
Execution

Train Free

能力提升完全依赖外部 skill 的演化

Design

1 Execution



1. 执行

➤ **Step1:** 输入 **Task Instruction** 和 **Current Skill**

➤ **Step2:** **Local Executor** 与环境交互

固定的 executor 根据当前 observation、历史状态和 skill 选择下一步动作，例如 go、open、pick、put。

➤ **Step3:** 形成 **Trajectory**

每一步的 observation 和 action 被记录下来，形成完整轨迹：

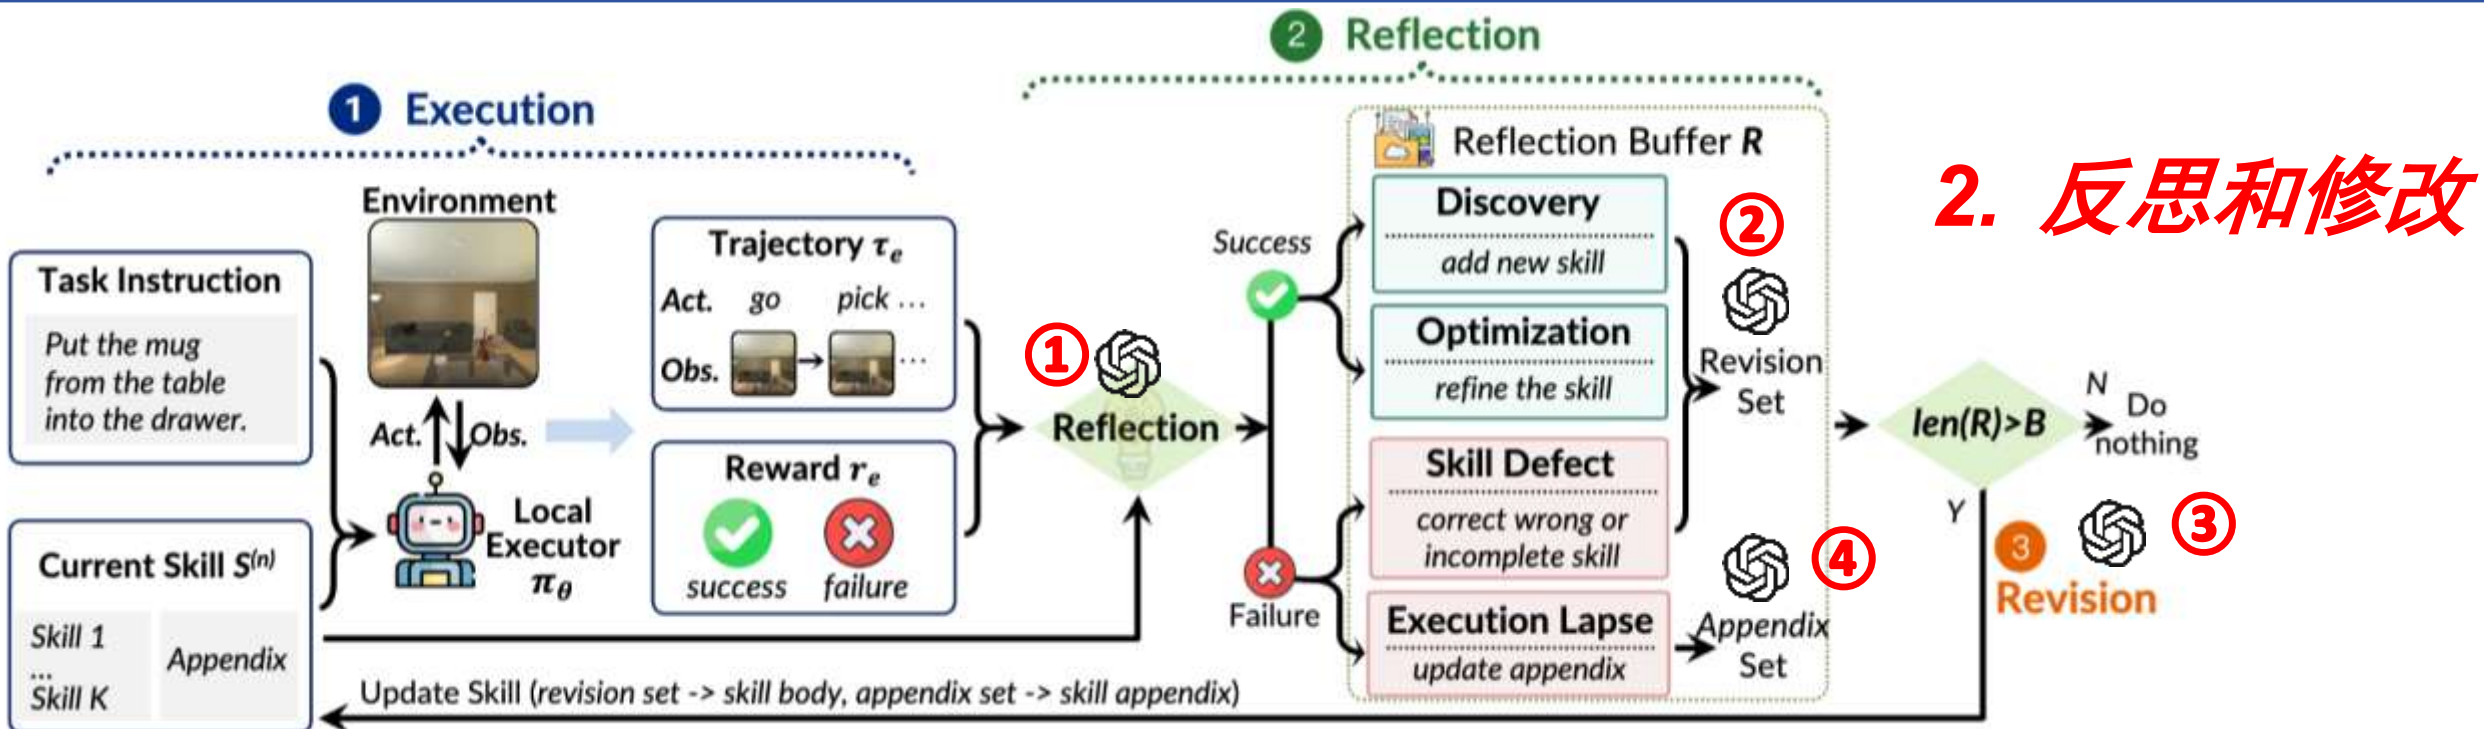
$$\tau = (I, o_1, a_1, \dots, o_T, a_T, r)$$

➤ **Step4:** 输出 **Reward**，为后续反思提供依据

任务结束后得到 success / failure 信号 r 。

这一步 不更新 skill，只是把 trajectory 和 reward 交给下一阶段 Reflection

Design



2. 反思和修改

➤ Step1: Skill-aware Reflection 技能反思

目的：分析出这次错误的原因，将它们分类为四类。

Input：原始轨迹 τ 、当前 Skill $S(n)$

Output：Reflection record

ep: type: Discovery / Optimization / Skill Defect / Execution Lapse
evidence: 轨迹证据
target skill: 对应的 skill 内容
directive: 修改建议

➤ Step2: Consolidate Revisions 整合修订

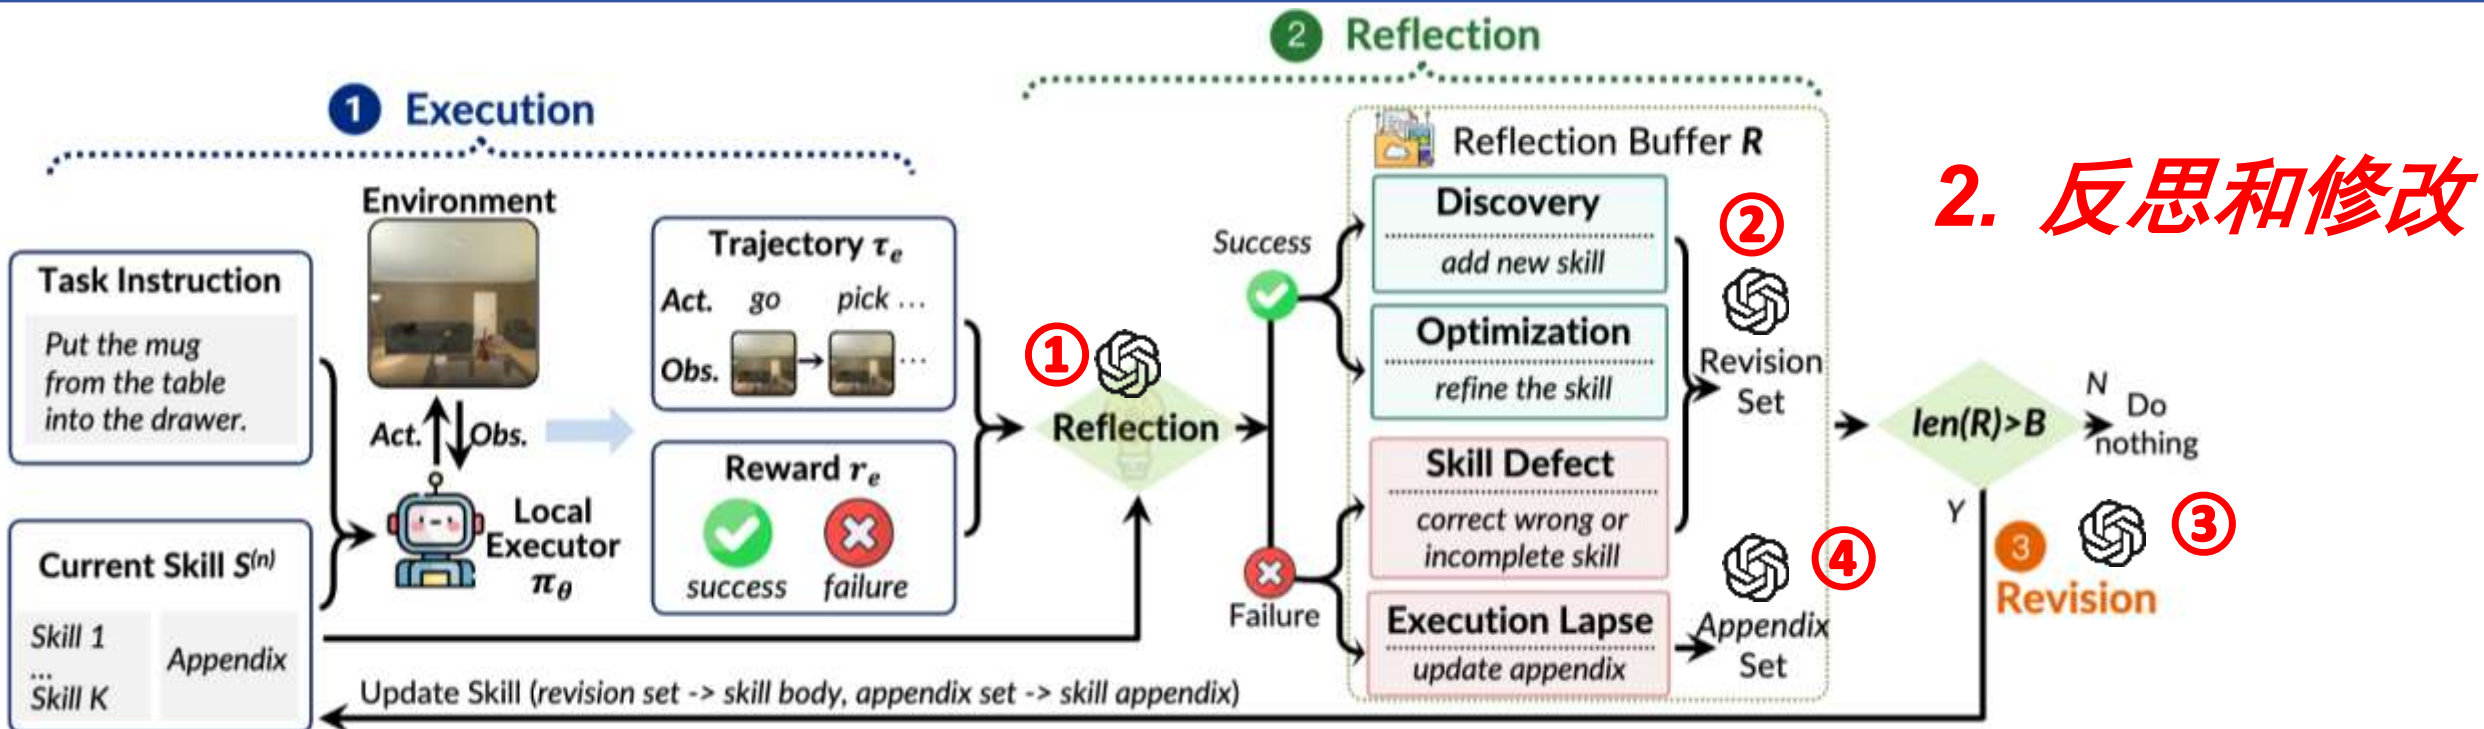
目的：整合前三类 reflection，形成一个综合性修改建议

Input：前三类的 Reflection record、当前 Skill body

Output：整合后的 revision signals

去重
合并相似建议
解决冲突
把针对同一 skill 的修改合并起来
丢弃不可靠的修改

Design



2. 反思和修改

➤ Step3: Revise Skill Body 只修主体

目的：根据整合后的 revision signals 修改 skill body。

Input：当前 Skill Body、整合后的 revision signals

Output：新的 Skill Body

ep:

Discovery	→ 添加新 skill
Optimization	→ 优化已有 skill
Skill Defect	→ 修正错误或不完整 skill

➤ Step4: Update Skill Appendix 只修附录

目的：如果是执行错误，则不修改 skill body，而是更新 appendix。

Input：更新后的 Skill Body、旧的 Skill Appendix 以及针对执行错误的 Reflection record

Output：新的 Skill Appendix

Contents

- Background
- Challenges
- Design
- **Evaluation**
- Thinking

Evaluation

A. Experiments: What does EmbodiSkill aim to verify?

1. EmbodiSkill 是否比 No skill和 memory based 方法更强?
2. 提升是不是来自 skill-aware reflection, 而不是单纯因为用了 skill?
3. skill 在多轮 revision 中是否真的逐步变好?

Evaluation

B. Experimental Setup

Benchmarks

- ALFWorld: 文本交互式家居任务, 如找物体、加热、冷却、清洁、放置
- EmbodiedBench-Habitat: 3D 环境中的视觉物体交互
- EmbodiedBench-Navigation: 视觉导航任务

评价指标都是: **Task Success Rate**

Models setup

Executor model: 真正执行任务的模型

在 ALFWorld 上, 作者用了:

- Qwen2.5-14B-Instruct
- Qwen3.5-27B

在 EmbodiedBench 上, 作者用了:

- Qwen3-VL-8B-Instruct
- Qwen3-VL-32B-Instruct

Skill evolution model: 负责反思和修改 skill 的模型, 作者用了:

- GPT-5.2、 Gemini-3-flash

Baselines

第一类: 强闭源模型 (不使用 evolving skill)

- GPT-5.2
- Gemini-3-flash

第二类: Memory-based baselines

- No memory
- Mem0
- G-Memory
- LangMem

Evaluation

C. Results — ALFWorld 纯文本交互任务

Method	Overall	ALFWorld Subtasks					
		Put	Clean	Heat	Cool	Examine	Puttwo
Closed-source direct agents							
GPT-5.2	70.89	87.50	67.74	56.52	76.19	83.33	52.94
Gemini-3-flash	82.09	91.67	83.87	65.22	85.71	83.33	82.35
Executor: Qwen2.5-14B-Instruct							
<i>Memory-based baselines</i>							
No memory	46.27	33.33	51.61	26.09	85.71	72.22	5.88
Mem0	12.69	0	0	4.35	0	88.89	0
G-Memory	67.16	50.00	83.87	69.57	85.71	83.33	17.65
LangMem	36.57	12.50	32.26	26.09	71.43	83.33	0.00
<i>EmbodiSkill (Ours)</i>							
EmbodiSkill w/ GPT-5.2	86.57	91.67	96.77	73.91	95.24	83.33	70.59
EmbodiSkill w/ Gemini-3-flash	85.82	79.17	93.55	73.91	90.48	100.00	76.47
Executor: Qwen3.5-27B							
<i>Memory-based baselines</i>							
No memory	61.19	66.67	51.61	65.22	76.19	72.22	35.29
Mem0	64.18	62.50	61.29	56.52	85.71	72.22	47.06
G-Memory	74.62	62.50	77.42	82.61	85.71	83.33	52.94
LangMem	62.69	62.50	61.29	52.17	76.19	72.22	52.94
<i>EmbodiSkill (Ours)</i>							
EmbodiSkill w/ GPT-5.2	93.28	95.83	96.77	73.91	95.24	100.00	100.00
EmbodiSkill w/ Gemini-3-flash	<u>87.31</u>	95.83	93.55	69.57	95.24	83.33	82.35

总结

1. 第一，EmbodiSkill 用14B/27B 的本地模型，效果远超直接用 GPT-5.2 做 agent
2. 第二，EmbodiSkill 明显超过最强 memory-based baseline G-Memory。也就是说，把训练轨迹转化成 evolving skill，比单纯检索 trajectory-level memory 更有效。

Evaluation

C. Results — EmbodiedBench 视觉交互任务

Method	Avg.	EB-Habitat						Avg.	EB-Navigation				
		Base	Com.	Comp.	Vis.	Spa.	Long		Base	Com.	Comp.	Vis.	Long
Closed-source direct agents													
GPT-5.2	40.00	80	40	26	44	32	18	57.33	63	72	68	65	18
Gemini-3-flash	46.00	78	42	38	56	32	30	56.00	62	60	55	47	57
Executor: Qwen3-VL-8B-Instruct													
Memory-based baselines													
No memory	24.00	58	20	20	18	18	10	45.00	58	53	62	50	2
Mem0	20.33	60	16	8	16	14	8	46.33	58	57	62	55	0
G-Memory	25.66	58	14	12	34	30	6	37.33	62	43	43	38	0
LangMem	19.67	60	12	8	16	14	8	47.00	60	57	62	57	0
EmbodiSkill (Ours)													
Ours-GPT	45.33	76	46	36	52	38	24	50.33	68	65	62	57	0
Ours-Gemini	41.00	78	34	32	52	34	16	49.00	60	63	67	52	3
Executor: Qwen3-VL-32B-Instruct													
Memory-based baselines													
No memory	34.67	78	26	28	34	28	14	46.33	60	53	60	53	5
Mem0	38.33	84	24	26	42	34	20	52.00	62	60	65	67	7
G-Memory	45.00	92	24	36	50	32	34	50.33	52	53	58	65	23
LangMem	38.33	86	26	28	40	32	18	52.00	62	60	65	67	7
EmbodiSkill (Ours)													
Ours-GPT	50.33	92	46	50	54	34	26	61.33	65	68	73	67	33
Ours-Gemini	52.33	96	44	52	62	36	24	61.33	67	70	70	68	32

总结

- 这说明 EmbodiSkill 不只适用于 ALFWorld 这种文本交互环境，也能迁移到视觉导航和视觉交互任务中。

Evaluation

D. Ablation 基于文本交互任务做消融，没有讨论视觉任务

Executor	Skill Model	Configurations				Δ_{aware}
		No skill	Static Skill	Skill-unaware	EmbodiSkill	
Qwen2.5-14B	GPT-5.2		65.67	70.90	86.57	+15.67
	Gemini-3-flash	46.27	58.95	67.91	85.82	+17.91
Qwen3.5-27B	GPT-5.2		73.13	78.36	93.28	+14.92
	Gemini-3-flash	61.19	79.85	85.82	87.31	+1.49

总结

1. 第一，**skill 本身有用**。从 No skill 的 61.19 提升到 Static Skill 的 73.13，说明即使不更新，只要有 procedural guidance，也能帮助 executor。
2. 第二，**skill evolution 有用**。Skill-unaware evolution 从 73.13 提升到 78.36，说明从轨迹中更新 skill 确实能带来收益。
3. 第三，**skill-aware reflection 是关键**。EmbodiSkill 从 78.36 进一步提升到 93.28，说明不是“随便更新 skill”就够了，而是要判断 trajectory 到底对应 Discovery、Optimization、Skill Defect 还是 Execution Lapse。

Contents

- Background
- Challenges
- Design
- Evaluation
- **Thinking**

Thinking

Conclusion

这篇文章提出 EmbodiSkill，目标是让具身智能体从自己的执行轨迹中不断进化出更好的 skill。它不是训练模型参数，而是让固定 executor 在任务执行后，通过 reflection 更新外部技能，从而提升后续任务表现。

主要贡献：

1. 把 skill self-evolution 引入具身任务中
2. 提出了 skill-aware reflection 机制
3. 区分 Skill Body 和 Skill Appendix

{
Discovery: 发现新技能;
Optimization: 优化已有技能;
Skill Defect: 修正错误或不完整技能;
Execution Lapse: skill 是对的, 但 agent 没执行好。

局限性：

1. 依赖强大的 skill evolution model
2. 方法仍然是 prompt pipeline engineering
3. 没有和更多 embodied skill-learning 方法对比



東南大學
SOUTHEAST UNIVERSITY

Q & A

汇报人：宋青阳

2026年6月15日

δ -mem: Efficient Online Memory for Large Language Models

arXiv 2026

Jingdi Lei[†], Di Zhang[†], Junxian Li, Weida Wang, Kaixuan Fan, Xiang Liu, Qihan Liu, Xiaoteng Ma, Baian Chen, Soujanya Poria



汇报人：宋青阳

2026年6月15日

Author

研究方向：LoRA adapter

从"大模型全参数后训练的廉价平替"

→ "持续学习 Agent 的核心机制"

1. **δ-mem**: 解决“借助 LoRA adapter 思想存 Memory”，参数增加 0.12%，Memory Agent Bench 性能提升 1.31 倍
2. **MinT**: 面向百万级 LoRA 的训练与服务基础设施，模型交接时间缩短 18.3 倍
3. **Macaron-A2UI-model**: 用 LoRA 训练出来的生成式 UI 模型
4. **Scaling of PEFT**: LoRA 的 Scale up / Scale down / Scale out 三大扩展轴

→ **Memory**

→ **LoRA infra**

→ **Model**

→ **Conclusion**



MIND LAB

<https://macaron.im/mindlab>

Contents

- **Background**
- Challenges
- Design
- Evaluation
- Thinking

Background

Motivation → 为什么 LLM 需要长期记忆？

1. 未来的 LLM 不只是语言生成器，而是需要有长期状态的 Agent 系统
2. 这些场景需要积累、更新、复用历史信息
3. 仅靠当前 prompt 已经不够

Limitations → 暴力扩大上下文不是根本解法

1. 扩大 context window, 计算成本高
2. 长上下文不保证模型能有效使用信息
3. 现有 memory 方法存在局限：
 - Textual Memory: 受上下文长度和检索噪声影响
 - Outside-channel Memory: 外部模块融合和对齐复杂
 - Parametric Memory: 参数静态, 难以在线更新

memory problem 不是 long-context problem

memory state:

历史信息到底以什么形式被存下来

memory steering:

存下来的记忆如何影响 LLM 当前的推理和生成



memory state = 文本
memory steering = 拼进输入上下文



memory state = 外部模块里的 latent state / key-value memory
memory steering = 通过检索或外部 reader 路径和 backbone 交互



memory state = 参数
memory steering = 通过参数改变模型计算

Contents

- Background
- **Challenges**
- Design
- Evaluation
- Thinking

Challenges

一般的：Memory mechanism 需要关注什么？

memory state 怎么维护？

memory signal 怎么注入模型？

memory 怎么直接影响 attention？

具体的： δ -mem 需要关注什么？

第一，如何把历史压缩进一个很小的状态？

论文用一个低秩矩阵（如 8×8 ）存 online memory state。

这意味着它不能像 RAG 那样完整保存所有历史，而必须学会压缩有用信号。

第二，如何让状态在线更新？

新 token、新文档、新 interaction 到来后，记忆状态要从： $S_{old} \rightarrow S_{new}$

而不是重新训练模型参数，所以它用 delta-rule learning 写入残差信息。

第三，如何让记忆影响 frozen LLM？

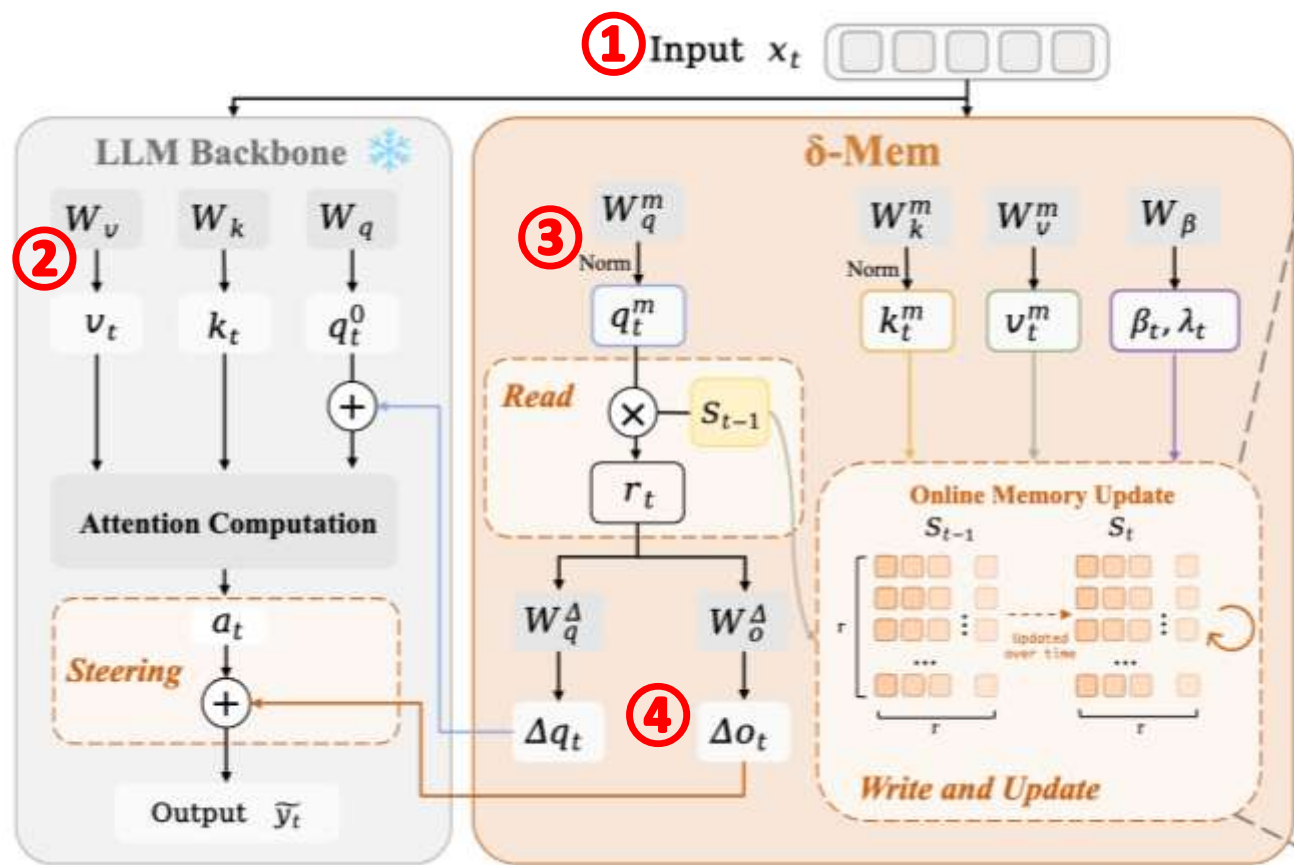
backbone 是冻结的，不能直接改模型参数。

因此 δ -mem 用 memory readout 生成 low-rank correction，去修正 attention 的 query 和 output。

Contents

- Background
- Challenges
- **Design**
- Evaluation
- Thinking

Design



1. 推理

➤ **Step1:** 来自前 n 个 Transformer layer 后的 input

当前 token 的 hidden state x_t 同时进入两部分：

1. 左边进入 frozen LLM backbone，走正常 attention；
2. 中间进入 δ -Mem 模块，用于读写记忆状态

➤ **Step2:** Frozen LLM 做标准 attention

➤ **Step3:** δ -Mem 先读旧记忆

目的：找出历史信息中有没有和当前 token 相关的信息

1. 先生成 memory query；
2. 然后用旧记忆状态 S_{t-1} ，两者相乘得到隐式信号 r_t

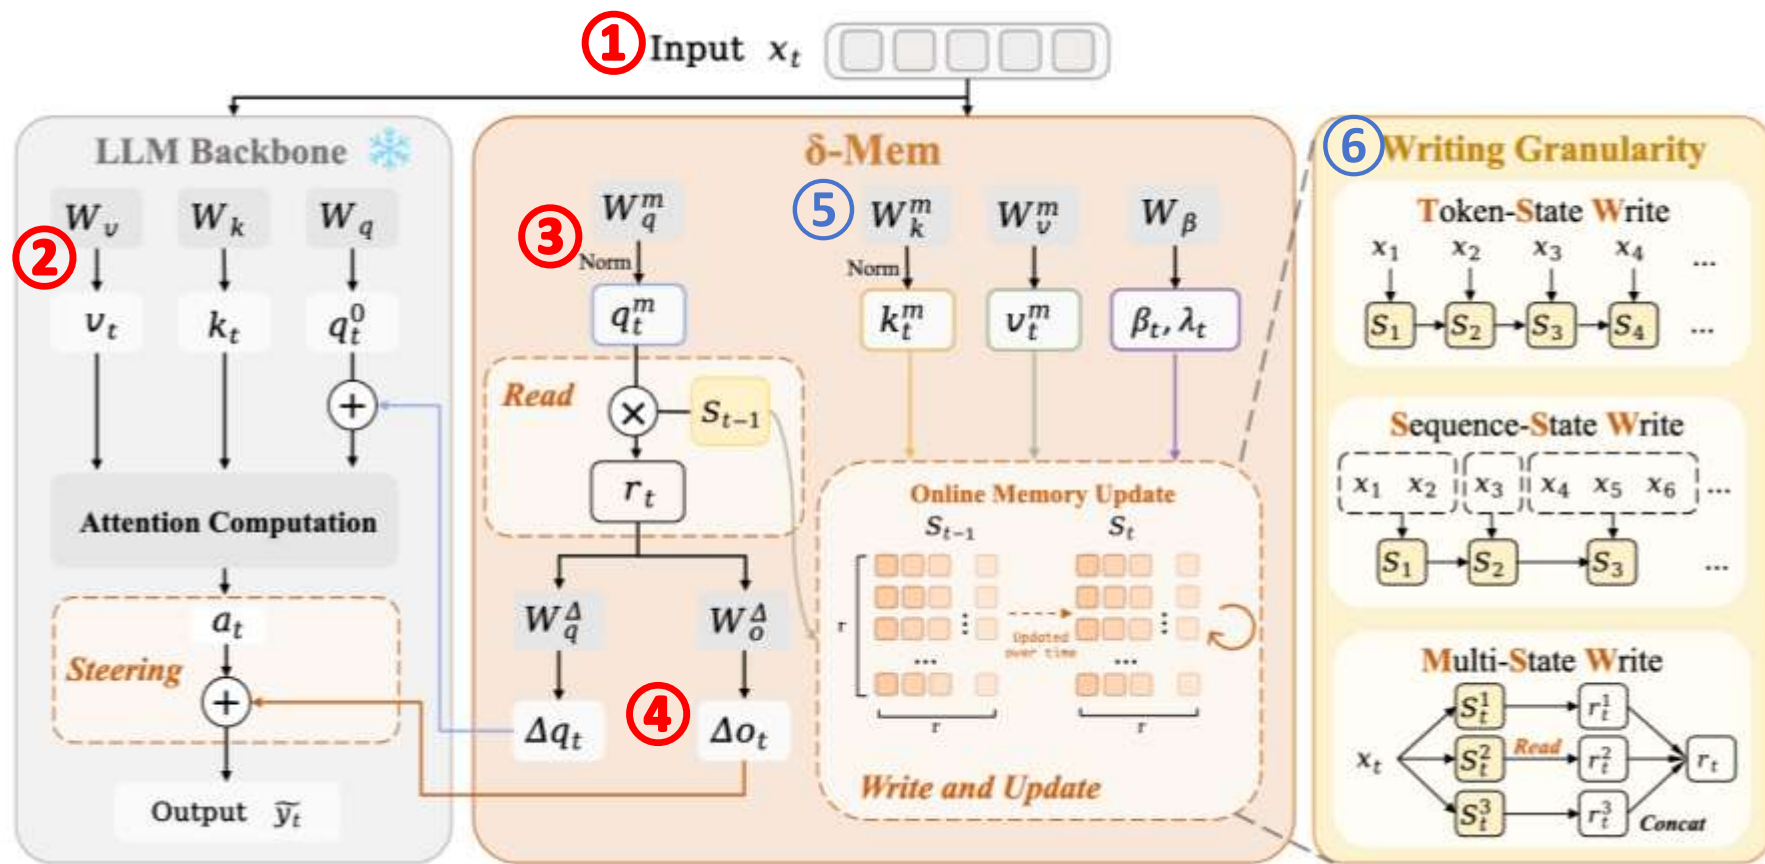
$$r_t = S_{t-1} q_t^m$$

➤ **Step4:** 记忆信号修正 attention

上一步读出的 r_t 会经过两个映射，

得到： $\Delta q_t, \Delta o_t$ ，其中： Δq_t 加到原始 query 上，影响模型 attention 应该关注哪里。 Δo_t 加到 attention output 上，补充历史相关信号。

Design



1. 推理

Step1: 来自前n个Transformer layer后的input

Step2: Frozen LLM 做标准 attention

Step3: δ -Mem 先读旧记忆

Step4: 记忆信号修正 attention

2. 更新

➤ Step5: 当前信息写入记忆矩阵 S_t

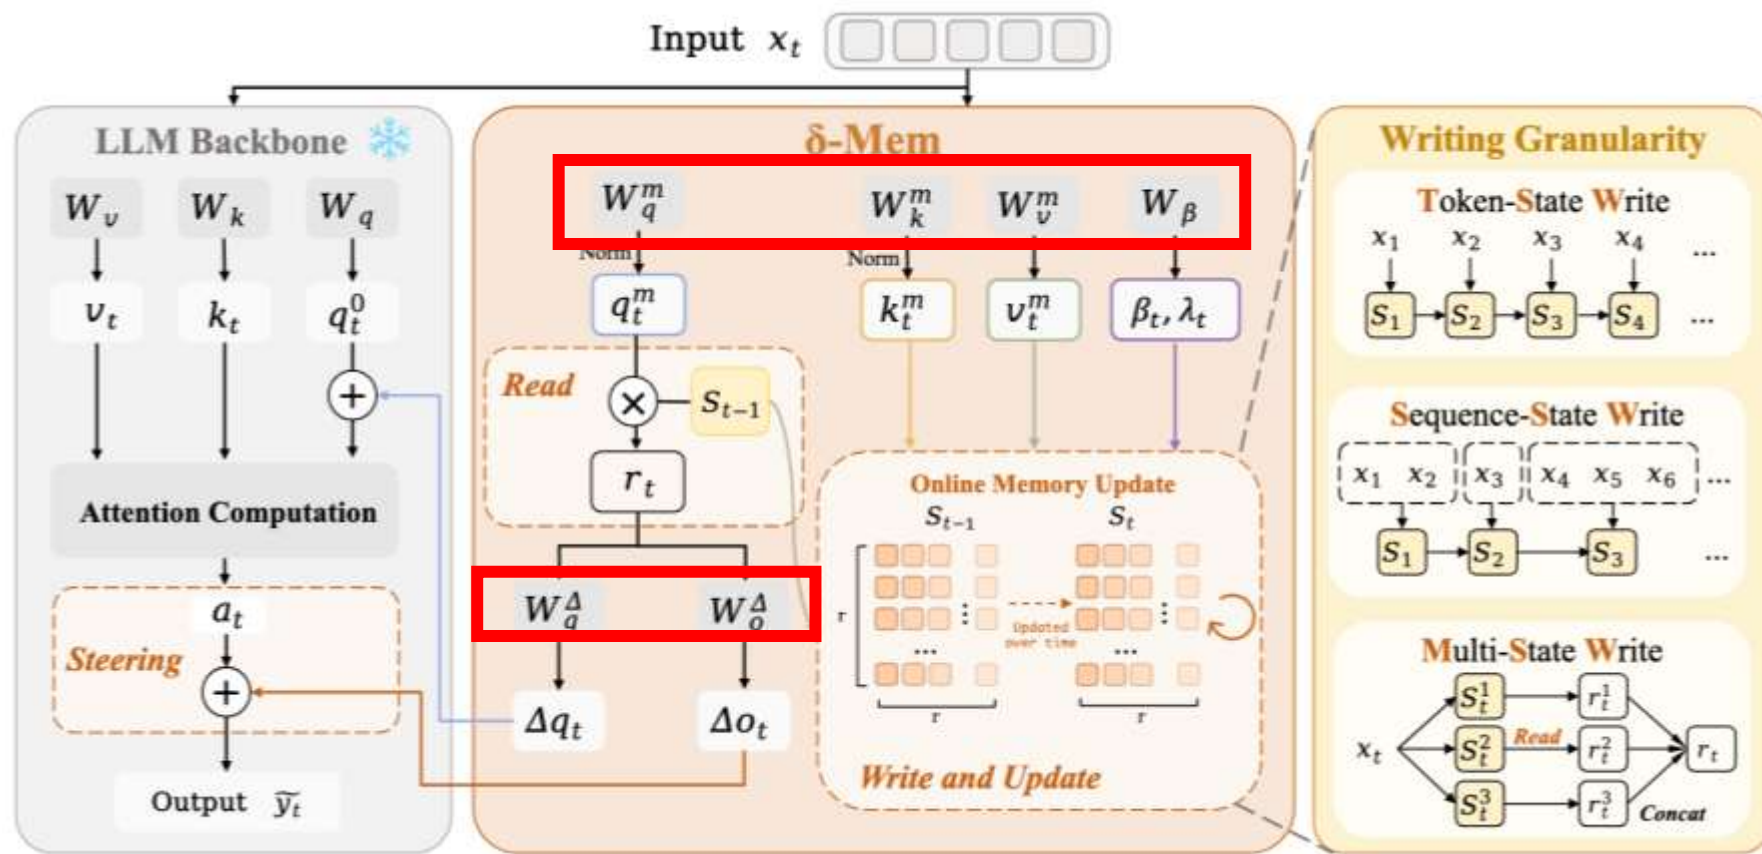
1. 类似第三步生成 memory query, 生成 memory key 和 value;
2. 同时生成两个门控信息: 写入门和遗忘门;
 β_t 决定“新信息写多少”, λ_t 决定“旧记忆留多少”。

➤ Step6: 三种写入粒度

说明 memory state 可以怎么更新。

1. Token-State Write: 每个 token 都写一次, 细粒度但噪声多。
2. Sequence-State Write: 一段 message 写一次, 更稳定但细节少。
3. Multi-State Write: 维护多个记忆状态, 减少不同信息互相覆盖。

Design



外部初始化训练

1. 反向传播更新了什么：训练的是 δ -mem 的模块参数，如图中红色方框

2. 训练目标：同 SFT 的 Loss

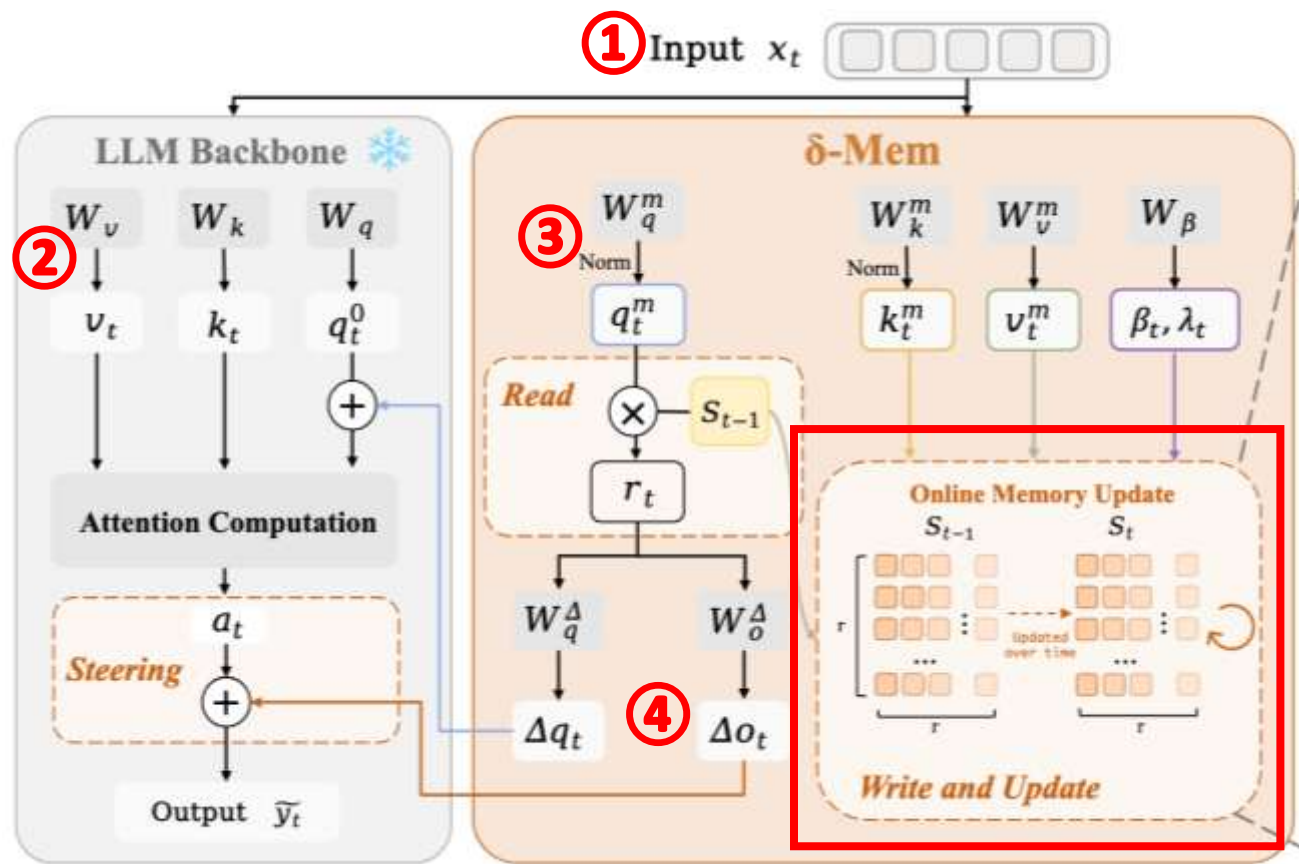
$$L_{\text{SFT}} = - \sum_j \log p_{\phi, \theta}(y_j | Q, y_{<j}, S_C)$$

第一步：Context $\rightarrow$ 写入 memory state S

第二步：Query + Answer + $S \rightarrow$ 预测 Answer

第三步：只在 Answer 上算 SFT loss

Design



4. **作用：**旧记忆状态 S_{t-1} 看到当前 key，会尝试预测这个 key 对应的 value 是什么。

$$\hat{v}_t = S_{t-1} k_t^m$$

- 如果预测得准，说明这个关联已经被记住了。
- 如果预测不准，说明当前信息还没有被记好，就需要更新 S_t

为什么矩阵 S_t 可以存储记忆？

1. **定义：**读到第 t 个 token 后，模型当前拥有的“在线记忆状态矩阵”。
2. **性质：**低秩（如 8×8 ）
3. **形状：**

$$S_t = \begin{bmatrix} 0.12 & -0.31 & \cdots \\ 0.44 & 0.08 & \cdots \\ \vdots & \vdots & \ddots \end{bmatrix}$$

- 这些数值表示一种 memory key 到 memory value 的线性映射关系。
- 那么每个元素 S_{ij} 可以理解为：memory key 第 j 维，对 memory value 第 i 维的关联强度。

***Tip:** δ -mem 并不是一个记忆模块，而是一个能增强 heavy context 下的注意力模块

Contents

- Background
- Challenges
- Design
- **Evaluation**
- Thinking

Evaluation

A. Experiments: What does δ -mem aim to verify?

1. δ -mem 是否优于 frozen backbone?
2. δ -mem 是否优于已有 memory mechanisms?
3. δ -mem 是否能适配不同 backbone?
4. 小型 memory state 是否真的保存了历史信息?
5. δ -mem 应该插入 attention 的哪些位置、哪些层?

Evaluation

B. Experimental Setup

Benchmarks

作者用了两类任务：

General capability benchmarks

- IFEval：指令遵循能力
- GPQA-Diamond：高难度知识推理
- HotpotQA：多跳问答，也带有一定 long-context / evidence retrieval 属性

Memory-heavy benchmarks

- LoCoMo：长期对话记忆
- MemoryAgentBench：Agent 场景下的记忆、检索、测试时学习、选择性遗忘等能力

Backbones

使用了：

- Qwen3-4B-Instruct
- Qwen3-8B
- SmoLLM3-3B

Baselines

主要包括：

- **Textual Memory**：BM25 RAG、LLMLingua-2、MemoryBank
- **Parametric Memory**：Context2LoRA、MemGen
- **Outside-channel Memory**：MLP Memory

Evaluation

C. Results

With context

Model	IFEval	HotpotQA		GPQA-D	Memory Agent Bench					LoCoMo					Avg.
		EM	F1		Avg.	AR	TTL	LRU	SF	Avg.	Multi	Temp	Open	Single	
Qwen3-4B-Instruct	81.89	42.35	56.00	39.39	29.54	35.30	26.14	47.08	14.37	40.79	38.39	32.89	10.77	48.05	46.79
Textual Memory															
+ BM25 RAG	-	40.35	52.83	-	24.49	32.20	9.74	37.86	15.00	36.68	38.12	20.34	9.99	45.47	44.56
+ LLMingua-2	-	36.93	50.03	-	15.63	21.45	1.43	38.45	8.62	40.98	39.07	30.13	10.98	49.19	42.96
+ MemoryBank	-	-	-	-	17.65	22.65	7.67	36.36	9.88	38.14	37.88	21.76	13.35	47.31	43.88
Parametric Memory															
+ Context2LoRA	76.71	37.85	50.88	29.29	32.53	40.00	29.86	25.15	17.75	48.11	37.95	34.99	16.75	60.11	44.90
+ MemGen	39.37	5.36	16.27	38.89	29.61	34.85	28.45	44.30	14.38	40.05	32.93	33.30	12.67	48.13	30.66
Outside-channel Memory															
+ MLP Memory	24.95	10.94	25.83	22.73	28.80	35.35	26.00	31.19	14.38	26.85	32.87	16.72	8.81	30.75	22.85
δ -Mem															
+ δ -Mem (SSW)	81.70	49.22	63.43	41.41	37.84	41.50	50.50	43.02	16.50	47.05	41.00	36.48	14.08	56.88	51.44
+ δ -Mem (TSW)	82.99	49.41	63.66	40.40	36.48	42.45	40.64	46.08	15.88	46.53	42.14	37.20	13.35	55.36	51.66
+ δ -Mem (MSW)	81.52	46.86	60.47	37.37	38.85	44.40	47.29	41.55	17.00	49.12	42.57	39.31	18.12	58.59	50.74


*Tip: δ -mem 并不是一个记忆模块，而是一个能增强 heavy context 下的注意力模块

1. Backbone Qwen input: 完整 context + query
2. Baselines input: 未知?
3. δ -mem input: 完整 context + 记忆矩阵 S + query

结论: δ -mem 的通用 Agent 能力相比 Backbone 有明显提升，在 heavy context 方面有显著提升；

这说明它有助于在长上下文中关注有效信息

No context



1. Backbone Qwen input: ~~完整 context~~ + query
2. δ -mem input: ~~完整 context~~ + 记忆矩阵 S + query

结论: 在完全无 Context 的情况下， δ -mem 的能力相比 Backbone 有提升，但是总体分数都非常低；

这说明它确实记住了一些东西，但记住的不多

Evaluation

D. Ablation

Head	HotpotQA						LoCoMo					Avg.
	Overall		Bridge		Comparison		Avg.	Multi	Temp	Open	Single	
	EM	F1	EM	F1	EM	F1						
q	45.87	60.59	44.96	60.34	49.50	61.58	43.15	42.43	33.60	10.03	50.82	44.51
k	43.39	57.28	42.35	56.82	47.55	59.09	40.98	38.44	33.12	10.93	48.26	42.19
v	46.12	60.95	45.07	60.54	50.30	62.57	42.35	39.54	34.24	11.11	49.95	44.24
o	48.94	63.69	47.67	63.58	54.00	64.15	45.15	39.68	36.31	12.77	54.06	47.05
qk	45.46	59.62	44.19	59.12	50.50	61.59	42.94	40.64	33.65	10.09	51.01	44.20
qv	47.02	61.95	45.86	61.64	51.65	63.20	43.24	40.38	35.57	10.76	50.84	45.13
qo	49.41	63.66	47.65	63.22	56.42	65.42	46.53	42.14	37.20	13.35	55.36	47.97
kv	45.67	60.43	44.90	60.25	48.76	61.14	42.02	39.45	33.91	11.00	49.52	43.85
qko	48.24	62.42	46.79	62.11	54.00	63.66	46.01	40.89	36.82	12.61	55.05	47.13
qkv	47.47	62.56	46.40	62.25	51.71	63.81	42.42	39.40	34.70	10.04	50.08	44.95
qkvo	49.94	65.01	48.39	64.63	56.09	66.56	46.15	41.08	37.25	13.14	55.02	48.05

Layer	HotpotQA						LoCoMo					Avg.
	Overall		Bridge		Comparison		Avg.	Multi	Temp	Open	Single	
	EM	F1	EM	F1	EM	F1						
Front 12	45.52	61.01	45.32	61.08	46.33	60.77	43.26	39.06	33.65	10.19	52.10	44.39
Middle 12	47.44	60.59	45.56	60.06	54.94	62.71	45.87	44.00	35.75	13.09	54.10	46.66
Back 12	44.58	59.04	43.56	58.65	48.62	60.58	43.53	40.60	36.31	11.11	50.97	44.06
All Layers	49.41	63.66	47.65	63.22	56.42	65.42	46.53	42.14	37.20	13.35	55.36	47.97

Heads Ablation

1. **讨论**: 将记忆修正项 (Delta) 注入到不同的分支组合时, 对模型性能的影响。
2. **结论**: 插 **qkvo** 效果最好, 插 **qo** 性价比最高 (这也是本文默认的方法)

Insertion Depth Ablation

1. **讨论**: 应该在哪些 Transformer Layers 中安插 δ -mem 记忆模块。
2. **结论**: 插 **All Layers** 效果最好, 插 **Middle 12 Layers** 性价比最高

Contents

- Background
- Challenges
- Design
- Evaluation
- **Thinking**

Thinking

Conclusion

- 这篇文章说明，LLM 的记忆不一定只能以显式文本或参数更新的形式存在，也可以被压缩成一个小动态状态，并用于引导 attention 计算。
- 不过， δ -mem 更接近一种隐式的注意力引导机制，而不是 RAG 式的长期记忆系统：它不能检索原始证据，no-context 实验也说明其保存的信息是非常有限的。
- 因此，这篇工作的主要价值不在于替代显式记忆或检索系统，而在于提升 frozen LLM 在长上下文 / memory-heavy 场景下对历史信息的利用能力。

这篇 paper 的 idea 引起的思考？

1. Memory 不只是“存历史”，也是“调节当前行为”

本文启发在于：memory 不一定要像 RAG 一样把历史原文存下来再检索，也可以作为一种动态 latent state，直接影响模型当前的 attention 和推理。

对应到具身智能，memory 的价值不只是记录过去，还应该帮助 agent 决定当前看哪里、关注什么、下一步怎么行动。

2. 具身 memory 可能需要“显式记忆 + 隐式状态”

δ -mem 的局限也说明，仅靠隐式状态很难替代长期记忆系统。

例如，在具身任务中，显式记忆可以负责保存地图、物体位置、历史事件和用户偏好；隐式状态则负责把这些历史信息转化为当前任务中的注意力偏置或动作倾向。



東南大學
SOUTHEAST UNIVERSITY

Q & A

汇报人：宋青阳

2026年6月15日