Trace as State: Reasoning Traces as Conditional States for Long-Context Transformers

推理轨迹作为长上下文 Transformer 的条件状态

arXiv:2609.02702

Xu Zou[1] Jie Tang[2]

[1]Z.ai（智谱）
[2] 清华大学（Tsinghua University）

论文分享会：2026 年 10 月 26 日

作者介绍

邹旭（Xu Zou） Z.ai / 智谱

研究方向

- 预训练大模型
- 可控文本生成

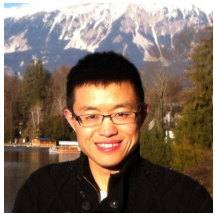
近期发表

- GLM-5: from Vibe Coding to Agentic Engineering
- BIPro: Zero-shot Chinese Poem Generation via Block Inverse Prompting Constrained Generation Framework



邹旭[1]

Z.ai 算法专家



唐杰[2]

清华大学

[1]邹旭（Xu Zou）Homepage
[2]唐杰（Jie Tang）Homepage

目录

1. 背景与问题
2. 理论动机
3. Trace as State
4. 实验
5. 结论与局限

背景与问题

背景: 长上下文的因果性

- 前沿 LLM 模型已能处理**数十万到百万 token** 的上下文。
- 但自回归 Transformer 存在**因果注意力**:
  - 后出现的信息 可以 被后续推理与答案生成使用;
  - 它**无法**影响同一次 pass 中**更早位置已经形成的表示**。
- **输入顺序 $\neq$ 推理顺序**。

问题: 上下文与任务状态的互相依赖

- 大部分长上下文任务要求模型持续维护 **任务状态 (Task State)**:
  - 当前活跃目标（active target）
  - 搜索前沿（search frontier）
  - 已被排除的假设集合
- 这类状态常常**只有在读完前面那一大段上下文之后**才开始浮现。
- 处理对应上下文时，又需要对应的任务状态的引导。

目录

1 背景与问题

2 理论动机

3 Trace as State

4 实验

5 结论与局限

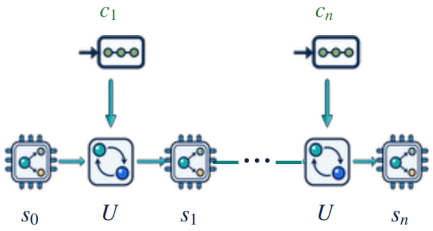
形式化工作流程

工作流程

- 把输入切成长度 n 的有序信息单元 $C = (c_1, \dots, c_n)$
- 处理器维护一个有限状态空间 $\mathcal{S}$ 中的任务状态 s_i
- 每读一个单元，用固定更新规则 U 更新

$$s_i = U(s_{i-1},\, c_i), \qquad i = 1, \dots, n$$

- 初始状态 s_0 由任务**条件** $z \in \mathcal{S}$ 给出
- 记 $b = \log_2 |\mathcal{S}|$（状态空间的对数规模）

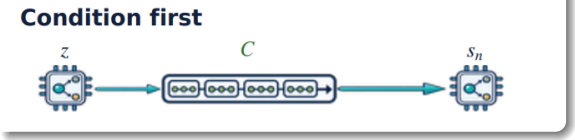


理论结果：条件前置

条件在前 $[z, C]$

收到 z 时就知道该沿哪条状态路径更新，只需保存**当前状态**：

$$\lceil b \rceil \text{ bits}$$



条件在后 $[C, z]$

读完 C 还不知道该走哪条路径，必须为**每种可能的** z 保留完整的信息：

$$\lceil b\, 2^b \rceil \text{ bits}$$



- 因此条件 z 在前时，获得结果 s_n 的难度会大幅降低。

目录

1 背景与问题

2 理论动机

3 Trace as State

4 实验

5 结论与局限

推理轨迹作为 Task State 的文本代理

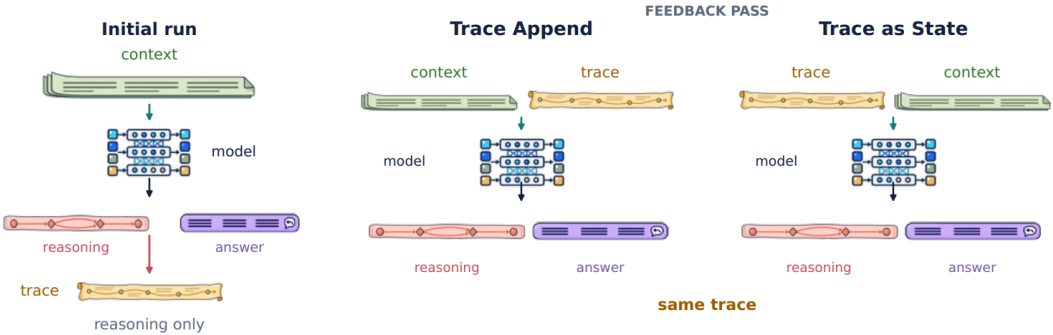
Trace as State

- 真实任务中，z 可能在**推理时才浮现**的。
- 关键观察：现代推理模型会把推理过程**显式输出**出来——轨迹里天然记录着活跃目标、已解析的指代、搜索前沿这类中间状态。
- 于是把这条轨迹当作 task state 的**近似可观测文本代理（textual proxy）**。

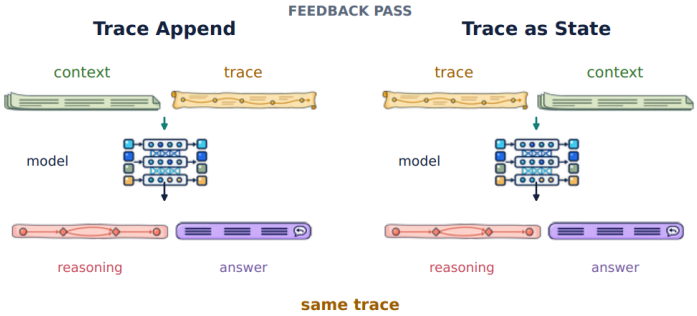


方法

1. **Initial run**：在同一个问题上跑模型 n_{tr} 次
2. **Serialize**：将获得的推理轨迹拼接，作为文本代理
3. **Reread**：让模型在拼接了推理轨迹的上下文中重新作答



顺序对照



TRACE-APPEND [x, T, q]

轨迹在上下文**之后**。
T 仍可影响后续推理与最终答案，但**无法改变**已经为前文 token 形成的表示。

TRACE-AS-STATE [T, x, q]

轨迹在上下文**之前**。
重读上下文时，T 已经可用，**能参与表示的形成**。

目录

1. 背景与问题
2. 理论动机
3. Trace as State
4. 实验
5. 结论与局限

实验设置：3 模型 × 3 基准

模型

- **Qwen 3.7 Max** ——GDN + Gated Attention
- **DeepSeek V4 Pro Preview** ——CSA + HCA + mHC
- **GLM-5.2** ——1M MoE，DSA + IndexCache

任务

- **GraphWalks 256K**（200 题）——在长边表上维护图状态
- **MRCRv2 8-needle 256K/512K**（200 题）——多轮请求-响应绑定
- **NUB-1M Season 2**（20 题）——40–70 万 token 小说阅读

主结果

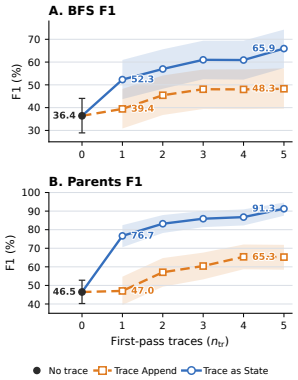
模型	条件	GraphWalks 256K				MRCRv2 8-needle				NUB-1M
		BFS		Parents		256K		512K		Season 2
		EM	F1	EM	F1	EM	Seq	EM	Seq	Acc
DeepSeek V4 Pro Preview	First Pass	31.6	36.4	29.2	46.5	53.8	78.5	45.4	63.6	60.0
	TRACE-APPEND	41.8	48.3	43.0	65.3	66.6	79.6	49.4	66.9	71.0
	TRACE-AS-STATE	**58.8**	**65.9**	**81.8**	**91.3**	**76.2**	**88.5**	**52.6**	**73.3**	**73.0**
Qwen 3.7 Max	First Pass	60.0	68.1	60.8	87.2	79.8	83.1	36.2	43.7	37.0
	TRACE-APPEND	60.4	70.4	71.0	91.7	84.0	87.1	40.4	47.4	49.0
	TRACE-AS-STATE	**63.8**	**71.7**	**96.4**	**99.1**	**88.4**	**91.3**	**46.8**	**52.5**	**51.0**
GLM-5.2	First Pass	55.8	70.7	66.4	88.5	40.2	48.2	42.6	52.0	43.0
	TRACE-APPEND	60.0	**75.8**	83.2	92.7	40.0	58.3	44.6	59.9	65.0
	TRACE-AS-STATE	**63.4**	75.0	**100.0**	**100.0**	**61.2**	**71.9**	**55.4**	**70.1**	**66.0**

消融实验

条件	Prompt	BFS		Parents	
		EM	F1	EM	F1
First pass	$[x, q]$	31.6	36.4	29.2	46.5
Majority@5	—	35.0	39.6	31.0	47.8
Oracle@5	—	50.0	55.5	50.0	75.0
Question First	$[q, x, q]$	33.4	36.8	53.0	64.6
Re2	$[x, q, x, q]$	49.0	52.9	50.0	68.9
Answer Feedback	$[a, x, q]$	35.4	39.4	45.4	58.0
Random Trace	$[T_{\mathsf{rand}}, x, q]$	22.4	35.9	14.2	31.3
Trace Only	$[T, q]$	46.2	52.7	43.8	67.3
Trace-Append	$[x, T, q]$	41.8	48.3	43.0	65.3
Trace-as-State	$[T, x, q]$	**58.8**	**65.9**	**81.8**	**91.3**

DeepSeek V4 Pro Preview × GraphWalks 256K，5 次重复平均。

轨迹数量



- 把回灌的轨迹数 n_{tr} 从 1 加到 5：
  - 性能**总体随轨迹数上升**
  - 对每个 $n_{\mathrm{tr}} \geq 1$，TRACE-AS-STATE 都高于 TRACE-APPEND
  - 两个条件嵌套（都取前 n 条合格轨迹）
- $n_{\mathrm{tr}} = 0$ 为五次首轮 pass 均值

模型冻结下的实现：排序效应在整个 n_{tr} 区间都稳定存在。

目录

1 背景与问题

2 理论动机

3 Trace as State

4 实验

5 结论与局限

结论

任务状态的价值

推理轨迹能把 task state 信息**带到下一轮**。
而这段信息的**位置**，决定了其带来的性能提升。

代价

额外 pass 带来**延迟与 token 成本**。
把状态前置还会**破坏 KV cache 复用**。

思考

能否用更廉价的方式获得思维链的状态信息？
能否在思考链之后再 prefill 原文，以减少延迟与 token 成本？
在行为无法撤回的场景下，如何保证轨迹不会强化潜在高风险内容？