VLA Models Are More Generalizable Than You Think: Revisiting Physical and Spatial Modeling

CVPR 2026

Weiqi Li, Quande Zhang, Ruifeng Zhai, Liang Lin, Guangrun Wang

徐翎

11.2

作者团队

中山大学人机物智能融合实验室（SYSU-HCP Lab）

实验室主攻方向：

Human Cyber Physical Intelligence Integration Lab

- **具身智能与机器人**
- **多模态基础模型**
- **计算机视觉与视觉生成**

补充：
广东省大数据分析与处理重点实验室
及 **X-Era AI Lab**



王广润



林倞

- W. Li *et al.*, "VLA Models Are More Generalizable Than You Think: Revisiting Physical and Spatial Modeling," **CVPR 2026**.
- L. Zhang *et al.*, "AtomicVLA: Unlocking the Potential of Atomic Skill Learning in Robots," **CVPR 2026**.
- K. Zhang *et al.*, "RoBridge: A Hierarchical Architecture Bridging Cognition and Execution for General Robotic Manipulation," **ICCV 2025**.
- T. Tao *et al.*, "RoboPearls: Editable Video Simulation for Robot Manipulation," **ICCV 2025**.
- M. Han *et al.*, "RoomTour3D: Geometry-Aware Video-Instruction Tuning for Embodied Navigation," **CVPR 2025**.

章节目录

- 问题背景
- 核心判断与评测设置
- FTM 与 FLA 方法
- 实验评估
- 总结与讨论

问题背景

换一个相机视角，机器人为什么容易失手?

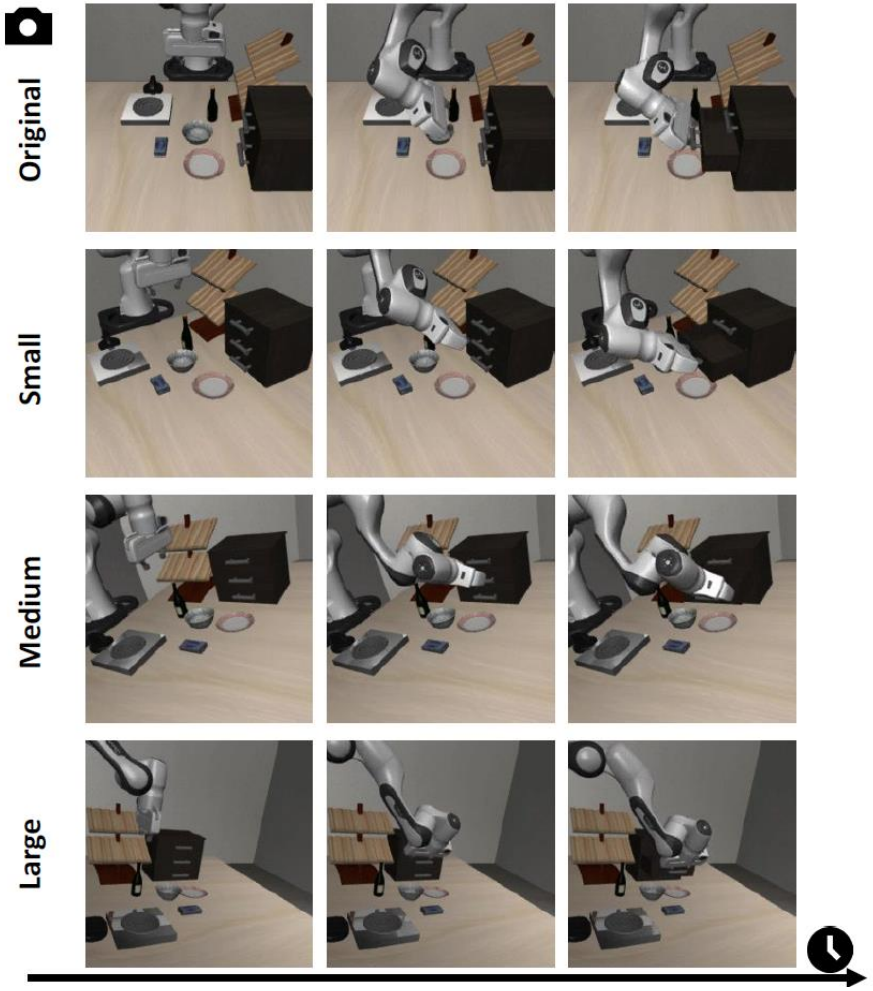
场景：任务指令和物体没有变，画面里的位置、方向和遮挡变了。

π0.5 在未见视角下的零样本平均成功率

48.5%

归因 ----> VLA模型泛化能力弱？

但是现实真的如此吗?



同一任务的不同视角观测（论文 Fig. 2）

解决方案

如何解决视角切换的成功率损失问题?

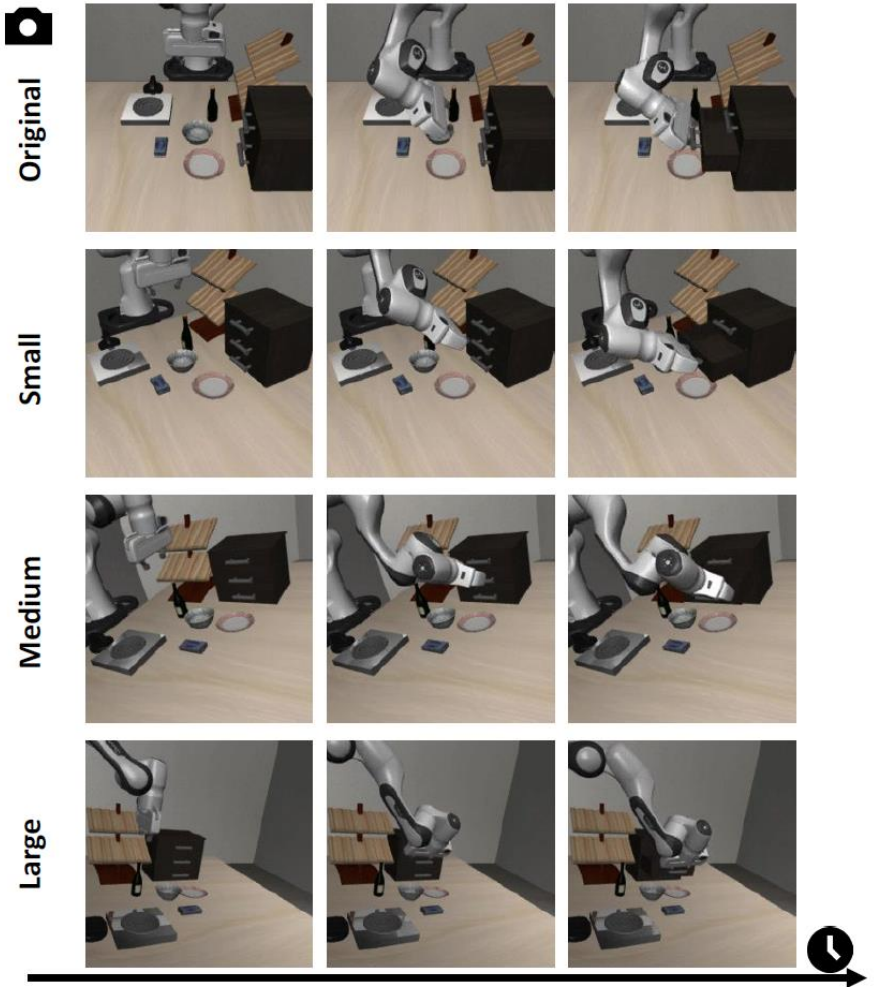
解决方法:

1. 增加训练数据: 不同角度、光照、背景。有效但是代价大
2. 改变模型结构, 让模型具有显式的空间/几何分析能力

一个反问:

- **是不是我们根本不需要重新设计整个 VLA?**

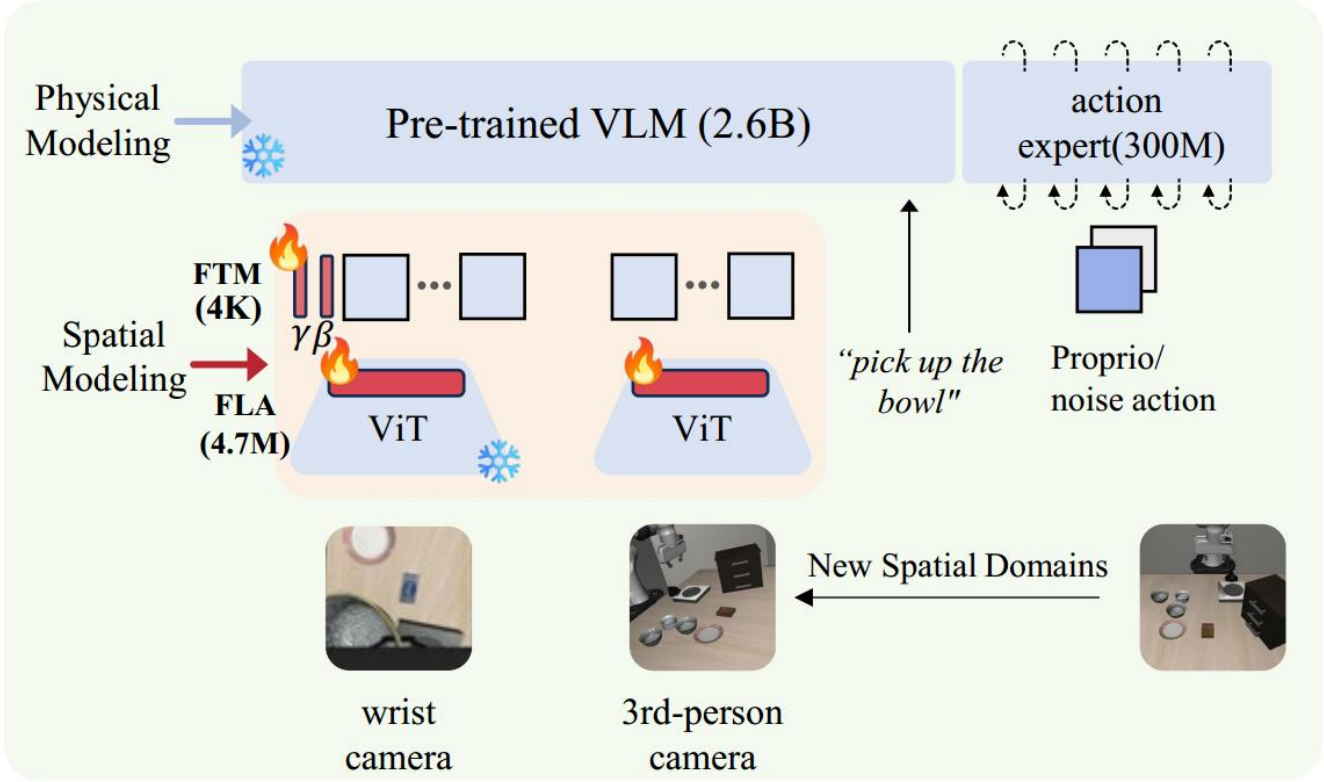
VLA模型并没有损失完成动作的能力
而只是见到了从没见过的视角



同一任务的不同视角观测（论文 Fig. 2）

核心Insight

视觉空间表示发生偏移



视觉编码器负责空间表示，VLM 与动作专家生成动作

Spatial Modeling

视觉编码器提取物体位置、朝向和接触关系。

Physical Modeling

模型对物理世界的理解，VLM 和动作专家据此生成动作。

论文判断：新视角的主要瓶颈在视觉侧对齐。

FTM 方法

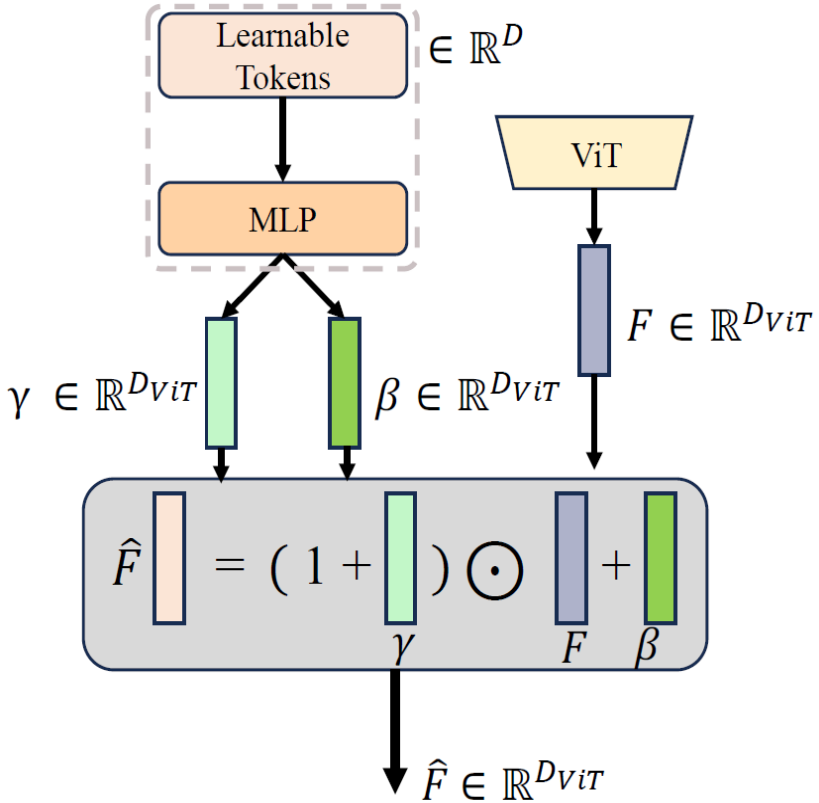
Feature Token Modulation（FTM）

只针对调整视觉编码器输出的 token

$$\hat{F} = (1 + \gamma) \odot F + \beta$$

γ：按特征维度缩放　　β：按特征维度平移

主模型保持冻结，只训练约 4K 个参数。



(a) Feature Token Modulation.

FTM方法的示意图

FLA 方法

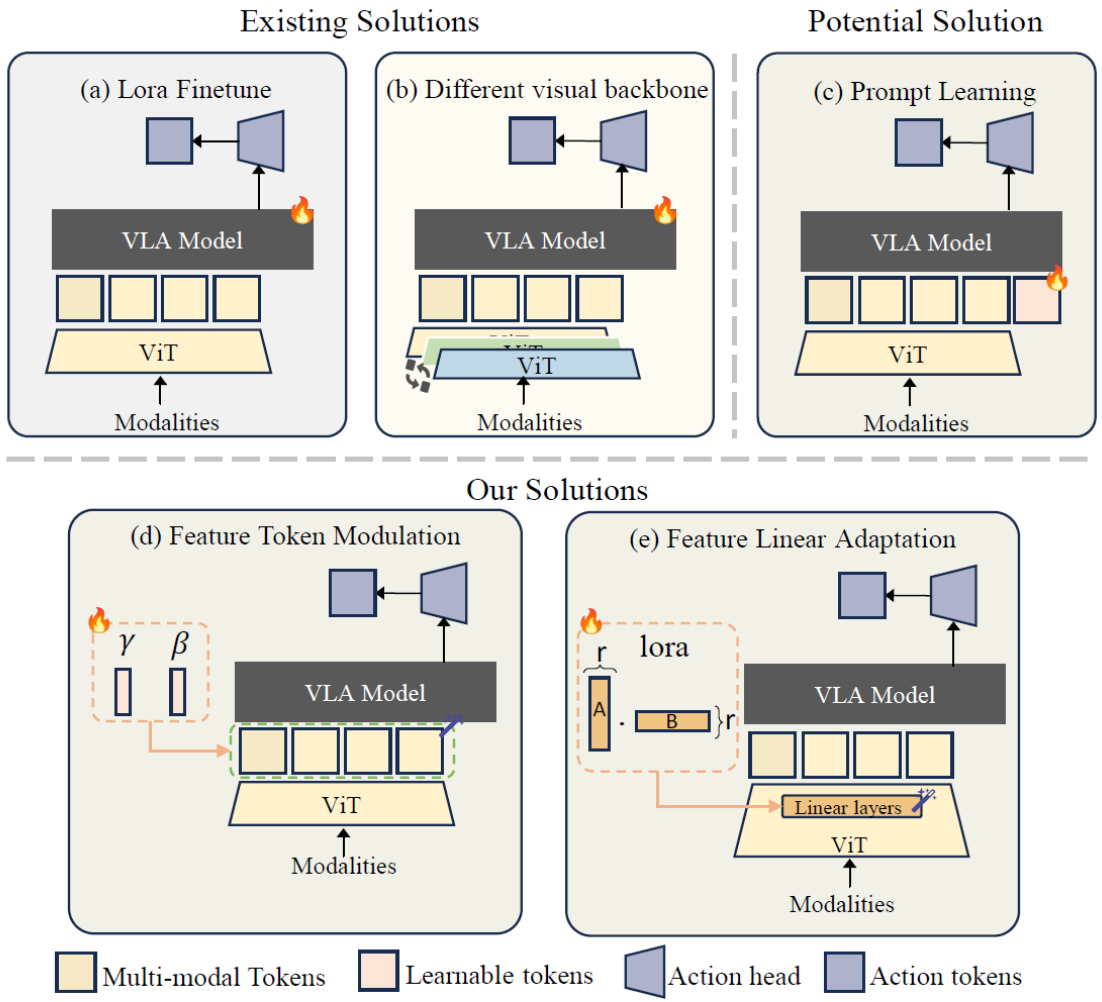
Feature Linear Adaptation（FLA）

把小规模更新放进**视觉编码器的线性层**

$$W' = W + BA$$

W 保持冻结，只训练低秩矩阵 A、B

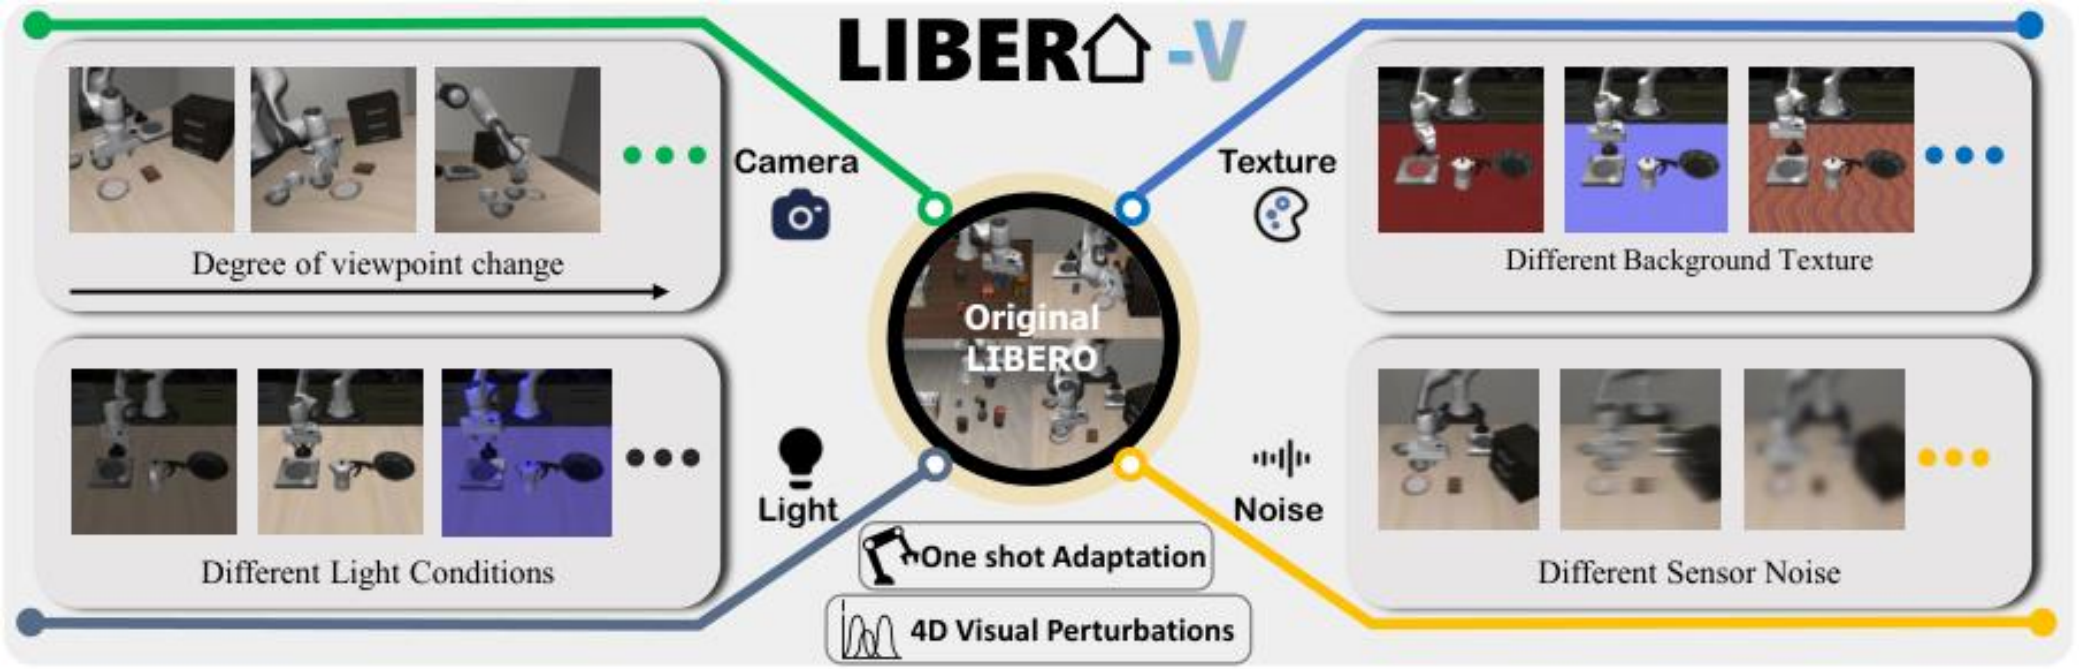
可训练参数约 4.7M



整体 Design

Libero-V 评测

同一组机器人任务，改变四类视觉条件



相机视角 **光照** **背景纹理** **图像噪声**

40 个任务；每任务 50 次测试；每任务仅用 1 条新域人工示范进行适应

实验评估

四类视觉扰动中的任务成功率（%）

Model	Visual Perturbations				Average
	camera	light	texture	noise	Across Subsets
OpenVLA-OFT	50.3	92.7	92.3	78.6*	78.5
OpenVLA-OFT-m(Fine-Tuned on Libero-Plus [8]))	65.2	94.9	93.9	89.9*	86.0
π_0(One-Shot Lora Fine-tuned)	83.6	90.7	86.7	87.0*	87.0
$\pi_{0.5}$(Zero-Shot)	48.5	96.2	96.0	93.5	83.6
$\pi_{0.5}$(One-Shot Lora Fine-tuned)	90.3	96.5	**97.2**	94.5	94.6
$\pi_{0.5}$(One Shot FTM)(ours)	87.1	96.0	96.0	93.6	90.5
$\pi_{0.5}$(One-Shot FLA)(ours)	**90.8**	**96.8**	97.1	**94.6**	**94.8**

FTM 用约 4K 参数把成功率从 48.5% 提升到 87.1%；FLA 达到 90.8%。

视角变化最难；FLA 在四类扰动的平均成功率为 94.8%。

实验评估

在不同视觉偏移幅度下的成功率

Model	Libero Suites (Novel Camera)			
	Small SR(%)	Medium SR(%)	Large SR(%)	Average SR(%)
GeoAware-VLA	88.0	74.5	71.2	77.9
OpenVLA-oft-m(fine-tuned on Libero-Plus)	88.1	65.5	42.1	65.2
π_0(One-Shot Lora Fine-tuned)	88.3	83	79.5	83.6
$\pi_{0.5}$(One-Shot Lora Fine-tuned)	**94.8**	**90.5**	85.6	90.3
Ours	94.6	90.0	**87.9**	**90.8**

参数效率

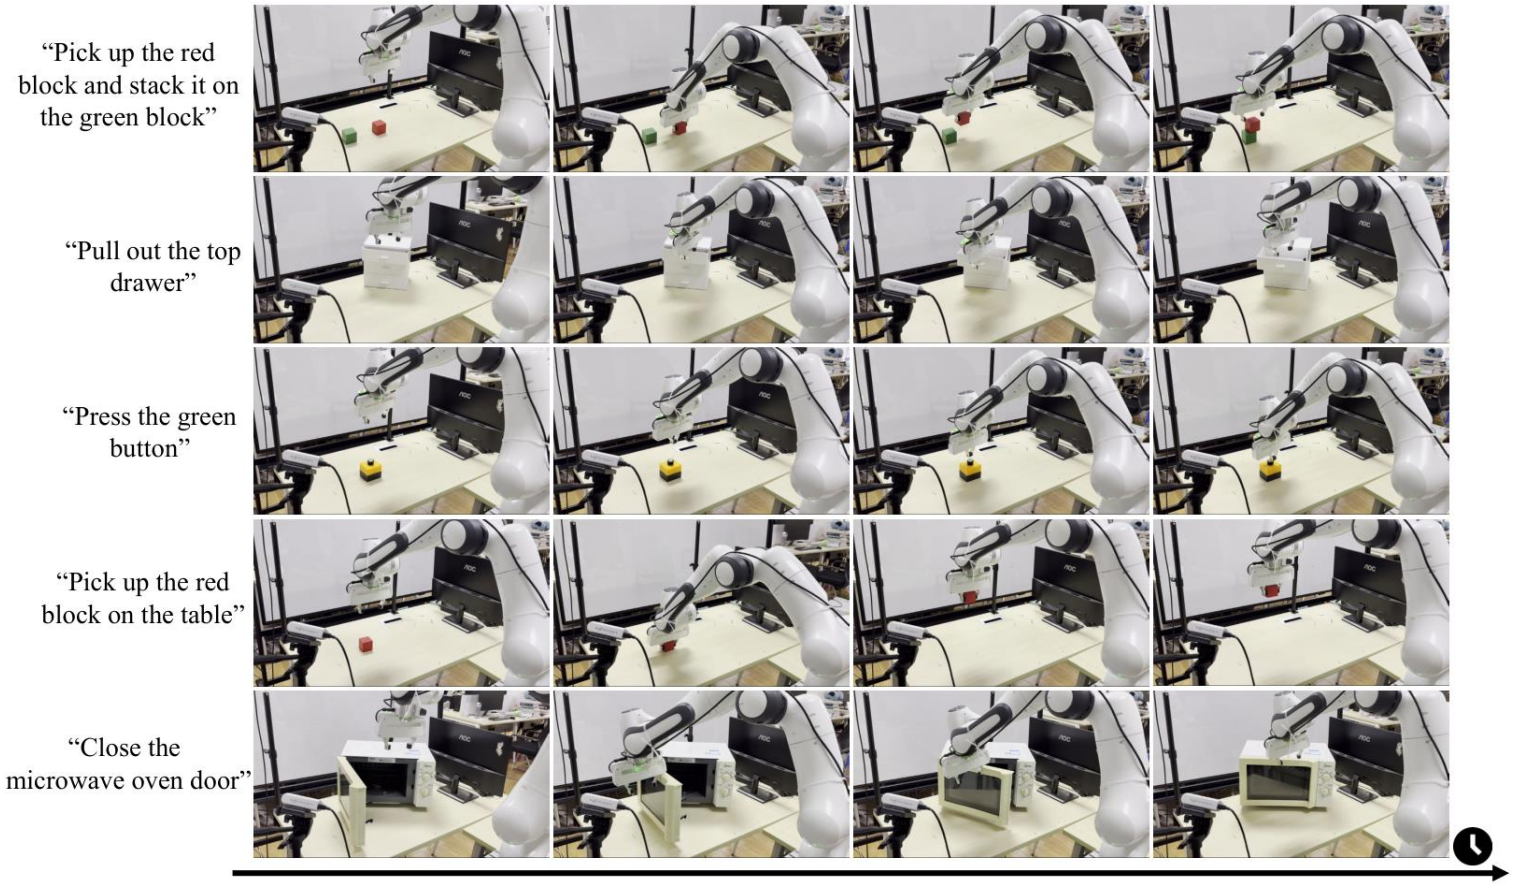
更新多少参数，换来多少新视角成功率?

Methods	#Params (M)	Libero-V(%)
π_0(One-Shot Lora Fine-tuned)	468.04	87
$\pi_{0.5}$(Prompt Learning)	0.131	75.1
$\pi_{0.5}$(One-Shot Lora Fine-tuned)	466.96	94.6
$\pi_{0.5}$(One Shot FTM)(ours)	**0.004**	90.5
$\pi_{0.5}$(One-Shot FLA)(ours)	4.7	**94.8**

FLA 与 LoRA 的成功率接近，可训练参数约为后者的 1/99。

真实机器人验证

新机位下，Franka Panda 完成五类操作



一条新视角示范

FLA 仅调整视觉编码器

涵盖抓取、堆叠、开抽屉、按按钮与关门。

结果为定性展示。

总结与讨论

全文总结

论文在机械臂控制任务中，摄像头漂移场景下，视觉传感器真实接收数据与训练数据分布偏差进行深入探讨。通过观察和实验指出模型视觉建模和物理世界建模的区别，进一步将问题归因为视觉表示的偏移，最后设计轻量模块高效解决问题。此外还改编了数据集。

思考讨论

- 论文整体工作的质量
- 对模型的表征分析
- 对模型能力的正确估计

系统的角度：对于参数对的收集与管理 ----> 融合 $\alpha W_1 + \beta W_2 = W_{new}$

感谢聆听

Q&A

徐翎

11.2

实验评估

未见相机视角下的平均成功率