ProphetKV

面向用户问题的KV选择性重算

User-Query-Driven Selective Recomputation for
Efficient KV Cache Reuse in Retrieval-Augmented Generation

Shihao Wang、Jiahao Chen 等

ICML 2026 • PMLR 306

作者团队

哈尔滨工业大学（深圳）为主的合作团队

ProphetKV 共同一作：Shihao Wang、Jiahao Chen

共同通讯：Xiangyu Zou、Wen Xia 研究方向：存储系统、数据去重、压缩算法和系统优化

代表工作	发表情况	研究方向	主要贡献
ProphetKV	ICML 2026	KV 复用	用当前问题选择重算位置，修复跨文档联系
RESA	ICLR 2026	稀疏注意力	估计未选 KV 的贡献，补偿稀疏注意力输出
TTKV	arXiv 2026	分层存储	按时间组织 KV，协同精度、存储位置与传输
DGAP	arXiv 2026	低比特量化	保留低比特 KV，选择性校正下一词候选分布

研究背景

同一文档，前文变了

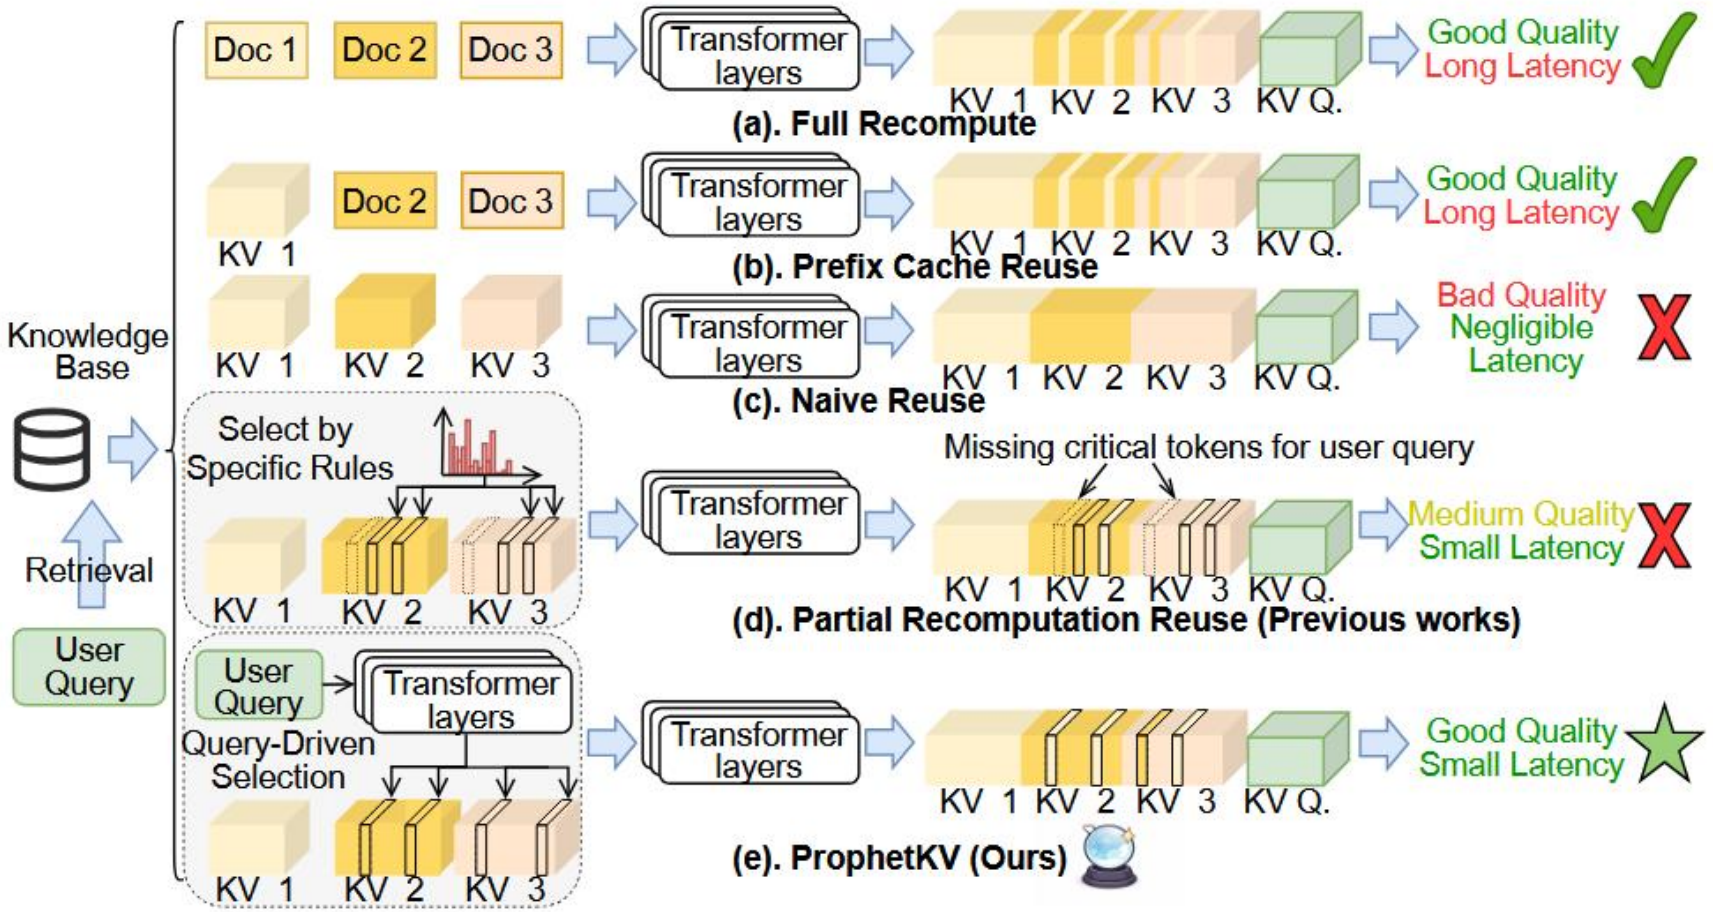
请求	检索文档及问题
甲	文档A，文档B，问题甲
乙	文档C，文档A，问题乙

A再次出现，但它前面的内容已经不同 ----- 非前缀复用

CacheBlend：比较KV差异，选择性重算

研究背景

独立缓存缺少块间联系



各块单独编码时
没有读到前面的块

部分重算让选中位置
重新获得跨块信息

研究动机

如何选择重算位置

挤出效应

问题无关的token占据重算名额
挤出真正重要的位置

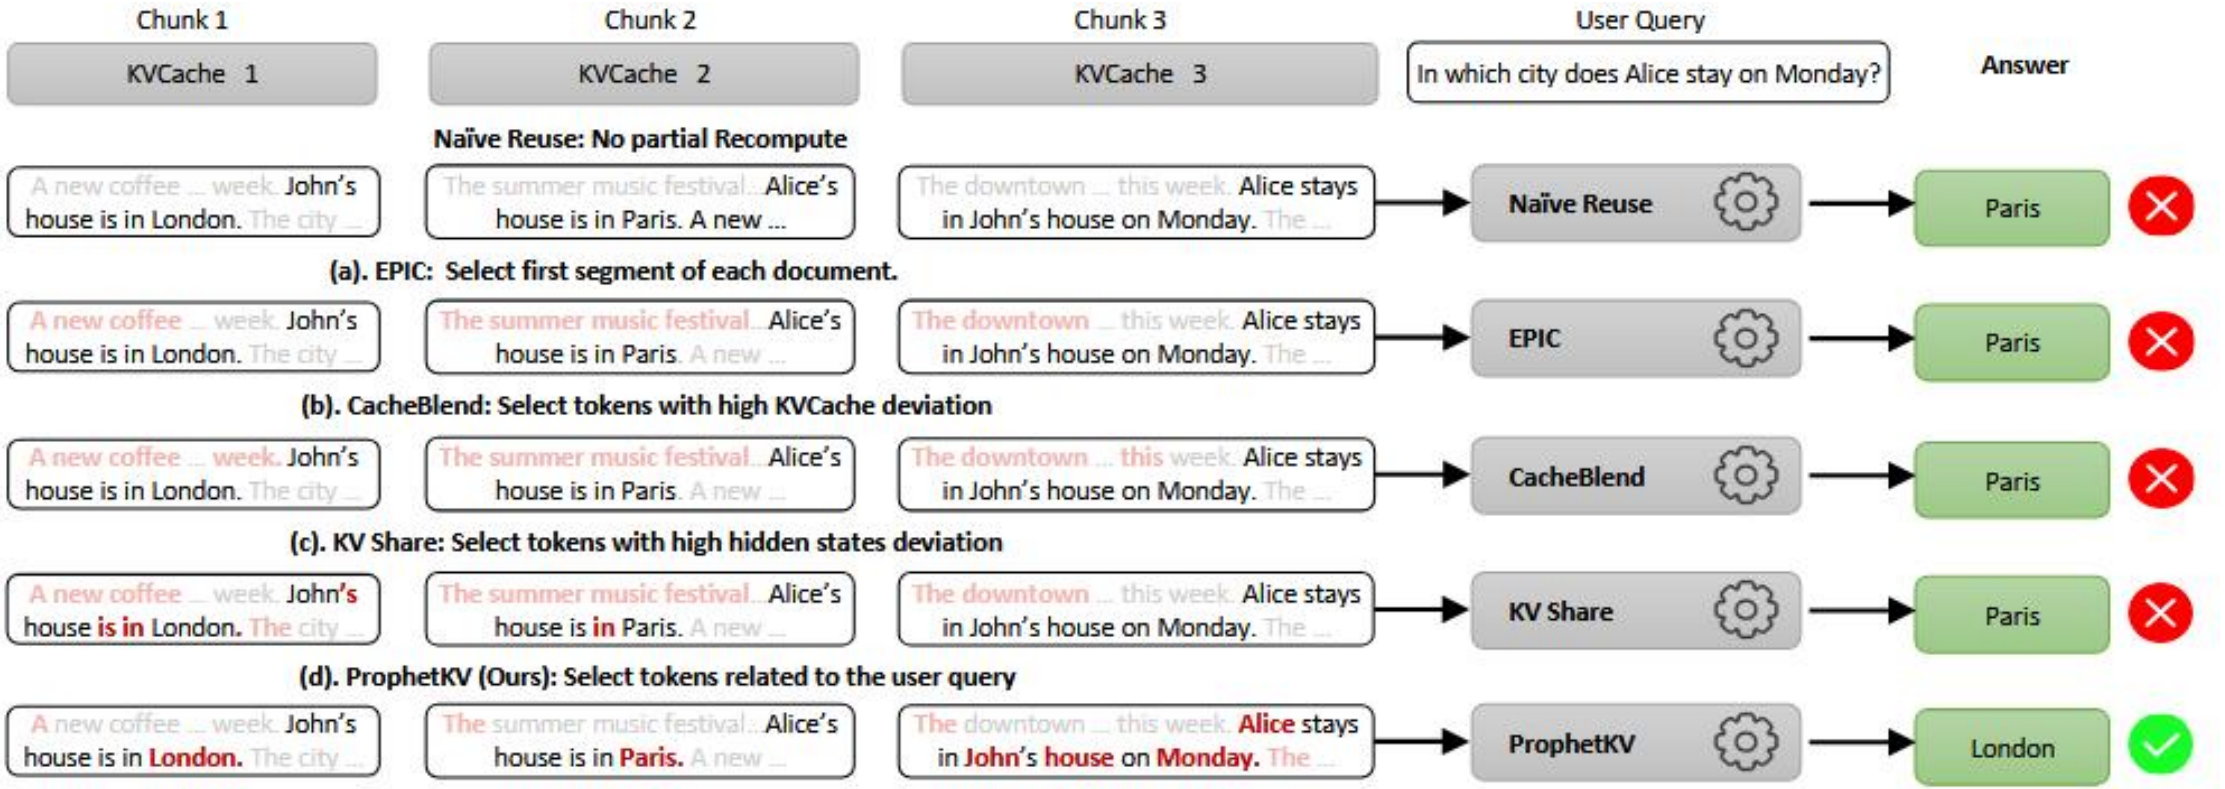
方法	主要选择依据
EPIC	开头位置(attention sink)
CacheBlend	KV变化差异
KVShare	偏差及注意力
ProphetKV	**当前问题的注意力**

数值变化大的位置，是否也是当前答案需要的位置?

研究动机

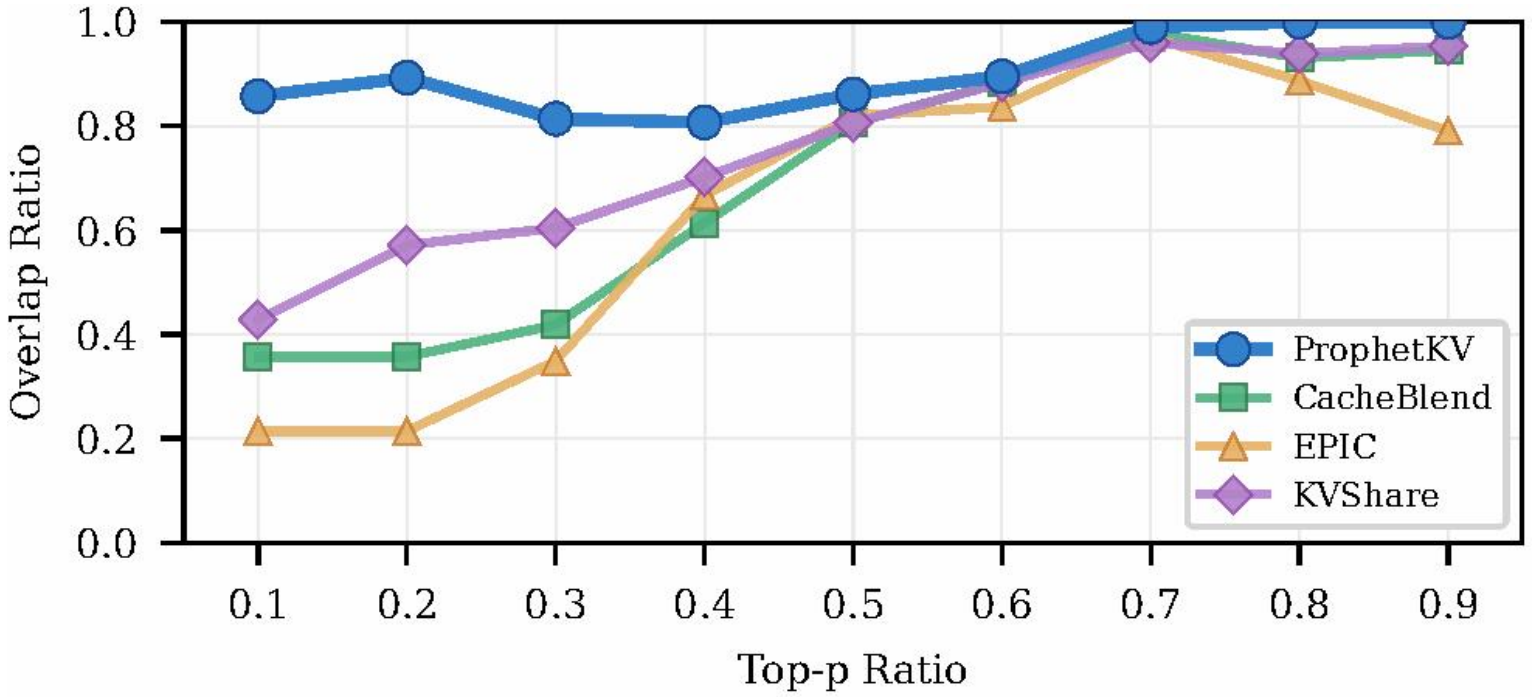
论文里的城市问答

先前的工作把大量重算消耗在无关位置上



研究动机

选中的位置，是否服务当前问题



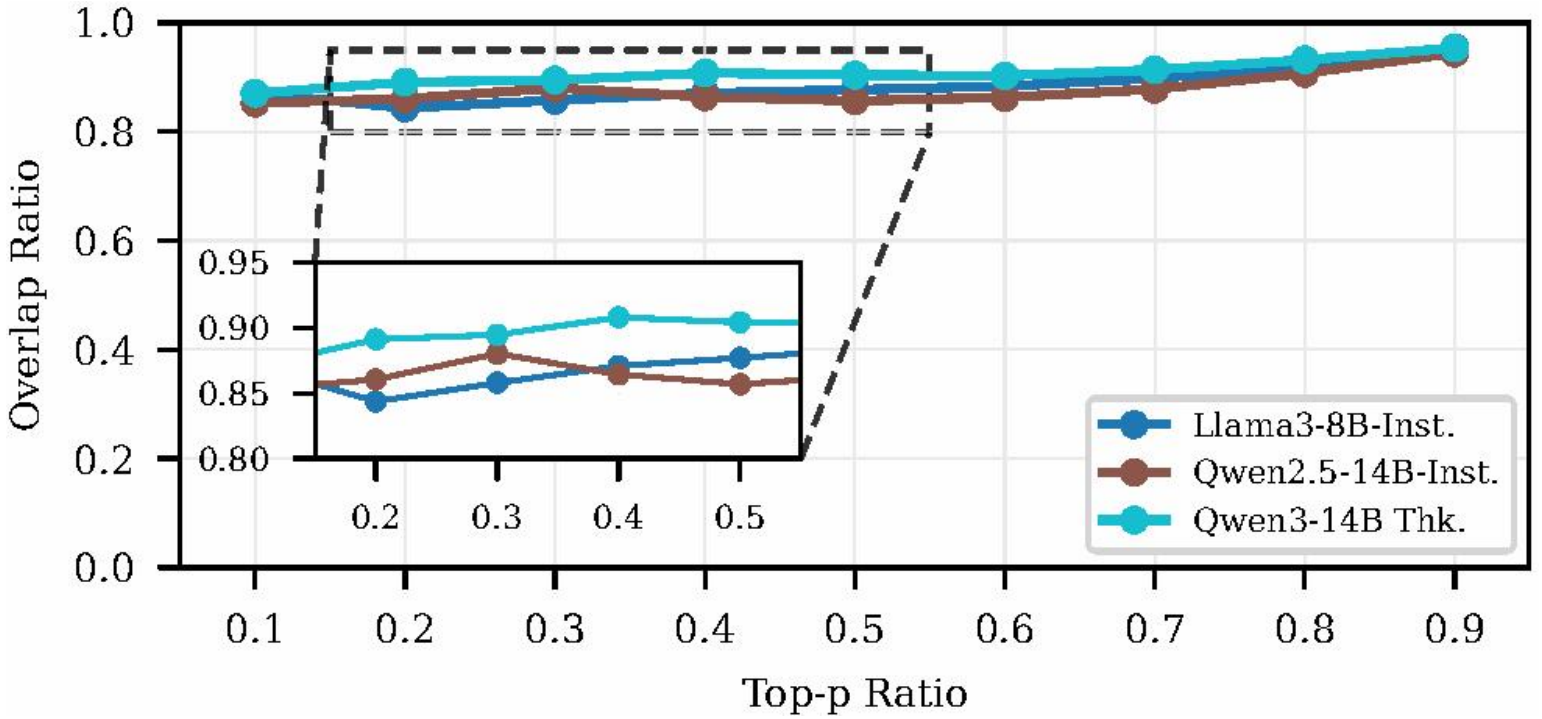
横轴：各自架构排序后排名前p个token

纵轴：前p个token集合与query实际关注集合的覆盖率

有限预算下
ProphetKV更贴近问题关注点

研究动机

Prefill与Decode之间的联系



RAG：问题位于文档之后

问题关注的位置
与后续生成关注的位置
有较高重合

方法

用问题注意力近似生成时的关注

$$g(t) \approx w(t)$$

$$\mathrm{w(t)} = \left(\frac{1}{|\mathrm{Q}|}\right) \sum \Phi(\mathrm{q}, \mathrm{t})$$

$$\mathrm{AttnOut}_n = \sum_{t \le n} \Phi_{n,t} V_t = \sum_{1 \le t \le s} \Phi_{n,t} V_t + \sum_{s < t \le n} \Phi_{n,t} V_t.$$

g(t)是生成时对t位置的注意力，w(t)是问题所有token对t位置的平均注意力

生成token注意力输出=文档先前注意力输出+已经生成token注意力输出

方法

理想排序需要知道多少误差

$$\alpha_{\text{ideal}}(t) = \| \widehat{\Phi}_{Qs,t} V_t - \widehat{\Phi}'_{Qs,t} V'_t \|_2,$$

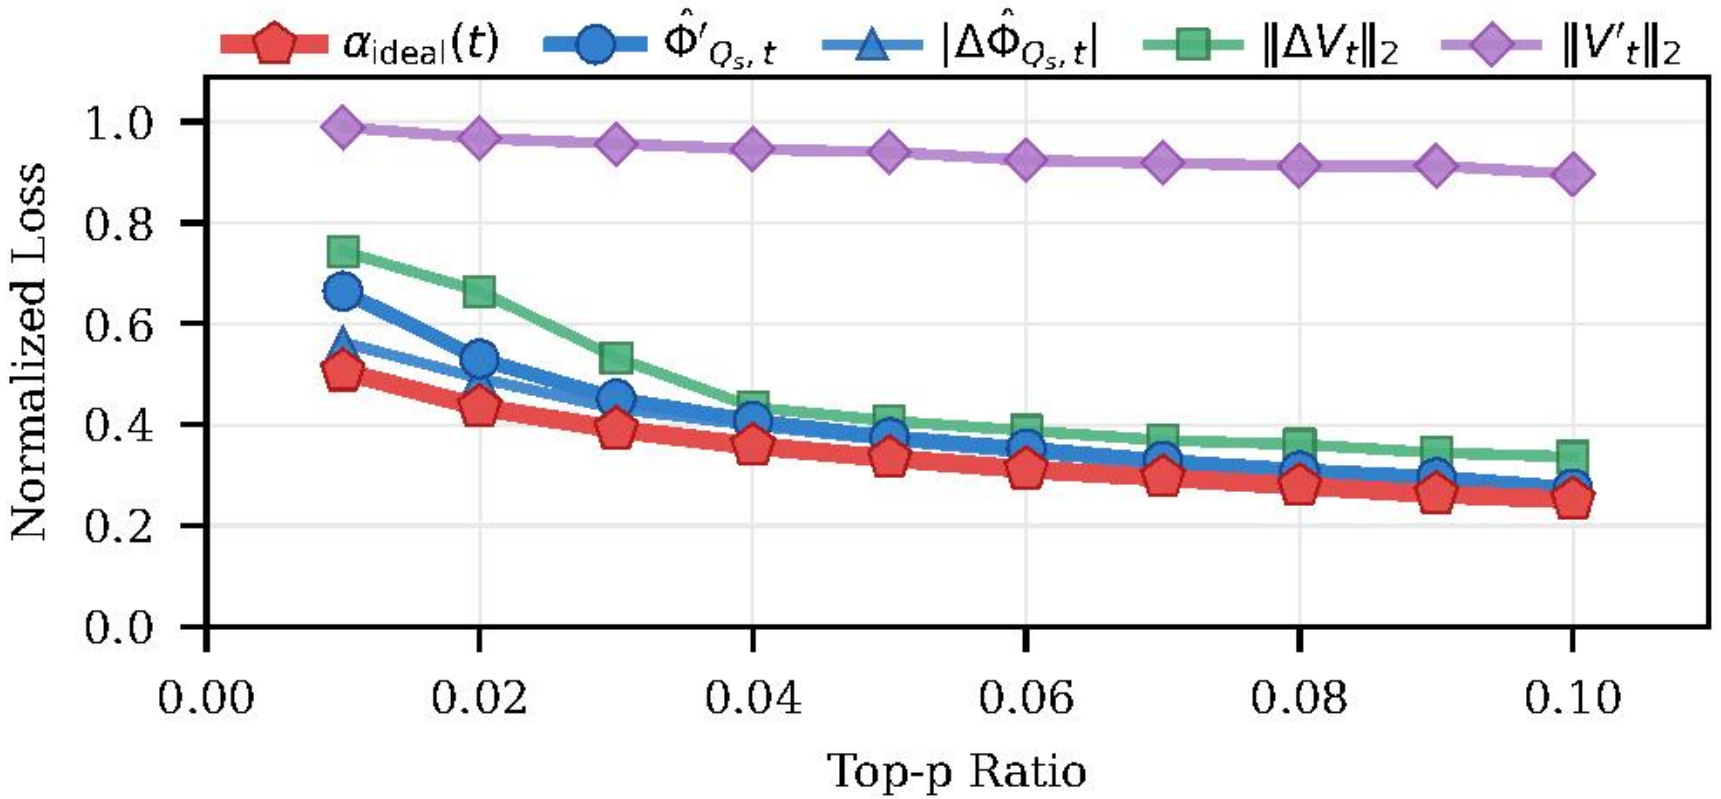
$$\alpha_{\text{ideal}}(t) = \| \left(\Delta\widehat{\Phi}_{Q_s,t}\right) V'_t + \left(\widehat{\Phi}'_{Q_s,t} + \Delta\widehat{\Phi}_{Q_s,t}\right) \Delta V_t \|_2,$$

$\left\|\left(\Delta\widehat{\Phi}_{Q_s,t}\right)\right\|$	完整 prefill 与旧缓存的平均注意力变化幅度
$\|\|V'_t\|\|_2$	旧缓存中，该位置的 Value 向量大小
$\widehat{\Phi}'_{Q_s,t}$	问题读取旧缓存时，对该位置的平均注意力
$\|\|\Delta V_t\|\|_2$	完整 prefill 与旧缓存的 Value 向量差异大小

理想分数需要完整参考计算，在线无法直接得到

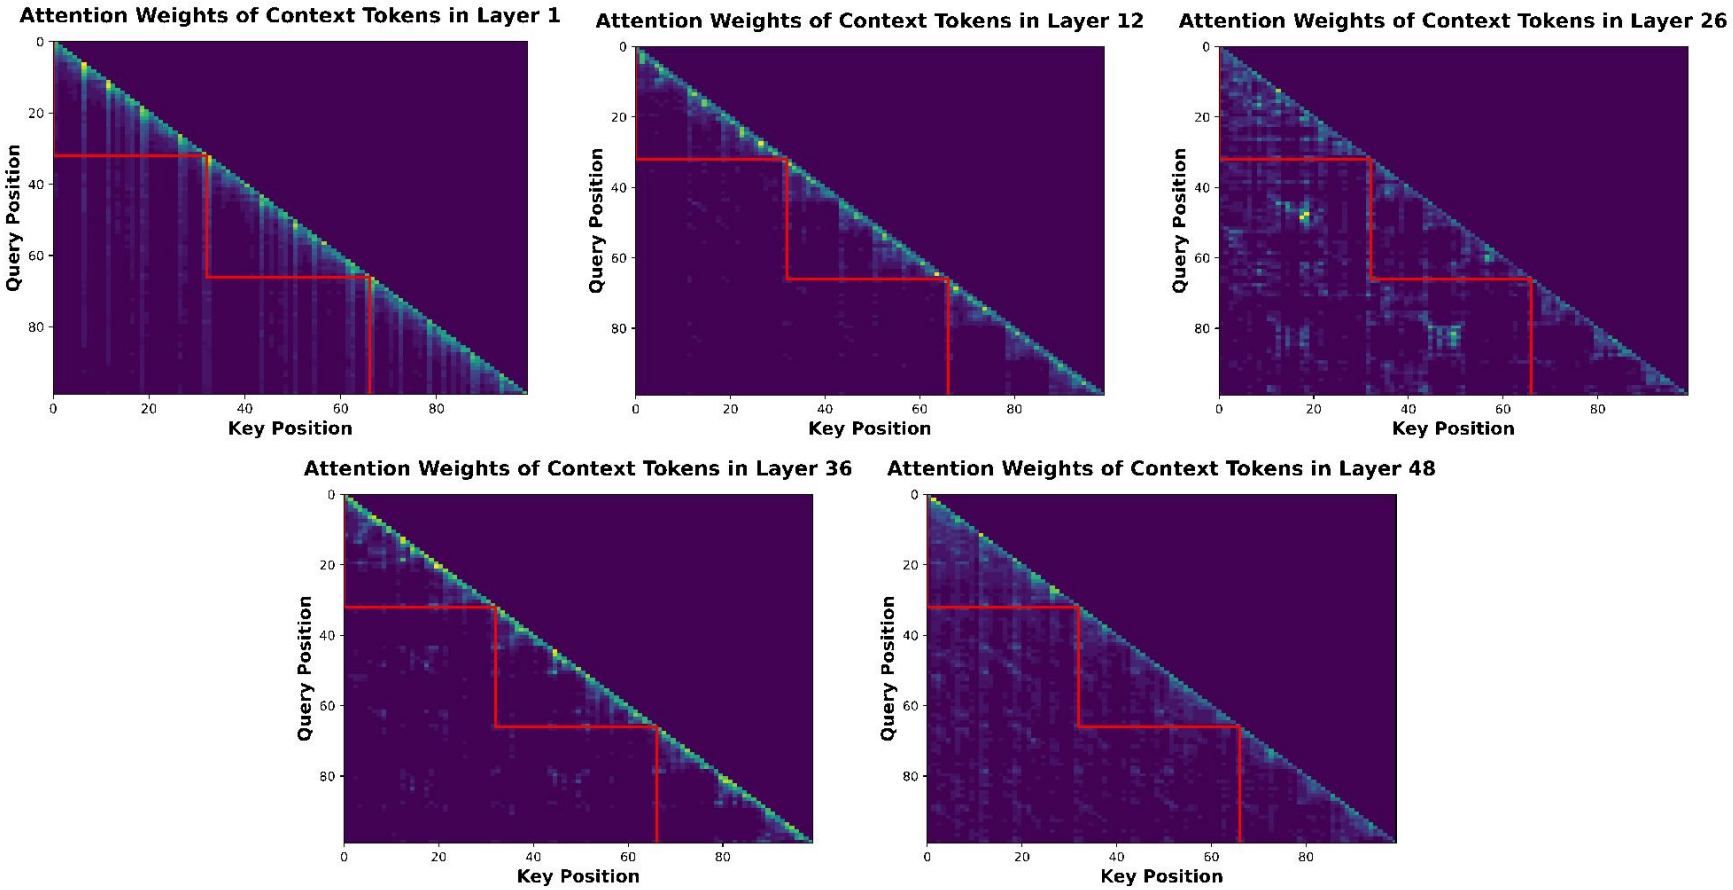
方法

旧缓存上的可观测代理



方法

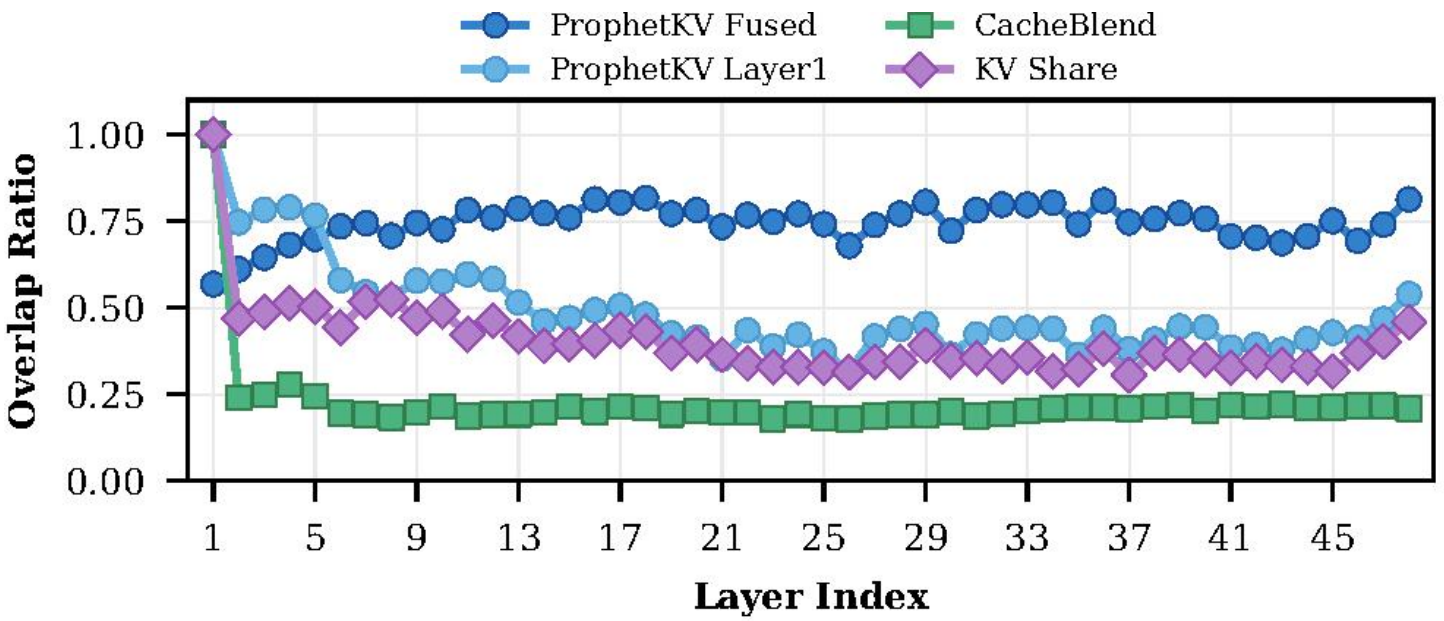
不同深度关注不同



浅层偏局部，高层还会聚合更远处信息

方法

跨层平均计算注意力

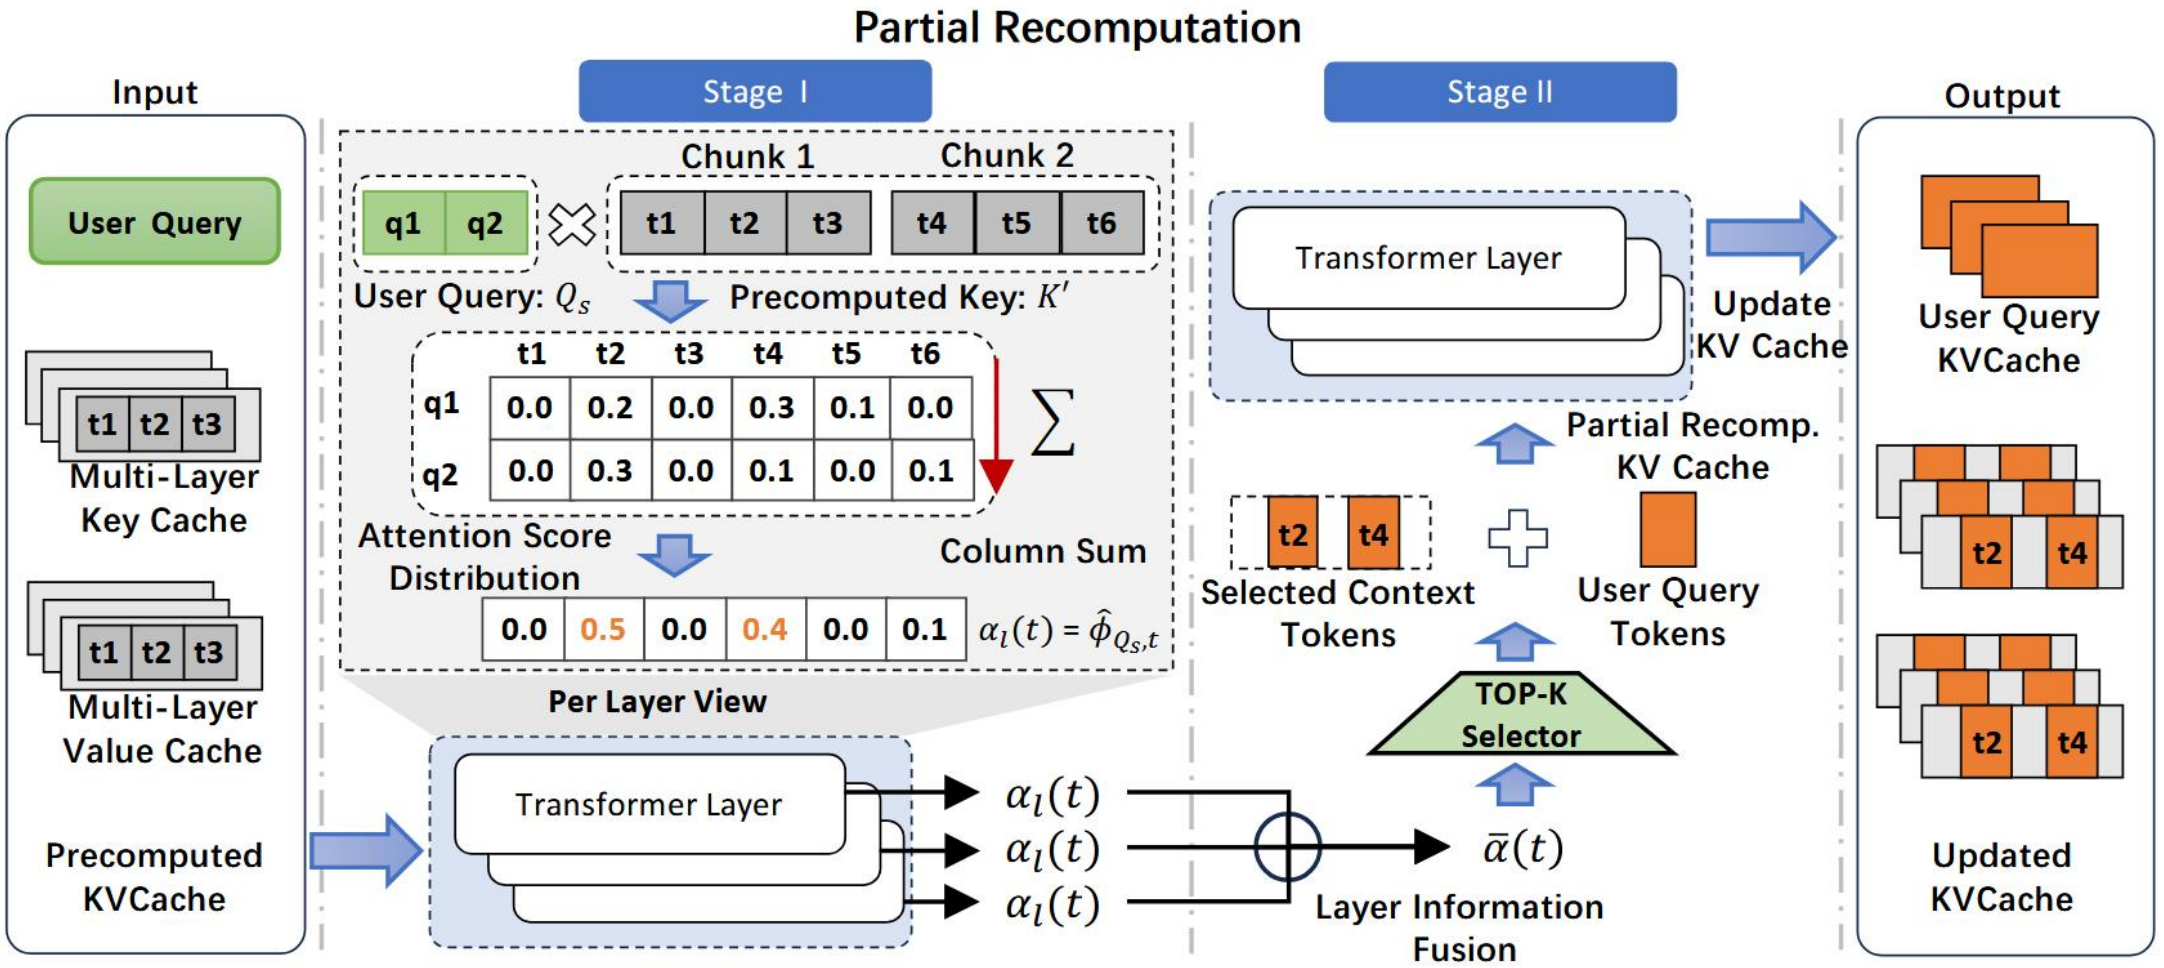


$$\bar{a}(t) = (1/L)\,\Sigma\,\alpha_l(t)$$

各层先给出分数
取均值后再选top-p

统一集合使各层张量形状规则
平均融合不保证逐项最优

方法


Partial Recomputation
Input
Stage I
Stage II
Output
User Query
Multi-Layer Key Cache
Multi-Layer Value Cache
Precomputed KVCache
Chunk 1
Chunk 2
q1 q2
t1 t2 t3 t4 t5 t6
User Query: Q_s
Precomputed Key: K'
Attention Score Distribution
Column Sum
0.0 0.2 0.0 0.3 0.1 0.0
0.0 0.3 0.0 0.1 0.0 0.1
0.0 0.5 0.0 0.4 0.0 0.1
$\alpha_l(t) = \hat{\phi}_{Q_s,t}$
Per Layer View
Transformer Layer
$\alpha_l(t)$
$\bar{\alpha}(t)$
Layer Information Fusion
TOP-K Selector
Selected Context Tokens
User Query Tokens
Partial Recomp. KV Cache
Update KV Cache
User Query KVCache
Updated KVCache

方法

20%重算比例与两阶段开销

上下文	第一阶段	第二阶段	两阶段之和
4K	0.015 s	0.138 s	0.153 s
8K	0.036 s	0.319 s	0.355 s
16K	0.050 s	1.082 s	1.132 s

16K时，探测约占本方法两阶段时间的4.4%

实验设置与比较口径

项目	论文设置
模型	Llama3.1-8B、Qwen2.5-14B、Qwen3-14B
任务	RULER、LongBench；上下文按512 token拆块
比较	完整prefill、直接复用、CacheBlend、EPIC、KVShare
实现	统一Hugging Face Transformers实现
计时	单张H100，batch size = 1

实验

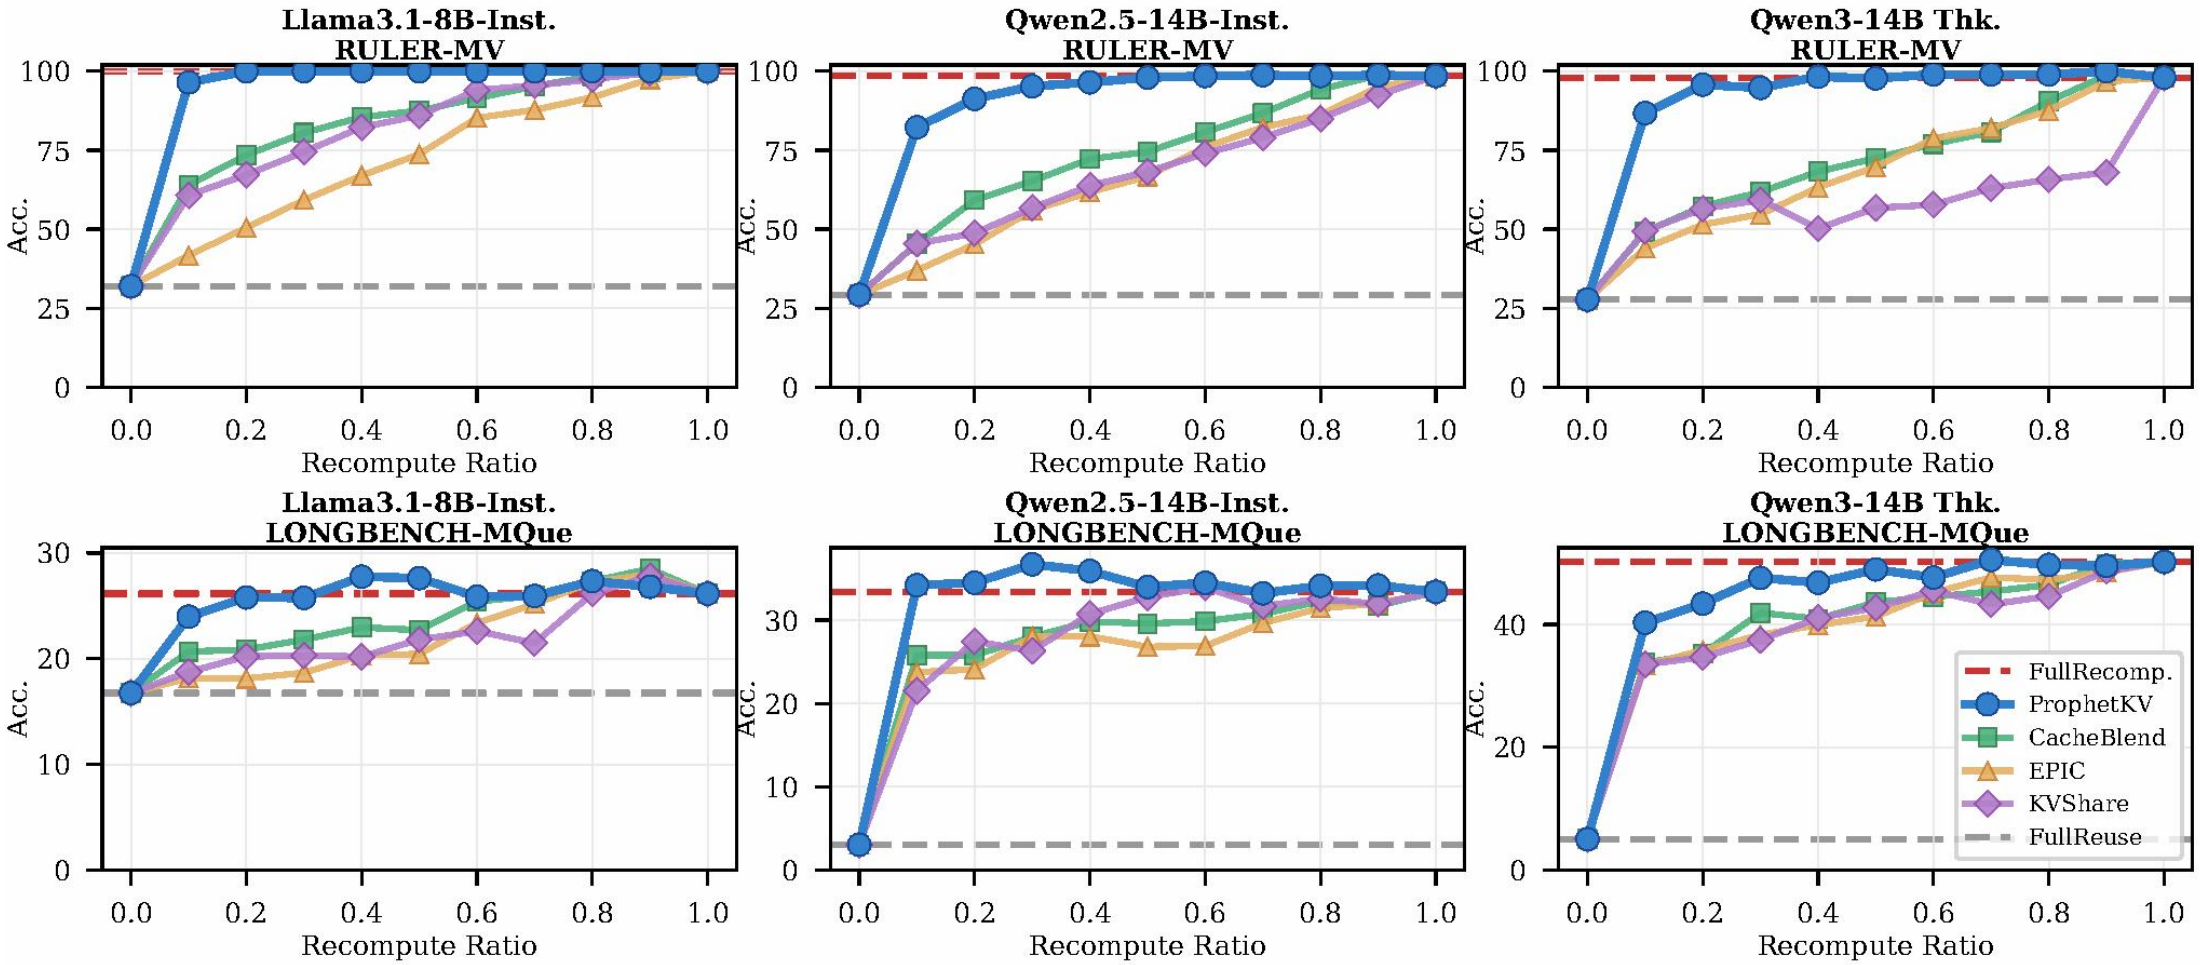
20%重算下，三种模型的任务均分

方法	Llama3.1-8B		Qwen2.5-14B		Qwen3-14B	
	RULER	LongBench	RULER	LongBench	RULER	LongBench
完整 prefill	88.82	50.19	90.28	54.86	91.79	61.06
直接复用	61.36	29.84	62.83	15.86	43.85	17.37
CacheBlend	77.27	39.82	78.11	35.40	71.99	50.17
EPIC	70.32	35.41	74.04	30.99	67.94	45.23
KVShare	73.47	38.67	73.35	34.82	70.64	48.90
ProphetKV	**84.71**	**50.80**	**88.60**	**53.43**	**89.89**	**59.52**

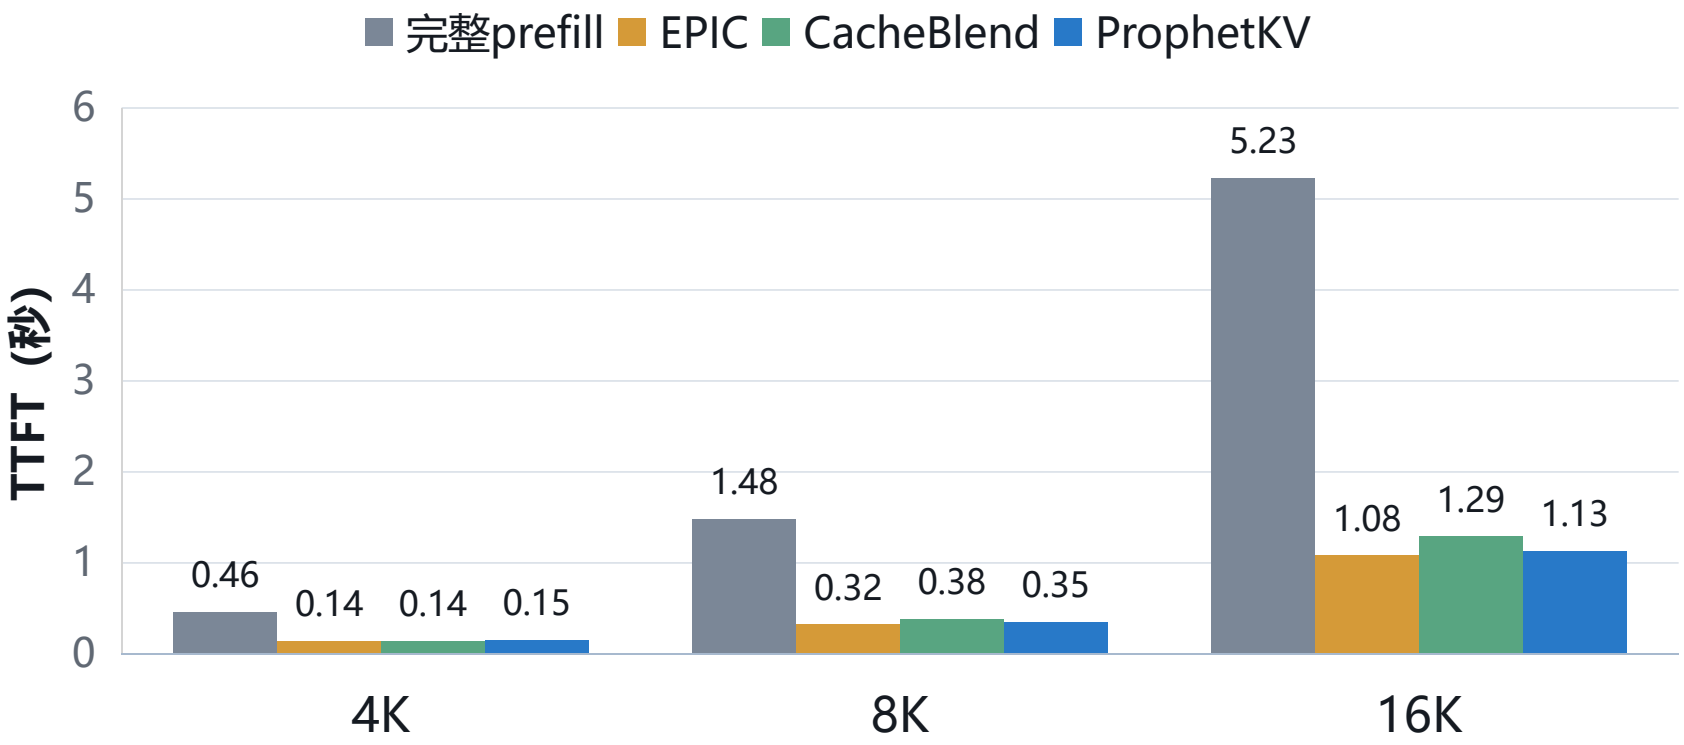
三种模型、两套基准：ProphetKV均高于三种部分重算基线

实验

重算预算变化时的结果



论文实现中的首字等待时间



16K，三种模型

4.6–4.7×

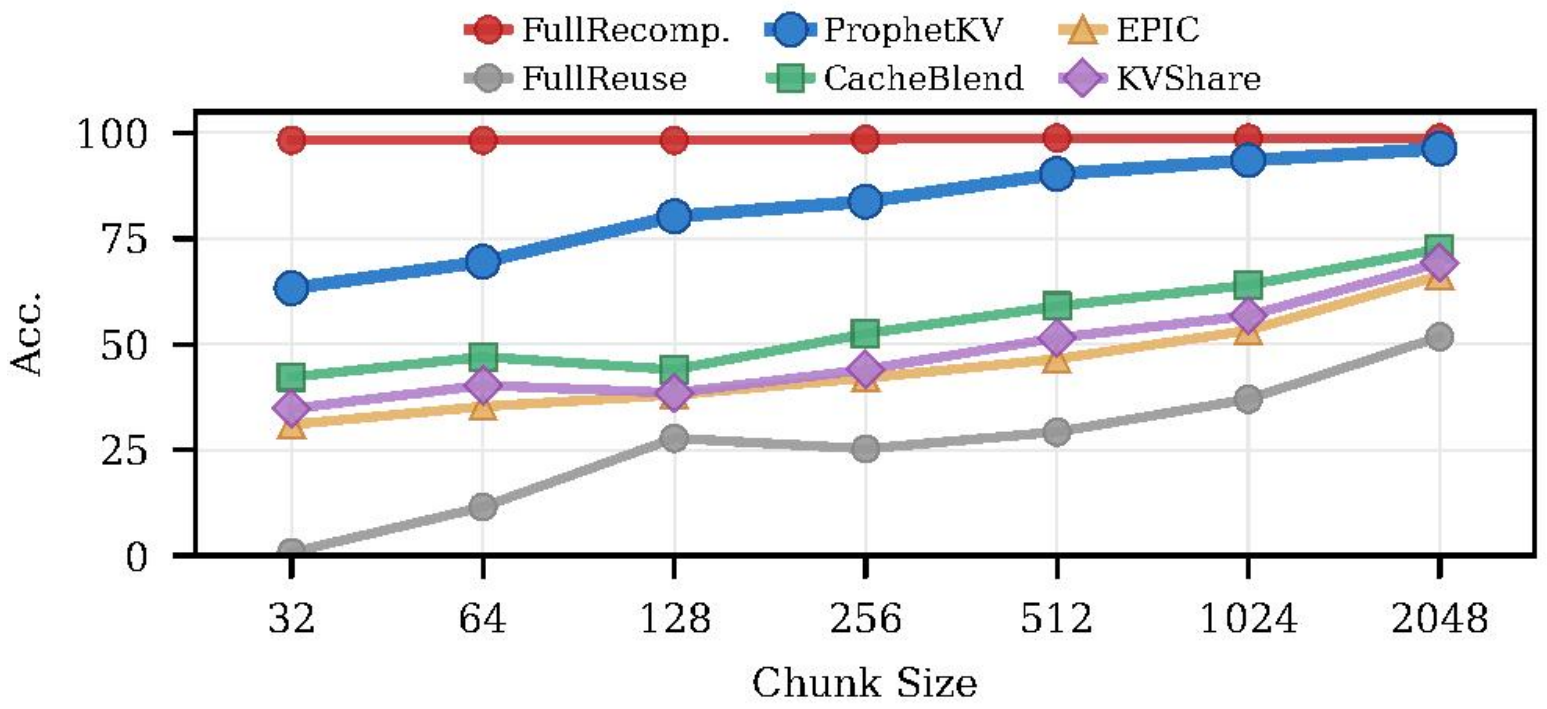
完整 / ProphetKV（秒）

Llama3.1	5.23 / 1.13
Qwen2.5	9.94 / 2.12
Qwen3	8.70 / 1.84

图示 Llama3.1-8B。单 H100，batch=1，重算20%，包含问题探测。

实验

文档块越碎，修复越困难



固定20%重算

32 token：约63分
2048 token：约96分

各分块设置下
均优于三种对比方法

讨论

目前证据覆盖到哪里

论文已展示	进一步验证的空间
问题注意力有预测价值	长链推理中的间接证据是否被漏选
多层平均较稳定	任务变化后能否调整层权重
两阶段包含探测仍能加速	缓存IO、多并发及优化引擎中的收益

适用条件：用于评分的问题位于文档之后，能看到证据。

结论与讨论

问题相关性改变了修复优先级

用当前问题的注意力，决定有限预算修哪里

两遍执行取得全层信号，再用同一集合完成修复

讨论：保持文档不变，只换问题，选中位置与答题收益怎样一起变化？

附录

完整主结果表

Methods	CWE	FWE	MK1	MQ	MV	Single	QA1	QA2	VT	Avg.	WQA	TQA	HQA	NQA	MQue	QMSum	PRetr_en	PRetr_zh	Avg.
Llama3.1-8B-Inst.	96.90	93.67	100.00	98.75	100.00	100.00	77.42	48.00	95.80	88.82	43.14	43.31	53.35	25.50	26.20	22.19	99.67	88.18	50.19
NaiveReuse	93.00	90.33	62.00	54.75	32.00	72.00	64.42	46.00	38.40	61.36	34.88	44.31	42.92	**24.48**	17.25	21.53	39.33	14.00	29.84
CacheBlend	93.60	89.33	77.00	82.25	73.50	**98.67**	77.17	49.00	54.60	77.27	39.10	**44.79**	46.75	22.77	20.91	22.60	73.67	48.00	39.82
EPIC	**96.10**	**93.00**	76.00	67.00	50.50	97.00	70.75	**52.00**	36.20	70.32	40.39	44.65	47.46	24.03	17.88	23.01	65.33	20.50	35.41
KVShare	92.90	87.33	73.00	79.50	67.25	97.00	67.42	45.00	51.40	73.47	36.20	44.22	45.48	23.55	20.50	22.76	65.67	51.00	38.67
ProphetKV	95.50	90.67	**99.00**	**98.50**	**100.00**	97.67	**77.33**	51.00	**67.00**	**84.71**	**43.21**	44.12	**50.69**	23.68	**24.38**	**23.35**	**99.00**	**98.00**	**50.80**
Qwen2.5-14B-Inst.	97.70	94.00	100.00	99.75	98.50	100.00	68.92	64.00	99.40	90.28	54.45	40.57	62.11	26.78	33.56	22.94	99.67	98.79	54.86
NaiveReuse	94.00	98.00	69.00	55.75	29.25	96.00	51.00	43.00	35.60	62.83	17.82	9.84	24.40	15.24	2.95	19.84	28.03	8.72	15.86
CacheBlend	96.40	99.00	94.00	93.00	59.25	**99.67**	60.00	59.00	58.60	78.11	44.39	27.42	52.61	22.25	27.02	21.48	69.11	18.92	35.40
EPIC	**97.30**	98.67	88.00	91.50	45.25	98.33	64.67	55.00	41.60	74.04	41.70	22.94	53.36	24.48	24.00	21.98	45.72	13.76	30.99
KVShare	95.80	98.67	92.00	88.50	48.75	**99.67**	63.00	53.00	39.40	73.35	43.85	25.80	50.07	23.93	26.76	21.76	65.06	21.30	34.82
ProphetKV	96.00	**99.33**	**97.00**	**97.00**	**91.25**	**99.67**	**70.17**	**60.00**	**95.40**	**88.60**	**52.32**	**39.82**	**58.13**	**26.68**	**35.60**	**22.51**	**99.67**	**92.67**	**53.43**
Qwen3-14B-Thk.	-	-	100.00	100.00	98.00	100.00	78.75	74.00	100.00	91.79	73.01	46.16	74.24	25.43	49.10	20.58	100.00	100.00	61.06
NaiveReuse	-	-	50.00	49.25	27.75	75.00	54.33	41.00	15.80	43.85	25.31	37.77	26.08	7.62	3.88	5.18	24.65	8.50	17.37
CacheBlend	-	-	72.00	77.50	57.25	98.33	70.08	64.00	64.80	71.99	63.91	45.30	63.85	23.82	37.81	**19.24**	73.90	73.50	50.17
EPIC	-	-	68.00	75.25	51.50	99.00	71.08	67.00	43.80	67.94	62.81	45.19	61.61	22.51	37.79	18.96	66.00	47.00	45.23
KVShare	-	-	68.00	77.25	56.50	**99.33**	72.75	65.00	53.00	70.64	61.84	45.26	64.95	22.61	33.26	18.49	71.78	73.00	48.90
ProphetKV	-	-	**97.00**	**96.50**	**95.75**	98.67	**76.42**	**72.00**	**100.00**	**89.89**	**70.83**	**46.53**	**70.77**	**25.33**	**44.12**	19.07	**100.00**	**99.50**	**59.52**

完整表保留原始任务列。LongBench各任务指标不同。